Instituto Tecnológico Autónomo de México

La regresión ordinal y discriminantes poblacionales como métodos de predicción del rendimiento en la Premier League

Tesis

que para obtener el título de

Licenciado en Actuaría / Matemáticas Aplicadas

Presenta

Ricardo Odilón Méndez Bribiesca

Asesora

Jorge Francisco de la Vega Góngora

Ciudad de México 2025

≪Con fundamento en los artículos 21 y 27 de la Ley Federal del Derecho de Autor y como titular de los derechos moral y patrimonial de la obra titulada "**La regresión ordinal y discriminantes poblacionales como métodos de predicción del rendimiento en la Premier League**", otorgo de manera gratuita y permanente al Instituto Tecnológico Autónomo de México y a la Biblioteca Raúl Bailléres Jr., la autorización para que fijen la obra en cualquier medio, incluido el electrónico, y la divulguen entre sus usuarios, profesores, estudiantes o terceras personas, sin que pueda percibir por tal divulgación una contraprestación.≫

Fecha

Ricardo Odilón Méndez Bribiesca

A mis padres,
por su esfuerzo.

Agradecimientos

El siguiente trabajo va dedicado a mi familia, amigos, profesores y compañeros que me han acompañado a lo largo de mi vida y que me han permitido desarrollar dos de mis mayores gustos: fútbol y matemáticas.
A mi mamá por apoyarme a lo largo de mi vida y a mi papá por escucharme y ver tantos partidos de fútbol conmigo. A mi hermana Bere por regalarme mi primera playera del Tottenham y acercarme a este gran equipo. A mi hermana Sofía por apoyarme en momentos estresantes de la carrera. A mis cuñados Rafa y Daniel por las pláticas de la liga inglesa y a mi sobrino Rafita por traer alegría a la familia. A Barbie por motivarme y darme consejos para LaTex.
A Rodri por ser de mis mejores amigos y darme tan buenas ideas para este trabajo. A Sebas por las risas durante la pandemia y la carrera. A todos los grandes amigos que fui haciendo durante el camino: Caraveo, Regina, Polo, Dodo, Sou, Sop, Ale, Parente, Lomelí y Monse. A Durán por corretearme por avances.
A todos los profesores y profesoras que tuve el gusto de conocer durante mi tiempo en el ITAM.
Finalmente, a Jorge Francisco de la Vega Góngora por su apoyo y dedicación para poder desarrollar este trabajo.

Resumen

La presente tesis consiste en una investigación en la cual busco determinar los factores que influyen principalmente en el rendimiento de un equipo de la primera división inglesa de fútbol. Estos factores incluirán variables deportivas como goles, pases, intercepciones, lesiones y no deportivas como traspasos, dinero invertido, asistencia al estadio, participación en competiciones europeas, etc. La meta de este trabajo será determinar cuáles características influyen principalmente en el ranking o posición de la tabla terminarán los equipos al final de la temporada, si podrán salvarse del descenso y si clasificarán a la UEFA Champions League.

La información utilizada incluye bases de datos desde la temporada 2015-2016 hasta la temporada 2023-2024 de todos los equipos que participaron en la Premier League durante esos años. Se exploraron los datos para entender qué variables podrían tener mayor relevancia y así abordar el problema con una variedad de modelos con la finalidad de predecir la posición de cada equipo basada en las variables que resultaron más significativas.

La Premier League fue la competencia elegida para este trabajo por

ser de las ligas más competitivas y de las más vistosas de fútbol profesional. Asimismo, fue interesante consolidadr una base de datos que contiene datos deportivos y extradeportivos, ya que no se pudo encontrar una base de datos que incluyera todas las variables consideradas en la investigación. Podría ser interesante extender un análisis similar a otro tipo de ligas de fútbol más impredecibles, como la Liga MX, y tratar de encontrar un modelo adecuado que, como aficionado, es difícil de imaginar.

Índice general

Introducción **1**

1. Contexto **4**

1.1. El fútbol 5

1.2. La liga inglesa 5

1.3. Planteamiento a resolver 6

2. Metodología **7**

2.1. Regresión lineal múltiple 8

2.1.1. Modelo 8

2.1.2. Selección de variables 9

2.2. Regresión ordinal 10

2.2.1. Modelo 10

2.3. Regresión Logit 13

2.3.1. Modelo Logit 13

2.3.2. Regresión Logit con penalización Lasso 14

2.3.3. Regresión Logit con penalización Ridge 15

2.4. Análisis discriminante 16

2.4.1. Análisis discriminante lineal (LDA) 16

2.4.2. Análisis discriminante cuadrático (QDA) 17

3. Bases de datos **19**
3.1. Creación de base de datos 20

4. Análisis y modelos de la Premier League **23**
4.1. Análisis exploratorio de datos 24
4.1.1. Desempeño en el campo de juego 24
4.1.2. Características extra cancha 30
4.2. Regresión Lineal 31
4.3. Regresión Ordinal 33
4.4. Discriminación de dos poblaciones 39
4.4.1. Champions League 41
4.4.2. Descenso 42

Conclusiones **43**

A. Código R **46**

Referencias **47**

Índice de cuadros

3.1. Desempeño en el campo de juego 21
3.2. Desempeño en el ranking 22
3.3. Características extra cancha 22

4.1. Coeficientes del modelo de regresión ordinal 37
4.2. Precisión de los modelos lineales y ordinales 38
4.3. Champions League: Precisión de los modelos de separación de poblaciones 41
4.4. Descenso: Precisión de los modelos de separación de poblaciones 42

Índice de figuras

4.1. Diferencia de goles (goles a favor menos goles en contra) promedio por la posición de la tabla 24
4.2. Tiros a gol 27
4.3. Goles a favor 27
4.4. Diferencia de goles 28
4.5. Correlación 29
4.6. Relación entre valor promedio (millones de dólares estadounidenses) de jugadores y posición en la tabla . . 30

Introducción

Disertación

La motivación para realizar este trabajo es poder combinar mi afición por el fútbol inglés y mi gusto por la estadística, y así realizar un análisis que pueda determinar qué métricas deportivas y extradeportivas pueden influir en el rendimiento de un equipo durante una temporada futbolística. Se aplicarán métodos vistos durante las materias de la carrera para hacer un análisis exploratorio de datos, regresiones logit y discriminantes lineales y cuadráticos. Asimismo, se utilizará un método no visto como la regresión ordinal.

La Premier League es de las ligas de fútbol más populares en el mundo. Su método de clasificación para torneos internacionales, para ascender/descender y, en general, su competitividad son los principales motivos por los que he decidido realizar este análisis y, así, entender mejor que variables influyen en el rendimiento de cada equipo.

El trabajo constará con 6 capítulos de contenido: en primer lugar, se establecerá el problema la investigación; en segundo lugar, se contextualizará sobre el fútbol inglés y su método de clasificación; en

tercer lugar, se hablará de los métodos utilizados para crear los modelos; en cuarto lugar, se hablará de la base de datos; en quinto lugar, se analizarán los datos, se realizarán los modelos pertinentes y se comparar para entender su relevancia; finalmente, en sexto lugar, se darán las conclusiones pertinentes.

Objetivo

La meta principal del trabajo es entender qué variables deportivas y extradeportivas influyen en el rendimiento de cada equipo para predecir la probabilidad de que queden en cada posición de la tabla, logren clasificarse a la UEFA Champions League y mantenerse en la primer división. Para esto, se usarán los datos de las ligas desde la 2015/2016 hasta la 2023/2024 y métodos de comparación entre modelos para seleccionar cuáles son las variables más relevantes.

Capítulo 1

Contexto

1.1. El fútbol

El fútbol es un deporte colectivo donde dos equipos de 11 jugadores se enfrentan y tratan de meter gol en la portería del equipo rival. Los jugadores pueden usar cualquier parte del cuerpo, excepto los brazos y manos. Los once jugadores de cada equipo tienen funciones diferentes: los delanteros marcan goles, los mediocampistas recuperan el balón y crean juego, los defensas protegen la portería y los porteros evitan los goles rivales. Los partidos duran 90 minutos, y el equipo con más goles gana. El fútbol surgió en el siglo XIX en Inglaterra y se convirtió en el deporte más popular del mundo en el siglo XX.

1.2. La liga inglesa

La primera división inglesa, también conocida como *Premier League*, es la máxima categoría de clubes en Inglaterra. Fundada en 1992, se separó de la Football League para incrementar el nivel de juego. La liga consta de 20 equipos que se enfrentan entre todos de local y de visita, resultando en un total de 380 partidos a lo largo del año. Cada partido puede resultar en victoria, empate o derrota para cada equipo, lo que otorga 3 puntos, 1 punto o 0 puntos, respectivamente. Cada jornada, estos puntos se van acumulando en un ranking. Los tres últimos equipos en el ranking descienden a la Championship (segunda división) y, usualmente, los cuatro primeros se clasifican a la UEFA Champions League, la competencia de clubes más prestigiosa a nivel mundial. La Premier League se caracteriza por ser de las más competitivas a nivel mundial. Equipos como el Arsenal, Chelsea, Liverpool, Manchester City, Manchester United y Tottenham (conocidos como el "Big 6") luchan por el título y por las posiciones para clasificar a competencias europeas.

Aunque en ocasiones, equipos fuera de este grupo, como el Leicester City en la temporada 2016-2017, logran clasificarse para torneos europeos e incluso ganar el campeonato.

1.3. Planteamiento a resolver

A lo largo de la temporada, se registra información deportiva (goles, tiros, pases, faltas, entre otras) y extracancha (gasto en transferencia, asistencia al estadio, entre otras) que podría relacionarse con la posición de cada equipo en el ranking al final de la temporada. Es por esto que este trabajo se centrará en distintos métodos para predecir la variable dependiente, como la posición en el ranking o la clasifiación a la Champions League, a través de variables independientes (pases, goles, faltas, entre otras). Casas de apuestas y trabajos de investigtación, como *Statistical Analysis of the Effectiveness of the FIFA World Rankings (McHale & Davies, 2007)* o *Competitive Balance in National European Soccer Competitions (Haan, 2007)* han utilizado este tipo de información para desarrollar modelos de predicción y discriminación de poblaciones para entender mejor este deporte.

Capítulo 2

Metodología

2.1. Regresión lineal múltiple

2.1.1. Modelo

El método de regresión lineal múltiple estudia la construcción de modelos para explicar o representar la dependencia entre una variable dependiente (y) y las variables independientes (x) de manera lineal. Es decir, se utilizará el modelo de regresión lineal múltiple, como un acercamiento previo, para explicar y predecir la variable "Posición" a partir de las variables predictivas (45 características observadas).

El modelo de regresión lineal múltiple se puede expresar de la siguiente forma:

$$Y = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + ... + \beta_k X_{ik} + \varepsilon, \tag{2.1}$$

Donde:

- Y es la variable dependiente (el resultado a predecir)
- $X_{i1}, X_{i2}, ..., X_{ik}$ son las variables independientes (factores que potencialmente afectan a Y)
- β_0 es la ordenada al origen (la constante que representa el valor de Y cuando todas las X_{ik} son cero)
- $\beta_1, \beta_2, ..., \beta_k$ son los coeficientes de regresión que indican la magnitud y dirección de la influencia de cada X_{ik} sobre Y
- ε es el término de error, que captura la variabilidad en Y que no puede ser explicada por las variables independientes

Supuestos:

- Linealidad: La relación entre las variables dependiente e independientes es lineal
- Independencia: Las observaciones son independientes entre sí
- Homocedasticidad: Los residuos (errores) tienen varianza constante para todos los niveles de las variables independientes
- Normalidad de los residuos: Los errores del modelo siguen una distribución normal

2.1.2. Selección de variables

Se utilizará el método AIC (Criterio de Información de Akaike) para seleccionar el modelo que mejor balance tenga entre cantidad de variables y calidad. El modelo se expresa como:

$$AIC = 2k - 2ln(L) \tag{2.2}$$

Donde

- k es el número de parámetros estimados en el modelo
- $ln(L)$ es el logaritmo de la verosimilitud del modelo, que mide qué tan bien el ajusta los datos observados

Bajo este criterio, conforme AIC sea menor, se ajusta mejor el modelo. Por lo que el criterio castiga modelos con un alto número de variables y beneficia a aquellos con mayor verosimilitud.

2.2. Regresión ordinal

2.2.1. Modelo

La regresión ordinal es utilizada para modelar la relación entre una variable dependiente ordinal (posición de cada equipo en el ranking) y una o más variables independientes. Una variable dependiente ordinal es aquella que presenta un orden inherente entre sus categorías, como en este caso puede ser la posición de cada equipo en la tabla de clasificación.

El modelo comúnmente utilizado en regresión ordinal es el modelo de probabilidades proporcionales, también conocido como modelo *logit* ordenado. Este modelo supone que la relación entre cada par de categorías de la variable dependiente es constante en todos los niveles de las variables independientes. Matemáticamente, se expresa mediante la función *logit* acumulativa, que estima la probabilidad de que una observación pertenezca a una categoría específica o a una inferior, en función de una combinación lineal de las variables independientes.

La ecuación de un modelo de regresión ordinal con k categorías en la variable dependiente Y se basa en la probabilidad acumulativa de pertenecer a una categoría o a una inferior y se expresa de la siguiente manera:

$$\begin{gathered} log(\frac{P(Y \leq j)}{1 - P(Y \leq j)}) = log(\frac{\theta_j}{1 - \theta_j}) = \star \\ \star = \alpha_j + \beta_1 X_1 + \beta_2 X_2 + ... + \beta_p X_p = \gamma_j - x\prime\beta \end{gathered} \tag{2.3}$$

Donde:

- $P(Y \leq j)$ es la probabilidad acumulada de que la variable dependiente Y tome un valor menor o igual a j (con $j = 1, 2, ..., k-1$)
- α_j es la intersección específica de cada categoría, que varía para cada j
- $X_1, X_2, ..., X_p$ son las variables independientes
- $\beta_1, \beta_2, ..., \beta_p$ son los coeficientes de regresión que indican el efecto de las variables independientes sobre la probabilidad de estar en una categoría mayor de Y

Es importate notar que el signo del coeficiente del predictor lineal es negativo, contrario al signo positivo utilizado comúnmente en de las regresiones binarias.

Una característica interesante del modelo es que la proporción (también conocido como momio) de las probabilidades para el evento $y_1 \leq j$ y el evento $y_2 \leq j$ es:

$$\frac{\frac{\theta_{1j}}{1-\theta_{1j}}}{\frac{\theta_{2j}}{1-\theta_{2j}}} = exp[-(x_1 - x_2)'\beta] \tag{2.4}$$

Independientemente de la categoría de respuesta j. Por esta razón, el modelo es conocido como el modelo de categorías proporcionales (McCullagh, 1980).

Supuestos:

- Probabilidades proporcionales: las relaciones entre cada par de categorías de la variable dependiente son iguales en todos los niveles de las variables independientes
- Independencia de las observaciones: Cada observación debe ser independiente de las demás
- Ausencia de multicolinealidad: Las variables independientes no deben estar altamente correlacionadas entre sí
- Linealidad: Se asume que existe una relación lineal entre las variables independientes y las probabilidades logarítmicas de las categorías de la variable dependiente

2.3. Regresión Logit

La regresión logística es utilizada cuando algunas o todas las variables explicativas son cualitativas. En su expresión más simple, la variable de respuesta solo toma dos valores: 1 y 0 y, en este trabajo, se puede entender como "clasificado a Champions League" o "No clasificado a Champions League".

2.3.1. Modelo Logit

Si en lugar de modelar directamente la probabilidad θ_j, primero se considera la proporción:

$$Momio = \frac{\theta_j}{1 - \theta_j} \tag{2.5}$$

que es la proporción de la probabilidad de que se tome el valor 1 entre la probabilidad del valor 0. Se puede notar que la proporción puede ser mayor a 1. El modelo logit se define como:

$$logit(\theta_j) = log(momio) = log(\frac{\theta_j}{1 - \theta_j}) = x'\beta \tag{2.6}$$

De donde se obtiene que:

$$\frac{\theta_j}{1 - \theta_j} = exp[x'\beta] \tag{2.7}$$

Y de donde:

$$\theta_j = \frac{1}{1 + exp[x'\beta]} \tag{2.8}$$

2.3.2. Regresión Logit con penalización Lasso

Lasso (*Least Absolute Shrinkage and Selection Operator*) es un método que penaliza el valor absoluto de los coeficientes del modelo, lo que promueve modelos más simples donde algunos coeficientes se reducen a cero, y así solo se seleccionan ciertas variables.

La función objetivo de una regresión logística con penalización Lasso es:

$$min_{\beta} = -\frac{1}{n}\sum_{i=1}^{n}[y_i log(p_i) + (1-y_i)log(1-p_i)] + \lambda\sum_{j=1}^{k}|\beta_j| \qquad (2.9)$$

Donde:

- $p_i = \frac{1}{1+exp[-(\beta_0+\sum_{j=1}^{k}\beta_j x_{ij})]}$
- $\lambda \geq 0$ es el parámetro de penalización de los coeficientes de las variables

Conforme λ es mayor, más coeficientes son castigados al realizar la minimización

Además de los supuestos de la regresión logística, existen algunos supuestos adicionales:

- Variables irrelevantes: Lasso es útil si se sospecha que algunas variables no son significativas
- Multicolinealidad moderada: Lasso puede ayudar a manejar multicolinealidad eliminando variables redundantes, aunque no siempre de la forma óptima

2.3.3. Regresión Logit con penalización Ridge

A diferencia de Lasso, Ridge (también llamada Tikhonov) es un método de penalización cuadrática sobre los coeficientes. Este método reduce continuamente, dando modelos donde todas las variables tienen un pequeño efecto.

La función objetivo de una regresión logística con penalización Ridge es:

$$min_{\beta} = -\frac{1}{n}\sum_{i=1}^{n}[y_i log(p_i) + (1-y_i)log(1-p_i)] + \lambda\sum_{j=1}^{k}\beta_j^2 \qquad (2.10)$$

Donde:

- $p_i = \frac{1}{1+exp[-(\beta_0+\sum_{j=1}^{k}\beta_j x_{ij})]}$
- $\lambda \geq 0$ es el parámetro de penalización de los coeficientes de las variables

Supuestos adicionales:

- Multicolinealidad: Ridge es especialmente útil cuando existe alta colinealidad entre las variables independientes, debido a que tiende a estabilizar las estimaciones

2.4. Análisis discriminante

El análisis discriminante se utiliza para clasificar en grupos a partir de variables predictoras. El objetivo es definir la función que maximiza la separación entre clases, minimizando al mismo tiempo la variabilidad dentro de cada grupo. Las variantes que se utilizarán en esta investigación son el Análisis Discriminante Lineal (LDA) y el Análisis Discriminante Cuadrático (QDA). En esta sección, se utilizarán estos modelos para también entender si los equipos se clasificarán a la Champions League o si se salvarán de descender a la segunda división.

2.4.1. Análisis discriminante lineal (LDA)

El LDA asume que las observaciones de cada clase k provienen de una distribución normal multivariada con media μ_k y una matriz de covarianza común Σ. De esta manera, se obtiene una función discriminante lineal que clasifica observaciones según la probabilidad de pertenecer a cada clase.

La regla de clasificación se basa en maximizar la función discriminante:

$$\delta_k(x) = X'\Sigma^{-1}\mu_k - \frac{1}{2}\mu'_k\Sigma^{-1}\mu_k + log(p_k) \tag{2.11}$$

Donde:

- μ_k es la media del grupo k
- Σ es la matriz de covarianza
- $p_k = \frac{N_k}{N}$ es la probabilidad a priori de la clase k

Al momento de utilizar el modelo, una observación x es clasificada en la clase k en la que tenga el mayor valor.

Supuestos del LDA:

- Las variables predictoras siguen una distribución normal multivariada dentro de cada grupo
- Las matrices de covarianza son iguales para todas las clases
- Las observaciones son independientes entre sí
- Las clases son mutuamente excluyentes

2.4.2. Análisis discriminante cuadrático (QDA)

El Análisis Discriminante Cuadrático (QDA) es una generalización del LDA que relaja el supuesto de igualdad de matrices de covarianza entre clases. Para este método, se permite que cada grupo k tenga su propia matriz de covarianza Σ_k y, como resultado, las fronteras de decisión ya no son lineales, sino superficies cuadráticas.

La función discriminante en QDA está dada por:

$$\delta_k(x) = -\frac{1}{2}log(|\Sigma_k|) - \frac{1}{2}(x - \mu_k)'\Sigma_k^{-1}(x - \mu_k) + log(p_k) \tag{2.12}$$

Al igual que en LDA, a una observación se le asigna la clase con mayor valor de la función.

Supuestos del QDA:

- Las variables predictoras siguen una distribución normal multivariada dentro de cada grupo
- Cada clase tiene su propia matriz de covarianza Σ_k
- Las observaciones son independientes
- Las clases son mutuamente excluyentes

Capítulo 3

Bases de datos

Este capítulo tiene el propósito de explicar la construcción y variables de la base de datos.

3.1. Creación de base de datos

Para los propósitos de este trabajo, recopilé datos de 9 temporadas de la Premier League (2015/2016-2023/2024) sobre el desempeño y características de los 20 equipos por temporada. La base de datos está compuesta de 180 entradas con 43 variables sobre temas de desempeño dentro y fuera de la cancha. Para construir la base, la información fue extraída del sitio oficial de la Premier League (Premier League, 2025), el sitio especializado en data de fútbol FBREF (FBREF, 2025) y el sitio especializado en transferencias de jugadores (Tranfermarkt, 2025). Con esta información, las siguientes variables fueron creadas:

Cuadro 3.1. Desempeño en el campo de juego

Variable	Descripción
1. Goles a favor	Goles anotados a lo largo de la temporada
2. Goles en contra	Goles recibidos a lo largo de la temporada
3. Diferencia de goles	Resta de goles a favor y en contra
4. Porterías a cero	Cantidad de partidos sin recibir gol
5. Tarjetas amarillas	Cantidad de tarjetas amarillas recibidas
6. Tarjetas rojas	Cantidad de tarjetas rojas recibidas
7. XGF	Goles anotados esperados a lo largo de la temporada
8. XGC	Goles recibidos esperados a lo largo de la temporada
9. GvsXG	Diferencia de goles anotados y goles anotados esperados
10. Tiros	Tiros realizados
11. Tiros a Gol	Tiros realizados con dirección a portería
12. Tiros	Tiros realizados
13. Tiros a Gol	Tiros realizados con dirección a portería
14. Goles de penal	
15. Goles de cabeza	
16. Goles dentro del área	
17. Goles fuera del área	
18. Goles de contragolpe	
19. Fueras de lugar	
20. Autogoles	
21. Penales provocados	
22. Atajadas	
23. Despejes	
24. Barridas	
25. Faltas	
26. Total de pases	
27. Pases filtrados	
28. Pases hacia atrás	
29. Centros	
30. Tiros de esquina	

Cuadro 3.2. Desempeño en el ranking

Variable	Descripción
31. Competencias europeas	Indica si el equipo participó en un torneo europeo
32. Recien Ascendido	Indica si el equipo recien ascendió
33. Champions League	Indica si el equipo logró clasificarse a Champions League
34. Descenso	Indica si el equipo descendió

Cuadro 3.3. Características extra cancha

Variable	Descripción
35. Temporada	Indica el año
36. Big 6	Indica si el equipo es del *Big 6*
37. Gasto por transferencias	
38. Ingreso por transferencias	
39. Jugadores nuevos	Cantidad de jugadores que llegaron
40. Jugadores vendidos	Cantidad de jugadores que se fueron
41. Valor de la plantilla	
42. Cantidad de jugadores	
43. Valor promedio de los jugadores	
44. Asistencia promedio al estadio	Cantidad de asistentes al estadio
45. Ventaja de local	Diferencia porcentual de ventaja de local

Capítulo 4

Análisis y modelos de la Premier League

En este último capítulo se analizarán los datos y se generarán modelos de predicción

4.1. Análisis exploratorio de datos

4.1.1. Desempeño en el campo de juego

A continuación, se realizará un análisis exploratorio de datos para entender las posibles relaciones en las variables. Para analizar la primera división de fútbol inglesa, se analizarán datos de los últimos 9 años. Esta información incluye goles a favor y en contra, tipos de goles, tipos de pases, inversión en transferencias, asistencia al estadio, entre otras. El objetivo será encontrar qué variables influyen más en la posición en la tabla, así como en si un equipo podrá entrar a puestos de Champions League o salvarse de un posible descenso. A continuación se muestra un resumen de la diferencia de goles de por posición en la tabla:

Figura 4.1. Diferencia de goles (goles a favor menos goles en contra) promedio por la posición de la tabla

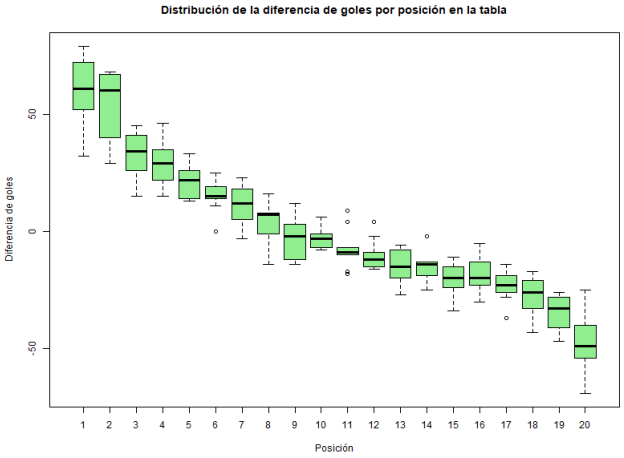

Al observar en la gráfica 4.1 los cuartiles y el promedio, se identifica variabilidad entre la diferencia de goles a través de las posiciones, específicamente en las primeras 4 posiciones, en la 8 y en la 20. Al relacionarlo con la situación de los equipos, se podría sugerir un impacto en la posición de cada equipo por variables como Goles a Favor, Goles en Contra, Tiros a puerta, Goles de Contragolpe, Valor promedio de los jugadores, Inversión en transferencias o la Asistencia promedio, lo cual lleva a las siguientes preguntas:

- ¿Alguna de estas variables podría explicar por sí sola la posición de cada equipo?
- ¿Existen variables extracancha que tengan un impacto significativo?
- ¿Participar en competencias europeas impacta en el rendimiento de la liga local?
- ¿Existe algún estilo de juego que influya en la posición de cada equipo (ofensivo como el Manchester City o defensivo como el Brentford)?

Para tratar de resolver estas preguntas se explorarán los datos para encontrar relaciones entre las variables dependientes (Posición en el ranking, clasificación a Champions League o salvación del descenso, según el modelo) y las variables independientes (goles, tiros, asistencia al estadio, transferencias, entre otras). Se comenzará con un análisis de tiros y goles, seguido de un análisis de correlación, para identificar posibles variables predictivas a través de los ditintos modelos.

Distribución de tiros y goles

A continuación se presentan los histogramas de Tiros a Gol, Goles a favor y su división si los equipos pertenecen al Big 6 [1] o si son recién ascendidos

[1] El Big 6 es un grupo de equipos considerados como los más relevantes de la liga en términos de historia, títulos y poder económico. Estos equipos son Arsenal, Chelsea, Liverpool, Manchester City, Manchester United y Tottenham Hotspur

Figura 4.2. Tiros a gol

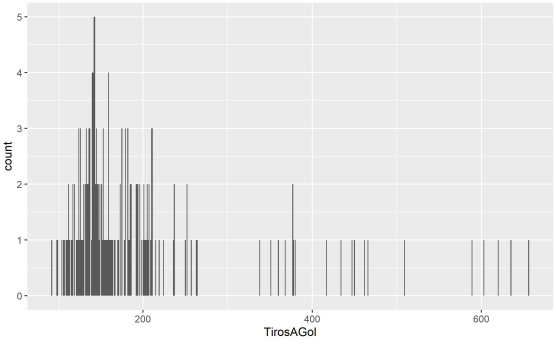

Figura 4.3. Goles a favor

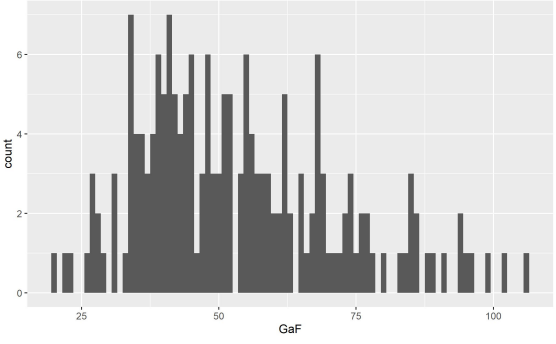

Figura 4.4. Diferencia de goles

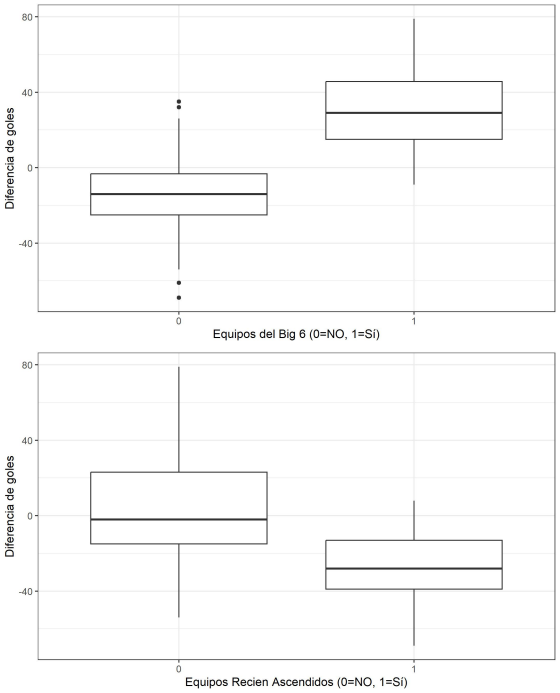

Se puede observar una concentración de tiros a gol entre 100 y 200 por temporada, Goles esperados entre 36 y 54 y Goles a Favor entre 35 y 62. Lo que podría decirnos que equipos fuera de estos rango puedan estar en posiciones muy altas o muy bajas. Asímismo, los equipos del Big 6 muestran una diferencia de goles muy superior al resto de la liga, mientras que los recien ascendidos tienden a tener una diferencia mucho menor. Lo que podría indicar que pertenecer a estos grupos podría predisponer el rendimiento durante la temporada.

Figura 4.5. Correlación

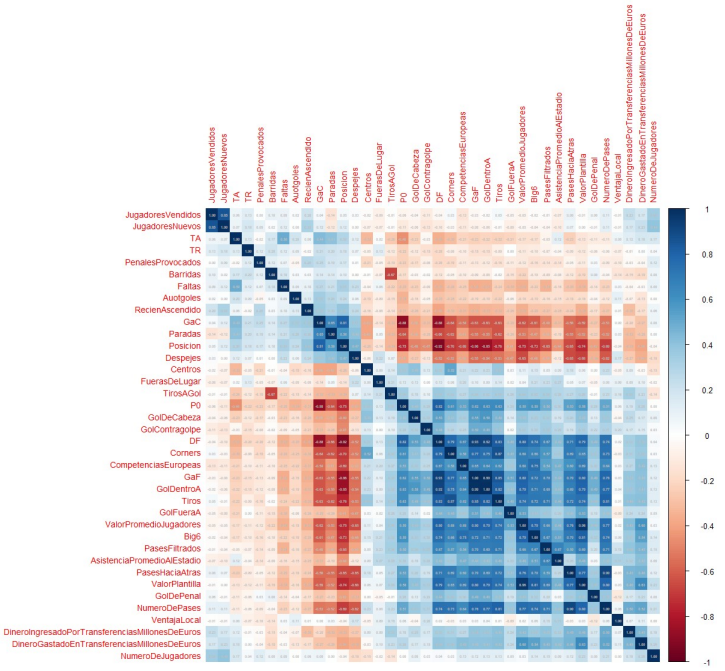

Se pueden observar 2 grupos altamente correlacionados: 1.Variables relacionadas con goles anotados con variables relacionadas con cantidad de pases, asistencia al estadio y valor de la plantilla; 2. Variables relacionadas con goles recibidos con goles, pases y valor de plantilla.

Por este motivo, se explorarán variables relacionadas con goles, tiros, asistencia al estadio y valor de plantilla como paso previo a los modelos.

Se observará la relación entre la posición con el valor de los jugadores

4.1.2. Características extra cancha

Figura 4.6. Relación entre valor promedio (millones de dólares estadounidenses) de jugadores y posición en la tabla

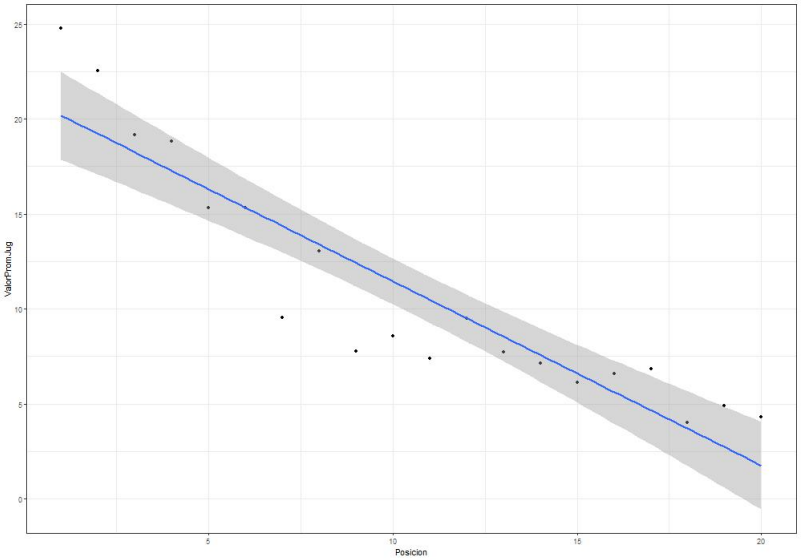

Al hacer un par de cálculos extras para obtener el valor promedio de los jugadores de los equipos dependiendo de su posición, se observa una clara relación entre un valor alto y una mejor posición en la tabla para los primeros 6 lugares, sin embargo de media tabla hacia abajo los valores promedio son similares, lo que indica que tener jugadores de valor alto no asegura la permanencia en la primera división

4.2. Regresión Lineal

Como ejercicio, se realizarán dos regresiones lineales para entender qué variables pueden influir más en la posición final. Como primer ejercicio, el primer modelo podría estimar la posición de la siguiente manera:

$$Posición = 10.5035 - .187089 * DiferenciaGoles \tag{4.1}$$

Esto indica que la posición en la tabla se ve negativamente relacionada con la diferencia de goles; es decir por cada gol neto, la posición mejora en .187089 lugares.

Este modelo mostró un nivel alto de significancia; sin embargo tiene algunas limitantes; ya que asume que las posiciones son continuas y no enteras.

Como ejercicio adicional, se hará una regresión lineal múltiple y se hará uso del criterio de Akaike para determinar el modelo que utilice la menor cantidad de variables con la mayor significancia.

Al analizar los modelos finales después de la selección, el modelo que utilizó el criterio de AIC arrojó 5 variables como las más significativas: Goles a Favor, Goles en Contra, Goles de contragolpe, Centros y Participación en competencias europeas. El modelo fue el siguiente:

$$\begin{aligned} Posición = 7.382702 - 0.148137 * GaF \\ +0.181642 * GaC - 0.172585 * GolContragolpe \\ +0.003628 * Centros - 1.727391 * CompetenciasEuropeas \end{aligned} \tag{4.2}$$

Este modelo indica que por cada gol a favor, la posición mejora en .1481 lugares; por el contrario, un gol en contra castiga más la posición y la baja en .1816 unidades. Los goles de contragolpe mejoran en .1725

unidades la posición, lo que podría beneficiar a equipos que recuperan el balón en zonas bajas y se despliegan rápidamente. Asimismo, el modelo arroja que la posición empeora en .0036 lugares por cada centro lanzado, lo cual a primer vistazo indica que este tipo de ataque no es tan eficiente. Finalmente, el modelo indica que si el equipo está participando en competencias europeas (Quedaron en el top 6 en la temporada anterior o ganaron la FA Cup o la Carabao Cup), su posición se beneficia en 2 unidades. Lo que indica que si un equipo tuvo buen rendimiento en un año, tiende a hacerlo bien al siguiente.

Ahora, este modelo sigue teniendo varias limitaciones ya que arroja resultados continuos que podrían salir del dominio. Por este motivo, se usará el modelo de regresión ordinal, el cuál arrojará la probabilidad de que cada equipo quede en cada posición de la tabla.

4.3. Regresión Ordinal

Para comparar este modelo con el de regresión múltiple se utilizaron las mismas variables para predecir la posición de la tabla: Goles a Favor, Goles en Contra, Goles de contragolpe, Centros y Participación en competencias europeas. El modelo fue el siguiente:

$$logit(P(Posición1)) = -10.26 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.3}$$

$$logit(P(Posición2)) = -7.17 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.4}$$

$$logit(P(Posición3)) = -5.19 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.5}$$

$$logit(P(Posición4)) = -3.69 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.6}$$

$$logit(P(Posición5)) = -2.36 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.7}$$

$$logit(P(Posición6)) = -1.21 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.8}$$

$$logit(P(Posición7)) = -0.06 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.9}$$

$$logit(P(Posición8)) = 1.06 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.10}$$

$$logit(P(Posición9)) = 2.03 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.11}$$

$$logit(P(Posición10)) = 2.82 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.12}$$

$$logit(P(Posición11)) = 3.56 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.13}$$

$$logit(P(Posición12)) = 4.29 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.14}$$

$$logit(P(Posición13)) = 4.99 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.15}$$

$$logit(P(Posición14)) = 5.67 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.16}$$

$$logit(P(Posición15)) = 6.34 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.17}$$

$$logit(P(Posición16)) = 7.05 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.18}$$

$$logit(P(Posición17)) = 7.29 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.19}$$

$$logit(P(Posición18)) = 9.07 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.20}$$

$$logit(P(Posición19)) = 10.80 - 0.18 * GaF + 0.19 * GaC$$
$$-0.11 * GolContragolpe + 0.003 * Centros - 1.07 * CompetenciasEuropeas \tag{4.21}$$

Al observar los coeficientes del modelo de regresión ordinal, se pueden identificar las variables con mayor influencia en la posición final de cada equipo. En primer lugar, los Goles a Favor presentan un coeficiente de $\hat{\beta} = -0.18$, lo que indica que por cada gol adicional anotado, el momio acumulado de quedar en una posición igual o peor se reduce en un factor de $e^{0.18} \approx 1.20$; es decir, anotar más goles mejora consistentemente la posición en la tabla. De manera análoga, los Goles en Contra presentan un coeficiente de $\hat{\beta} = 0.19$, lo que implica que cada gol recibido incrementa el momio de terminar en una posición peor en un factor de $e^{0.19} \approx 1.21$. Es interesante notar que el coeficiente de los Goles en Contra es ligeramente mayor en valor absoluto que el de los Goles a Favor, lo que sugiere que la solidez defensiva tiene un peso marginalmente superior al poder ofensivo en la determinación de la posición final. Por su parte, los Goles de Contragolpe presentan un coeficiente de $\hat{\beta} = -0.11$, confirmando que este estilo de juego tiene un efecto positivo en la clasificación, lo cual es consistente con el rendimiento histórico de equipos que priorizan la organización defensiva y la transición rápida al ataque. En cuanto a los Centros, si bien el coeficiente por unidad es pequeño ($\hat{\beta} = 0.003$), el efecto acumulado a lo largo de una temporada es relevante: un equipo

que lanza 100 centros adicionales multiplica su momio de terminar en una posición peor por un factor de $e^{0.3} \approx 1.35$, lo que indica que atacar predominantemente por las bandas no representa una estrategia eficiente en la Premier League. Finalmente, la Participación en Competencias Europeas es la variable con mayor magnitud en el modelo, con un coeficiente de $\hat{\beta} = -1.07$ que equivale a casi triplicar ($e^{1.07} \approx 2.92$) los momios de quedar bien posicionado. Esto se explica porque dicha variable es un proxy directo del rendimiento en la temporada anterior, reflejando que los equipos con buen desempeño reciente tienden a mantener esa tendencia en el siguiente año. Es importante recalcar que dado que la variable dependiente es la posición en el ranking (donde 1 es mejor que 20), un coeficiente negativo significa mejora en la posición.

Cuadro 4.1. Coeficientes del modelo de regresión ordinal

Variable	$\hat{\beta}$	$e^{\lvert\hat{\beta}\rvert}$	**Efecto acumulado**	**Dirección**
Goles a Favor	−0,18	1,20	+10 goles: ×6,05	Mejora
Goles en Contra	0,19	1,21	+10 goles: ×6,59	Empeora
Goles de Contragolpe	−0,11	1,12	+5 goles: ×1,73	Mejora
Centros	0,003	1,00	+100 centros: ×1,35	Empeora
Comp. Europeas	−1,07	2,92	Variable dummy	Mejora

Nota: Los coeficientes negativos indican mejora en la posición de la tabla (menor valor = mejor posición). $e^{\lvert\hat{\beta}\rvert}$ representa el cambio multiplicativo en el momio acumulado por unidad de la variable.

Al evaluar el modelo se notó algo interesante, el Leicester City del 2016 que logró la hazaña de ser campeón, bajo este modelo solo tendría 0.002 % de probabilidad de quedar en primer lugar, mientras que era más factible que terminara en cuarto lugar (34.87 %). Aunque estadísticamente se esperaba un resultado muy distinto, el Leicester

logró una de las mayores hazañas de la historia del deporte.

Para comparar los resultados de los modelos, se estimó la precisión de los modelos lineales y ordinales de tres maneras:

- **Posición exacta**: Precisión exacta de la predicción del modelo lineal u ordinal (Para el modelo lineal se redondea la estimación y para el ordinal se selecciona la posición con mayor probabilidad)
- **Posición** ± 1: Precisión con margen de error de 1 posición
- **Posición** ± 2: Precisión con margen de error de 2 posiciones

Además, el modelo ordinal se estresó para medir la posición en situaciones "normales", es decir, omitiendo las temporadas 19-20 y 20-21 debido a la pandemia. Los resultados fueron los siguientes:

Cuadro 4.2. Precisión de los modelos lineales y ordinales

Modelo	Posición exacta	Posición ± 1	Posición ± 2
Regresión Lineal	0.19	0.58	0.65
Regresión Ordinal	0.35	0.71	0.88
Regresión Ordinal (sin pandemia)	0.35	0.65	0.90

Si bien la regresión lineal estuvo descartada desde un inicio al no cumplir los supuestos, los resultados muestran una mayor precisión del modelo ordinal. La precisión exacta es de 35 % y en otros contextos puede parecer baja; sin embargo, si la comparamos con la probabilidad aleatoria de escoger la posición final, que es de 1 en 20 (5 %), se tienen 7 veces mayor probabilidad de obtener la posición exacta.

4.4. Discriminación de dos poblaciones

Ahora, existen dos grupos de puestos en la tabla en el fútbol inglés. El top 4 es de suma importancia ya que da acceso a la UEFA Champions League. Además de ser un torneo internacional de renombre, da exposición mundial y genera ingresos adicionales y superiores al club. Asimismo, los últimos 3 lugares de la tabla son aquellos que representan el descenso, lo que genera un impacto en la imagen, moral y economía del club. Por estas razones, se harán modelos para tratar de predecir si un equipo podrá quedar en el top 4 o si podrá salvarse del descenso. En primer término se usarán las regresiones logísticas de Ridge y Lasso. En segundo término, se usará el método de discriminación lineal y cuadrática.

Logit

La Regresión Logística Simple es un método de regresión que permite estimar la probabilidad de una variable cualitativa binaria en función de una variable cuantitativa. Una de las principales aplicaciones de la regresión logística es la de clasificación binaria, en la que las observaciones se clasifican en un grupo u otro dependiendo del valor que tome la variable empleada como predictor. En particular, para este trabajo se tratará de predecir si un equipo clasificará a Champions League y si se salvará del descenso. Como se mencionó previamente, se hará uso de dos subtipos de regresión logística: Lasso y Ridge.

Para cada lambda se tendrá una solución distinta, ya que esta controla el tamaño de los coeficientes. Por lo tanto, se utilizará validación cruzada para obtener la lambda que obtenga el mínimo error cuadrático medio.

Discriminantes

Además de la regresión logística, se usó un análisis discriminante para comparar diferentes métodos en los que se separan poblaciones. Se usaron discriminantes lineales y cuadráticos para tener una visión más completa sobre los resultados.

4.4.1. Champions League

Se utilizarán las variables GaF, GaC, GolContragolpe y CompetenciasEuropeas para realizar los siguientes modelos y, para medir la eficacia de los siguientes modelos, se utilizará el 70 % de la población como entrenamiento y un 30 % de prueba

Cuadro 4.3. Champions League: Precisión de los modelos de separación de poblaciones

Modelo	Precisión	Error Tipo 1	Error Tipo 2
Logit Lasso	0.16	0.83	0.00
Logit Ridge	0.14	0.86	0.00
Discriminante Lineal	0.94	0.04	0.02
Discriminante Cuadrático	0.90	0.06	0.04

Al observar los resultados, el modelo con mayor eficiencia es el discriminate lineal con un 94.4 %. Este modelo podría apoyar a equipos que aspiran a clasificar a Champions para encontrar objetivos de Goles a Favor, Goles en Contra, Centros y Goles de contragolpe para mejorar sus aspiraciones.

4.4.2. Descenso

Se utilizarán las mismas variables y porcentajes de prueba que en el ejercicio de clasificación a Champions League

Cuadro 4.4. Descenso: Precisión de los modelos de separación de poblaciones

Modelo	Precisión	Error Tipo 1	Error Tipo 2
Logit Lasso	0.83	0.16	0.00
Logit Ridge	0.83	0.16	0.00
Discriminante Lineal	0.89	0.09	0.02
Discriminante Cuadrático	0.89	0.09	0.02

Al observar los resultados, los modelos con mayor eficiencia son los discriminantes lineales y cuadráticos con un 89 % de precisión. Estos modelos podrían apoyar a equipos que aspiran a salvarse del descenso para establecer objetivos.

Conclusiones

Las variables que demuestran un mayor impacto en la estimación de los resultados de un equipo son los Goles a Favor, los Goles en Contra, Goles de Contragolpe, Centros y la Participación en Competencias Europeas. Al observar los coeficientes en los modelos lineales y ordinales se puede llegar a las siguientes conclusiones:

- **Goles a Favor**: Al tener un relación importante con los partidos ganados, mientras más goles anotados tenga un equipo, su posicón en la tabla mejora.

- **Goles en Contra**: De manera totalmente contraria a los Goles a Favor, mientras más goles encajados tenga un equipo, su posicón en la tabla empeora.

- **Goles de Contragolpe**: En los modelos, existe una relación positiva entre los goles por contragolpe y la posición en la tabla. Es decir, los equipos que juegan al contragolpe suelen beneficiarse. Este tipo de equipos suele jugar defensivamente, recuperar el balón y desplegarse rápidamente hacia adelante. Por lo que equipos que busquen mejorar su posición o evitar el descenso podrían optar por estilos de juego defensivos, cediendo la pelota al rival y esperándolos en campo propio para robar el

balón y atacar mientras el rival se encuentra desordenado defensivamente.

- **Centros**: La cantidad de centros tiene un impacto negativo en la posición de los equipos en la tabla, esto quiere decir que equipos que suelen atacar por las bandas y mandar pases elevados al área suelen tener un rendimiento menor. Si bien, los centros se asocian a un estilo de juego ofensivo, este tipo de pases tiene una probabildiad baja de éxito, pues pueden ser robados fácilmente o llegar de manera incómoda a su destinatario. Además, el centro fallido se puede asociar con un contragolpe del equipo contrario.

- **Participación en Competencias Europeas**: La participación en competencias europeas es un indicador directo del rendimiento en el año previo, pues para jugar competencias europeas, los equipos debieron de finalizar la temporada previa en la parte superior de la tabla. Por lo que si el rendimiento del equipo es bueno en un año, es esperado que su rendimiento al siguiente año siga esa tendencia.

Estos resultados pueden explicar porqué los equipos de Guardiola que suelen mantener la posesión del balón y evitar pases riesgosos suelen tener resultados positivos, o porqué en el pasado entrenadores como Mourinho o Tuchel tuvieron éxito con el Chelsea al mantener un estilo de juego de contragolpe. También es interesante ver como en años recientes, el Brentford de Thomas Frank logró mantener la categoría con una plantilla modesta al adaptarse al juego del rival y utilizar el contragolpe o la posesión del balón según se desenvolvieran los juegos.

Hablando de los modelos estadísticos, el modelo ordinal mostró ser una herramienta útil para identificar en qué posición podría quedar cada equipo según su rendimiento, incrementando la probabilidad de

encontrar la posición exacta de 5 % (en un caso aleatorio) a 35 %, además de una precisión de 71 % al estimar la posición con un margen de error de 1 lugar y de 88 % con un margen de error de 2 lugares. Por lo que, se identifican 2 usos principales:

- **Uso deportivo**: A lo largo de la temporada, cada equipo podría estimar sus resultados finales y así poder planear las ventanas de transferencias o el estilo de juego por el que pueden optar
- **Apuestas**: Se puede apalancar el modelo para estimar la posición exacta al final de la temporada y realizar apuestas en caso de que la casa de apuestas arroje un precio mejor al compararlo con la probabilidad del modelo

Asimismo, si se habla de los modelos de discriminación de poblaciones, tanto en la clasificación a Champions League o la salvación del Descenso, el Discriminante Lineal mostró el mejor rendimiento, teniendo una precisión superior al 89 %. Asimismo, el Discriminante Cuadrático tuvo resultados cercanos. Por lo que los equipos que buscan salvarse del descenso o entrar a competencias europeas podrían apalancar el modelo propuesto. Asimismo, el ejercicio podría llevarse a otras ligas con datos disponibles como la española, alemana o italiana, o a ligas con mayor variabilidad año tras año como la mexicana.

Apéndice A

Código R

Referencias

Montgomery, D. C., Peck, E. A., Vining, G. G. 2012. ≪Introduction to Linear Regression Analysis≫ (5th ed.). Wiley.

Kutner, M. H., Nachtsheim, C. J., Neter, J. 2004. ≪Applied Linear Statistical Models≫ (5th ed.). McGraw-Hill/Irwin.

Johnson, V. E., Albert, J. H. 1999 ≪Ordinal Data Modeling≫ (1st ed.). Springer.

Johnson, R, A., Wichern D. W. 2014. ≪Applied Multivariate Statistical Analysis≫ (6th ed.). Pearson Education Limited

Tibshirani, R. 1996. ≪Regression Shrinkage and Selection Via the Lasso≫, *Journal of the Royal Statistical Society: Series B (Methodological)* 58 (1): 267-288

Hoerl, A. E., Kennard, R. W. 1970. ≪Ridge Regression: Biased Estimation for Nonorthogonal Problems≫. *Technometrics*, 12(1), 55–67

Hastie, T., Tibshirani, R., Friedman, J. 2009. ≪The Elements of Statistical Learning≫ (2nd ed.). Springer.

La regresión ordinal y discriminantes
poblacionales como métodos de
predicción del rendimiento en la Premier League
escrito por Ricardo Odilón Méndez Bribiesca,
se terminó de imprimir el XXXX de 2025
en XXXXXXXX.
XXXXX XXXx, colonia XXXXX,
Ciudad de México.