

INSTITUTO TECNOLÓGICO AUTÓNOMO DE MÉXICO



**La regresión ordinal y discriminantes
poblacionales como métodos de
predicción del rendimiento en la
Premier League**

TESIS

QUE PARA OBTENER EL TÍTULO DE

LICENCIADO EN ACTUARÍA /
MATEMÁTICAS APLICADAS

PRESENTA

RICARDO ODILÓN MÉNDEZ BRIBIESCA

ASESORA

JORGE FRANCISCO DE LA VEGA GÓNGORA

CIUDAD DE MÉXICO

2026

«Con fundamento en los artículos 21 y 27 de la Ley Federal del Derecho de Autor y como titular de los derechos moral y patrimonial de la obra titulada **“La regresión ordinal y discriminantes poblacionales como métodos de predicción del rendimiento en la Premier League”**, otorgo de manera gratuita y permanente al Instituto Tecnológico Autónomo de México y a la Biblioteca Raúl Baillères Jr., la autorización para que fijen la obra en cualquier medio, incluido el electrónico, y la divulguen entre sus usuarios, profesores, estudiantes o terceras personas, sin que pueda percibir por tal divulgación una contraprestación.»

FECHA

RICARDO ODILÓN MÉNDEZ BRIBIESCA

*A mis padres,
por su esfuerzo.*

Agradecimientos

El siguiente trabajo está dedicado a mi familia, amigos, profesores y compañeros que me han acompañado a lo largo de mi vida y que me han permitido desarrollar dos de mis mayores gustos: fútbol y matemáticas.

A mi mamá por apoyarme a lo largo de mi vida y a mi papá por escucharme y ver tantos partidos de fútbol conmigo. A mi hermana Bere por regalarme mi primera playera del Tottenham y acercarme a este gran equipo. A mi hermana Sofía por apoyarme en momentos estresantes de la carrera. A mis cuñados Rafa y Daniel por las pláticas de la liga inglesa y a mi sobrino Rafita por traer alegría a la familia. A Barbie por motivarme y darme consejos para LaTeX.

A Rodri por ser de mis mejores amigos y darme tan buenas ideas para este trabajo. A Sebas por las risas durante la pandemia y la carrera. A todos los grandes amigos que fui haciendo durante el camino: Caraveo, Regina, Polo, Dodo, Sou, Sop, Ale, Parente, Lomelí y Monse. A Durán por corretearme por avances.

A todos los profesores y profesoras que tuve el gusto de conocer durante mi tiempo en el ITAM.

Finalmente, a Jorge Francisco de la Vega Góngora por su apoyo y dedicación para poder desarrollar este trabajo.

Resumen

La presente tesis consiste en una investigación en la cual busco estudiar potenciales factores que influyen en el rendimiento de un equipo de la primera división inglesa de fútbol. Estos factores incluirán variables deportivas como goles, pases, intercepciones, lesiones y no deportivas como traspasos, inversión financiera, asistencia al estadio, participación en competiciones europeas, etc. Estas características y variables permitirán llevar a cabo simulaciones realistas de temporadas completas y determinar 3 cosas: en primer lugar, el ranking de cada equipo; en segundo lugar, si cada equipo se clasifica a la UEFA Champions League y en tercer lugar, si cada equipo descenderá a la segunda división.

La información utilizada incluye bases de datos desde la temporada 2015-2016 hasta la temporada 2023-2024 de todos los equipos que participaron en la Premier League durante esos años. Se exploraron los datos para entender qué variables podrían tener mayor relevancia y así abordar el problema con una variedad de modelos con la finalidad de predecir la posición de cada equipo basada en las variables que resultaron más significativas.

La Premier League fue la competencia elegida para este trabajo por ser de las ligas más competitivas y de las más vistosas de fútbol profesional. Asimismo, fue interesante consolidar una base de datos que contiene datos deportivos y extradeportivos, ya que no se pudo encontrar una base de datos única que incluyera todas las variables consideradas en la investigación. En el futuro, podría ser interesante extender un análisis similar a otro tipo de ligas de fútbol más inciertas, como la Liga MX, y tratar de encontrar un modelo adecuado que, como aficionado, es difícil de imaginar.

Índice general

Introducción	1
1. Contexto	3
1.1. El fútbol	3
1.2. La liga inglesa	4
1.3. Planteamiento del problema a resolver	5
2. Metodología	7
2.1. Regresión lineal múltiple	7
2.1.1. Modelo	7
2.1.2. Selección de variables	8
2.1.3. Estimación	9
2.1.4. Inferencia	11
2.1.5. Validación	12
2.1.6. Distancias de Cook	13
2.1.7. Normalidad de los residuales	14
2.1.8. Homoscedasticidad e independencia de los residuales	15
2.1.9. Métodos de penalización: Lasso, Ridge y Elastic Net	16
2.2. Regresión Logit	18

2.2.1.	Modelo Logit	18
2.2.2.	Regresión Logit con penalización Lasso	19
2.2.3.	Regresión Logit con penalización Ridge	20
2.2.4.	Validación y diagnósticos en regresión logística	20
2.3.	Regresión ordinal	23
2.3.1.	Modelo	23
2.3.2.	Estimación	25
2.3.3.	Inferencia	27
2.3.4.	Validación	28
2.3.5.	Verificación del supuesto de proporcionalidad	30
2.3.6.	Diagnósticos en regresión ordinal	31
2.3.7.	Bondad de ajuste y evaluación del modelo	32
2.3.8.	Métodos de penalización en regresión ordinal	34
2.4.	Simulación de partidos: Modelo de Poisson	35
2.4.1.	Modelo	35
2.5.	Análisis discriminante	39
2.5.1.	Análisis discriminante lineal (LDA)	40
2.5.2.	Análisis discriminante cuadrático (QDA)	41
2.5.3.	Ventajas y desventajas de LDA y QDA	42
3.	Bases de datos y análisis exploratorio de datos	46
3.1.	Creación de base de datos	46
3.2.	Análisis exploratorio de datos	50
3.2.1.	Desempeño en el campo de juego	50
3.2.2.	Características extra cancha	55
4.	Análisis y modelos de la Premier League	56
4.1.	Regresión Lineal	56
4.2.	Regresión Ordinal	58
4.3.	Simulación de partidos: Modelo de Poisson	62

4.4. Discriminación de dos poblaciones	66
4.4.1. Champions League	67
4.4.2. Descenso	72
4.4.3. Importancia de variables en modelos de clasificación	76
5. Conclusiones	81
A. Código R	88
Referencias	90

Índice de cuadros

2.1. Frecuencias observadas de goles: local vs. visitante (2023-2024)	39
3.1. Desempeño en el campo de juego	47
3.2. Desempeño en el ranking	48
3.3. Características extra cancha	49
4.1. Parámetros de corte (α_j) del modelo de regresión ordinal	59
4.2. Coeficientes (β) comunes del modelo de regresión ordinal	59
4.3. Coeficientes del modelo de regresión ordinal	62
4.4. Precisión de los modelos lineales, ordinales y simulación	64
4.5. Comparación de posición real vs. predicha por modelo — Temporada 2023-2024	65
4.6. Champions League: Precisión de los modelos de separación de poblaciones	67
4.7. Predicción de clasificación a Champions League — Temporada 2023-2024	71
4.8. Descenso: Precisión de los modelos de separación de poblaciones	72
4.9. Predicción de descenso — Temporada 2023-2024	75

4.10. Importancia de variables - Modelos de clasificación	
Champions League	76
4.11. Importancia de variables - Modelos de clasificación Riesgo	
de Descenso	78
4.12. Ranking de importancia: Champions vs. Descenso . . .	79

Índice de figuras

3.1. Diferencia de goles (goles a favor menos goles en contra) promedio por la posición de la tabla	50
3.2. Tiros a gol	52
3.3. Goles a favor	52
3.4. Diferencia de goles	53
3.5. Correlación	54
3.6. Relación entre valor promedio (millones de dólares estadounidenses) de jugadores y posición en la tabla . .	55
4.1. Comparación de la posición simulada a través de una distribución Poisson y la posición real de la temporada 2023-2024	63

Introducción

Disertación

La motivación para realizar este trabajo es poder combinar mi afición por el fútbol inglés y mi gusto por la estadística, y así realizar un análisis que pueda determinar qué factores pueden influir en el rendimiento de un equipo durante una temporada futbolística. Se aplicarán métodos vistos durante las materias de la carrera para hacer un análisis exploratorio de datos, regresiones logit y discriminantes lineales y cuadráticos. Asimismo, se utilizará un método no visto como la regresión ordinal.

La Premier League es de las ligas de fútbol más populares en el mundo. Su método de clasificación para torneos internacionales, para ascender/descender y, en general su competitividad, son los principales motivos por los que he decidido realizar este análisis y, así, entender mejor qué variables influyen en el rendimiento de cada equipo.

El trabajo consta de 5 capítulos: el primero contextualizará sobre el fútbol inglés, su método de clasificación y el problema a resolver; el segundo capítulo hablará de los métodos utilizados para crear los

modelos; el tercero hablará de la base de datos a utilizarse en el análisis, cómo se definirán las variables necesarias y se hará un análisis exploratorio de datos; en el capítulo 4, se realizan los modelos pertinentes y se comparan entre sí para entender su relevancia; finalmente, en el capítulo 5, se darán las conclusiones del análisis.

Objetivo

La meta principal del trabajo es, por una parte, entender qué variables deportivas y extradeportivas influyen en el rendimiento de cada equipo para estimar la probabilidad de que se dé cierto ranqueo de la tabla de posiciones, y, por otra parte, la probabilidad de que los equipos logren clasificarse a la UEFA Champions League o mantenerse en la primera división. Para esto, se usarán los datos de las ligas desde la temporada 2015/2016 hasta la temporada 2023/2024 y métodos de comparación entre modelos para seleccionar cuáles son las variables más relevantes.

Capítulo 1

Contexto

1.1. El fútbol

El fútbol es un deporte colectivo donde dos equipos de 11 jugadores se enfrentan y, mediante diferentes estrategias y planteamientos, tratan de meter gol en la portería del equipo rival. Los jugadores pueden usar cualquier parte del cuerpo, excepto los brazos y manos. Los once jugadores de cada equipo tienen funciones diferentes: los delanteros marcan goles, los mediocampistas recuperan el balón y crean estrategias de juego, los defensas protegen la portería y los porteros evitan los goles rivales. Los partidos duran 90 minutos, y el equipo que anote más goles gana el partido. El fútbol surgió en el siglo XIX en Inglaterra y se convirtió en el deporte más popular del mundo en el siglo XX.

La Federación Internacional de Asociaciones de Fútbol (FIFA), fundada en 1904, es el organismo regulador del fútbol mundial y actualmente agrupa a 211 federaciones nacionales. La FIFA es responsable de organizar las principales competiciones del fútbol a

nivel internacional, siendo la más importante la Copa del Mundo, que se disputa cada cuatro años desde 1930. Este torneo reúne a las selecciones nacionales más competitivas del mundo y se ha convertido en el evento deportivo más prestigioso a nivel global. La Copa del Mundo se caracteriza por ser una competición de gran magnitud e impacto, tanto económico como cultural, generando una euforia sin precedentes en los países participantes y en los aficionados alrededor del planeta.

La popularidad del fútbol a nivel mundial es innegable. Estudios recientes estiman que aproximadamente 4 mil millones de personas en el mundo son aficionadas al fútbol, lo que representa más del 50 % de la población global. Durante la Copa del Mundo, el interés se concentra de manera masiva en esta competición. Es importante notar que la final del Mundial 2026 fue vista por entre 1.8 y 2.2 mil millones de espectadores a través de televisión, demostrando la capacidad del fútbol de generar audiencias masivas y reunir a aficionados de todas partes del mundo. Este fenómeno global de afición por el fútbol es especialmente relevante en competiciones como la Premier League, cuya proyección internacional la convierte en una de las ligas de fútbol profesional más vistas y analizadas a nivel mundial.

1.2. La liga inglesa

La primera división inglesa, también conocida como *Premier League*, es la máxima categoría de clubes en Inglaterra. Fundada en 1992, se separó de la Football League para incrementar el nivel de juego. La liga consta de 20 equipos que se enfrentan entre todos de local y de visita, resultando en un total de $2\binom{20}{2} = 380$ partidos a lo largo del año. Cada partido puede resultar en victoria, empate o derrota para

cada equipo, lo que otorga 3 puntos, 1 punto o 0 puntos, respectivamente. Cada jornada, estos puntos se van acumulando y determinan un ranking u ordenamiento de los equipos. En caso de que haya empate en puntos, existen criterios de desempate como la diferencia de goles, los goles anotados, las tarjetas recibidas, entre otros. Los tres últimos equipos en el ranking descienden a la Championship (segunda división) y, usualmente, los cuatro primeros se clasifican a la UEFA Champions League, la competencia de clubes más prestigiosa a nivel mundial. La Premier League se caracteriza por ser de las más competitivas a nivel mundial. Equipos como el Arsenal, Chelsea, Liverpool, Manchester City, Manchester United y Tottenham (conocidos como el “Big 6”) luchan por el título y por las posiciones para clasificar a competencias europeas. Aunque en ocasiones, equipos fuera de este grupo, como el Leicester City en la temporada 2016-2017, logran clasificarse para torneos europeos e incluso ganar el campeonato.

1.3. Planteamiento del problema a resolver

A lo largo de cada temporada, se registran estadísticas y datos de cada encuentro (goles, tiros, pases, faltas, entre otras) y extracancha (gasto en transferencia, asistencia al estadio, entre otras) que podrían relacionarse o asociarse con la posición de cada equipo en el ranking al final de la temporada. Es por esto que en este trabajo se considerarán distintos métodos para predecir la variable dependiente, que se define como la posición en el ranking o la clasificación a la Champions League, a través de variables independientes o predictores (pases, goles, faltas, entre otras). Casas de apuestas y trabajos de investigación, como *Statistical Analysis of the Effectiveness of the FIFA World Rankings*

(*McHale & Davies, 2007*) o *Competitive Balance in National European Soccer Competitions* (*Haan, 2007*) han utilizado este tipo de información para desarrollar modelos de predicción y discriminación del comportamiento de los equipos para entender mejor este deporte.

Capítulo 2

Metodología

2.1. Regresión lineal múltiple

2.1.1. Modelo

La regresión lineal múltiple estudia la construcción de modelos para explicar o representar la dependencia lineal entre una variable dependiente o respuesta (y) y una combinación lineal de variables independientes o predictoras (x). Es decir, se utilizará el modelo de regresión lineal múltiple, como un acercamiento previo, para explicar y predecir la variable “Score” a partir de las variables predictivas (45 características observadas).

El modelo de regresión lineal múltiple se puede expresar de la siguiente forma:

$$Y = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + \dots + \beta_k X_{ik} + \varepsilon, \quad (2.1)$$

Donde:

- Y es la variable dependiente (el resultado a predecir)
- $X_{i1}, X_{i2}, \dots, X_{ik}$ son las variables independientes (factores que potencialmente se relacionan con Y)
- β_0 es la ordenada al origen (la constante que representa el valor de Y cuando todas las X_{ik} son cero)
- $\beta_1, \beta_2, \dots, \beta_k$ son los coeficientes de regresión que indican la magnitud y dirección de la influencia de cada X_{ik} sobre Y
- ε es el término de error, que captura la variabilidad en Y que no puede ser explicada por las variables independientes

Supuestos:

- Linealidad: La relación entre las variables dependiente e independientes es lineal ($y = x\beta + \epsilon$)
- Independencia: Las observaciones son independientes entre sí ($y_1, \dots, y_n$ es una muestra independiente)
- Homocedasticidad: Los errores tienen varianza constante para todos los niveles de las variables independientes ($Var(\epsilon) = \sigma^2$)
- Normalidad de los residuos: Los errores del modelo siguen una distribución normal $\epsilon \sim N(0, \sigma^2 I_n)$, donde I_n es una matriz identidad de dimensión $n \times n$.

2.1.2. Selección de variables

Selección de variables

Se utilizará el método BIC (Criterio de Información Bayesiano) para seleccionar el modelo que mejor balance tenga entre cantidad de variables y ajuste del modelo. La métrica BIC expresa como:

$$\text{BIC} = k \ln(n) - 2 \ln(L) \quad (2.2)$$

Donde

- k es el número de parámetros estimados en el modelo
- n es el número de observaciones en la muestra
- $\ln(L)$ es el logaritmo de la verosimilitud del modelo, que mide qué tan bien ajusta los datos observados

Bajo este criterio, conforme BIC sea menor, se ajusta mejor el modelo. Es importante notar que BIC penaliza más fuertemente la inclusión de variables adicionales en comparación con AIC, ya que el término de penalización depende del tamaño de la muestra ($k \ln(n)$), lo que favorece modelos más parsimoniosos, especialmente cuando se cuenta con muestras grandes.

2.1.3. Estimación

Para estimar el vector de coeficientes $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_k)^\top$, se utiliza el método de *Mínimos Cuadrados Ordinarios* (MCO), que consiste en encontrar los valores de $\boldsymbol{\beta}$ que minimicen la suma de cuadrados de los residuos. En notación matricial, el modelo se puede expresar como:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad (2.3)$$

Donde:

- $\mathbf{y} \in \mathbb{R}^n$ es el vector de respuestas
- $\mathbf{X} \in \mathbb{R}^{n \times (k+1)}$ es la matriz de diseño, cuya primera columna es un vector de unos

- $\boldsymbol{\beta} \in \mathbb{R}^{k+1}$ es el vector de parámetros a estimar
- $\boldsymbol{\varepsilon} \in \mathbb{R}^n$ es el vector de errores, con $\mathbb{E}[\boldsymbol{\varepsilon}] = \mathbf{0}$ y $\text{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}$

La función que se busca minimizar es la suma de cuadrados de los residuos:

$$S(\boldsymbol{\beta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) = \mathbf{y}^\top \mathbf{y} - 2\boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{y} + \boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{X} \boldsymbol{\beta}. \quad (2.4)$$

Para obtener el mínimo, se calcula el gradiente de $S(\boldsymbol{\beta})$ con respecto a $\boldsymbol{\beta}$ y se iguala a cero:

$$\frac{\partial S}{\partial \boldsymbol{\beta}} = -2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X} \boldsymbol{\beta} = \mathbf{0}. \quad (2.5)$$

Esto conduce a las llamadas *ecuaciones normales*:

$$\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}. \quad (2.6)$$

Siempre que las columnas de $\mathbf{X}$ sean linealmente independientes, la matriz $\mathbf{X}^\top \mathbf{X}$ es invertible y la solución única es:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}. \quad (2.7)$$

Es importante notar que bajo los supuestos del modelo, este estimador es *insesgado*, es decir, $\mathbb{E}[\hat{\boldsymbol{\beta}}] = \boldsymbol{\beta}$, y su matriz de covarianzas es:

$$\text{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}. \quad (2.8)$$

Adicionalmente, el *Teorema de Gauss-Markov* garantiza que $\hat{\boldsymbol{\beta}}$ es el Mejor Estimador Lineal Insesgado (MELI): entre todos los estimadores lineales insesgados de $\boldsymbol{\beta}$, el estimador MCO tiene la menor varianza posible.

Dado que la varianza del error σ^2 también es desconocida, se estima a partir de los residuos del modelo $\hat{\boldsymbol{\varepsilon}} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}$ de la siguiente manera:

$$\hat{\sigma}^2 = \frac{\hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}}}{n - k - 1} = \frac{SCE}{n - k - 1}, \quad (2.9)$$

Donde $SCE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$ es la Suma de Cuadrados del Error y $n - k - 1$ son los grados de libertad del error. Este estimador también es insesgado, es decir, $\mathbb{E}[\hat{\sigma}^2] = \sigma^2$.

2.1.4. Inferencia

Una vez obtenidos los estimadores, el siguiente paso es determinar si los coeficientes del modelo son estadísticamente significativos. Para esto, se asume adicionalmente que $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$, lo que implica que:

$$\hat{\boldsymbol{\beta}} \sim \mathcal{N}\left(\boldsymbol{\beta}, \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}\right). \quad (2.10)$$

Prueba t para coeficientes individuales: Para evaluar si una variable independiente tiene un efecto significativo sobre Y , se plantea la hipótesis:

$$H_0 : \beta_j = 0 \quad \text{vs.} \quad H_1 : \beta_j \neq 0. \quad (2.11)$$

El estadístico de prueba se expresa de la siguiente manera:

$$t_j = \frac{\hat{\beta}_j}{\hat{\sigma} \sqrt{c_{jj}}}, \quad (2.12)$$

Donde c_{jj} es el j -ésimo elemento diagonal de $(\mathbf{X}^\top \mathbf{X})^{-1}$. Bajo H_0 , este estadístico sigue una distribución t_{n-k-1} , por lo que se rechaza H_0 si $|t_j| > t_{\alpha/2, n-k-1}$. De manera equivalente, se puede construir un intervalo de confianza del $(1 - \alpha) \times 100\%$ para β_j :

$$\hat{\beta}_j \pm t_{\alpha/2, n-k-1} \hat{\sigma} \sqrt{c_{jj}}. \quad (2.13)$$

Prueba F de significancia global: Adicionalmente, se puede evaluar si el modelo en su conjunto tiene poder explicativo a través de la prueba F , que plantea:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0 \quad \text{vs.} \quad H_1 : \exists j \text{ tal que } \beta_j \neq 0. \quad (2.14)$$

Para esto, se descompone la variabilidad total de $\mathbf{y}$ como $SCT = SCR + SCE$, donde:

$$SCR = \hat{\boldsymbol{\beta}}^\top \mathbf{X}^\top \mathbf{y} - n\bar{y}^2 \quad (\text{Suma de Cuadrados de la Regresión}), \quad (2.15)$$

$$SCE = \mathbf{y}^\top \mathbf{y} - \hat{\boldsymbol{\beta}}^\top \mathbf{X}^\top \mathbf{y} \quad (\text{Suma de Cuadrados del Error}). \quad (2.16)$$

El estadístico F se obtiene como el cociente entre los cuadrados medios de la regresión y del error:

$$F = \frac{SCR/k}{SCE/(n-k-1)}. \quad (2.17)$$

Bajo H_0 y el supuesto de normalidad, $F \sim F_{k, n-k-1}$, por lo que se rechaza H_0 si $F > F_{\alpha, k, n-k-1}$. Es importante notar que un valor F grande indica que el modelo explica una proporción relevante de la variabilidad de Y , lo que indica que al menos una de las variables independientes es útil para predecir la respuesta.

2.1.5. Validación

La validación del modelo se lleva a cabo en dos etapas: la verificación de los supuestos sobre los errores y la medición de la calidad del ajuste.

Coefficiente de determinación R^2 : Para medir qué tan bien se ajusta el modelo a los datos, se utiliza el coeficiente de determinación, que representa la proporción de la variabilidad total de $\mathbf{y}$ que es explicada por el modelo:

$$R^2 = \frac{SCR}{SCT} = 1 - \frac{SCE}{SCT}, \quad R^2 \in [0, 1]. \quad (2.18)$$

Sin embargo, R^2 aumenta mecánicamente con cada variable que se agrega al modelo, aunque ésta no aporte información real. Por este motivo, se utiliza el coeficiente de determinación ajustado, que penaliza la inclusión de variables innecesarias:

$$R_{\text{adj}}^2 = 1 - \frac{SCE/(n - k - 1)}{SCT/(n - 1)} = 1 - (1 - R^2) \frac{n - 1}{n - k - 1}. \quad (2.19)$$

Análisis de residuos: Los residuos $\hat{\varepsilon}_i = y_i - \hat{y}_i$ son la principal herramienta para verificar los supuestos del modelo. Para facilitar su análisis, se definen los *residuos estandarizados*:

$$r_i = \frac{\hat{\varepsilon}_i}{\hat{\sigma} \sqrt{1 - h_{ii}}}, \quad (2.20)$$

Donde h_{ii} es el i -ésimo elemento diagonal de la *matriz sombrero* $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$. Bajo los supuestos del modelo, $r_i \stackrel{\text{aprox.}}{\sim} \mathcal{N}(0, 1)$.

2.1.6. Distancias de Cook

La distancia de Cook es una medida que identifica observaciones influyentes en el modelo de regresión lineal. Una observación es considerada influyente si su eliminación causa cambios sustanciales en los coeficientes estimados del modelo. La distancia de Cook para la observación i se define como:

$$D_i = \frac{(y_i - \hat{y}_i)^2}{k \cdot \hat{\sigma}^2} \cdot \frac{h_{ii}}{1 - h_{ii}} \quad (2.21)$$

Donde:

- $y_i - \hat{y}_i$ es el residuo de la observación i
- k es el número de variables independientes
- $\hat{\sigma}^2$ es la estimación de la varianza del error
- h_{ii} es el i -ésimo elemento diagonal de la matriz sombrero $H = X(X'X)^{-1}X'$

Como regla general, se considera que una observación es influyente si $D_i > \frac{4}{n}$, donde n es el número de observaciones. Es importante identificar estas observaciones influyentes, ya que pueden distorsionar significativamente las estimaciones de los coeficientes del modelo y, consecuentemente, afectar la precisión de las predicciones.

2.1.7. Normalidad de los residuales

El supuesto de normalidad establece que los errores del modelo deben seguir una distribución normal. Para verificar este supuesto se pueden utilizar tanto pruebas visuales como pruebas estadísticas formales.

Pruebas visuales: El gráfico Q-Q (Quantile-Quantile) es una herramienta gráfica que compara los cuantiles de los residuos estandarizados con los cuantiles teóricos de una distribución normal estándar. Si los puntos se alinean aproximadamente sobre la línea de referencia de 45 grados, el supuesto de normalidad se sostiene.

Pruebas formales: La prueba de Shapiro-Wilk es una de las más utilizadas para evaluar normalidad. Esta prueba plantea:

$$H_0 : \text{los residuos siguen una distribución normal} \quad (2.22)$$

$$H_1 : \text{los residuos no siguen una distribución normal} \quad (2.23)$$

Si el p-valor de la prueba es mayor que el nivel de significancia $\alpha = 0,05$, no se rechaza H_0 y se concluye que los residuos provienen de una distribución normal. Es importante notar que ligeras desviaciones de la normalidad pueden ser tolerables cuando el tamaño de la muestra es grande, debido al Teorema del Límite Central.

2.1.8. Homoscedasticidad e independencia de los residuales

Homoscedasticidad: Este supuesto establece que la varianza de los errores es constante para todos los niveles de las variables independientes. Para verificarlo se pueden utilizar gráficas de residuos estandarizados contra valores predichos. Si los residuos se distribuyen de manera aleatoria sin patrones discernibles alrededor de cero, el supuesto de homoscedasticidad se sostiene.

Adicionalmente, la prueba de Breusch-Pagan puede utilizarse para contrastar formalmente este supuesto. Esta prueba plantea:

$$H_0 : \text{Var}(\varepsilon_i) = \sigma^2 \quad \text{vs.} \quad H_1 : \text{Var}(\varepsilon_i) \neq \sigma^2 \quad (2.24)$$

Si el p-valor es mayor que $\alpha = 0,05$, se concluye que existe homocedasticidad en los residuos.

Independencia: El supuesto de independencia establece que los residuos no están correlacionados entre sí. Para verificar la ausencia de autocorrelación se utiliza la prueba de Durbin-Watson, cuyo estadístico se define como:

$$DW = \frac{\sum_{i=2}^n (\hat{\varepsilon}_i - \hat{\varepsilon}_{i-1})^2}{\sum_{i=1}^n \hat{\varepsilon}_i^2} \quad (2.25)$$

El estadístico de Durbin-Watson toma valores entre 0 y 4. Un valor cercano a 2 indica ausencia de autocorrelación, mientras que valores cercanos a 0 sugieren autocorrelación positiva y valores cercanos a 4 sugieren autocorrelación negativa. Es importante notar que este supuesto es especialmente relevante en datos de series de tiempo; en datos de corte transversal, como los utilizados en este trabajo, suele ser menos crítico.

2.1.9. Métodos de penalización: Lasso, Ridge y Elastic Net

Los métodos de penalización son técnicas de regularización que reducen la complejidad del modelo al penalizar el tamaño de los coeficientes estimados. Estos métodos son especialmente útiles cuando existe multicolinealidad entre las variables independientes o cuando se desea una selección automática de variables. A continuación se presentan tres variantes principales que se aplican a través de la modificación de la función objetivo a minimizar.

Ridge (Tikhonov): Este método aplica una penalización cuadrática sobre los coeficientes. La función objetivo a minimizar es:

$$\min_{\beta} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^k \beta_j^2 \quad (2.26)$$

Donde $\lambda \geq 0$ es el parámetro de penalización. Conforme λ aumenta, los coeficientes se reducen continuamente hacia cero, pero ninguno se anula completamente. Ridge es especialmente útil cuando

existe alta colinealidad entre las variables independientes, ya que tiende a estabilizar las estimaciones.

Lasso (Least Absolute Shrinkage and Selection Operator):

Este método aplica una penalización sobre el valor absoluto de los coeficientes. La función objetivo a minimizar es:

$$\min_{\beta} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^k |\beta_j| \quad (2.27)$$

A diferencia de Ridge, Lasso puede reducir algunos coeficientes exactamente a cero, realizando automáticamente selección de variables. Esto es especialmente útil cuando se sospecha que algunas variables no son significativas y se desea un modelo más parsimonioso.

Elastic Net: Este método combina las penalizaciones de Ridge y Lasso, proporcionando un balance entre ambos enfoques. La función objetivo a minimizar es:

$$\min_{\beta} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \left(\alpha \sum_{j=1}^k |\beta_j| + (1 - \alpha) \sum_{j=1}^k \beta_j^2 \right) \quad (2.28)$$

Donde $\alpha \in [0, 1]$ es un parámetro que controla el balance entre Lasso ($\alpha = 1$) y Ridge ($\alpha = 0$). Elastic Net combina las ventajas de ambos métodos: la selección automática de variables de Lasso con la estabilidad de Ridge, siendo particularmente efectivo cuando hay grupos de variables correlacionadas.

Es importante notar que en todos estos métodos, la magnitud de la penalización está controlada por el parámetro λ . Un valor $\lambda = 0$ corresponde al modelo de regresión lineal ordinaria sin penalización, mientras que valores grandes de λ resultan en modelos más simples pero

potencialmente con mayor sesgo. La selección óptima de λ típicamente se realiza mediante validación cruzada.

2.2. Regresión Logit

La regresión logística se usa cuando la variable dependiente es una variable binaria que solo toma de manera genérica los valores 0 para indicar fracaso y 1 para indicar éxito. Este modelo será de utilidad para 2 ejercicios: en primer lugar, definir el estatus de clasificación a la Champions League (se considerará 0 como no clasificado y 1 como clasificado); y en segundo lugar, definir el estatus de descenso a la segunda división (se considerará 0 como no descendido y 1 como descendido).

2.2.1. Modelo Logit

Si en lugar de modelar directamente la probabilidad de éxito θ_j , primero se considera el momio de éxito, que se define como:

$$Momio = \frac{\theta_j}{1 - \theta_j} \quad (2.29)$$

que es la proporción de la probabilidad de que se tenga un éxito entre la probabilidad de fracaso. Es importante notar que el momio puede tomar valores en $(0, \infty)$ y su interpretación depende del rango en el que se encuentre:

- Si $\frac{\theta_j}{1 - \theta_j} < 1$, la probabilidad de clasificarse a Champions League es menor a la de no clasificarse, es decir, $\theta_j < 0.5$
- Si $\frac{\theta_j}{1 - \theta_j} = 1$, ambos eventos son igualmente probables, es decir, $\theta_j = 0.5$

- Si $\frac{\theta_j}{1-\theta_j} > 1$, la probabilidad de clasificarse a Champions League es mayor a la de no clasificarse, es decir, $\theta_j > 0.5$

El modelo logit se define como:

$$\text{logit}(\theta_j) = \log(\text{momio}) = \log\left(\frac{\theta_j}{1-\theta_j}\right) = x'\beta \quad (2.30)$$

De donde se obtiene que:

$$\frac{\theta_j}{1-\theta_j} = \exp[x'\beta] \quad (2.31)$$

Y de donde:

$$\theta_j = \frac{1}{1 + \exp[-x'\beta]} \quad (2.32)$$

2.2.2. Regresión Logit con penalización Lasso

Tal como se describió en la sección 2.1.9, la penalización Lasso puede aplicarse también en el contexto de regresión logística. La función objetivo a minimizar se expresa como:

$$\min_{\beta} = - \sum_{i=1}^n [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] + \lambda \sum_{j=1}^k |\beta_j| \quad (2.33)$$

Donde:

- $p_i = \frac{1}{1 + \exp[-(\beta_0 + \sum_{j=1}^k \beta_j x_{ij})]}$
- $\lambda \geq 0$ es el parámetro de penalización de los coeficientes

Lasso es útil en regresión logística cuando se sospecha que algunas variables no son significativas, permitiendo realizar selección automática de variables. Conforme λ aumenta, más coeficientes se reducen exactamente a cero.

2.2.3. Regresión Logit con penalización Ridge

De manera similar, la penalización Ridge puede aplicarse en regresión logística (ver sección 2.1.9 para detalles conceptuales). La función objetivo a minimizar es:

$$\min_{\beta} = - \sum_{i=1}^n [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] + \lambda \sum_{j=1}^k \beta_j^2 \quad (2.34)$$

Donde:

- $p_i = \frac{1}{1 + \exp[-(\beta_0 + \sum_{j=1}^k \beta_j x_{ij})]}$
- $\lambda \geq 0$ es el parámetro de penalización de los coeficientes

Ridge es especialmente útil en regresión logística cuando existe alta colinealidad entre las variables independientes, ya que tiende a estabilizar las estimaciones sin eliminar completamente ninguna variable.

2.2.4. Validación y diagnósticos en regresión logística

La validación de un modelo de regresión logística difiere en varios aspectos de la regresión lineal múltiple, principalmente porque la variable dependiente es binaria y las métricas de evaluación son diferentes. A continuación se presentan las herramientas principales para validar un modelo logístico.

Matriz de confusión y métricas de clasificación: A diferencia de la regresión lineal que predice valores continuos, la regresión logística predice probabilidades que se convierten en clasificaciones binarias (usualmente usando un umbral de 0.5). La matriz de confusión resume las predicciones correctas e incorrectas:

- **Verdaderos Positivos (VP):** Observaciones positivas correctamente clasificadas
- **Verdaderos Negativos (VN):** Observaciones negativas correctamente clasificadas
- **Falsos Positivos (FP):** Observaciones negativas incorrectamente clasificadas como positivas
- **Falsos Negativos (FN):** Observaciones positivas incorrectamente clasificadas como negativas

A partir de la matriz de confusión se derivan métricas de desempeño:

$$\text{Precisión} = \frac{VP}{VP + FP} \quad (2.35)$$

$$\text{Recall} = \frac{VP}{VP + FN} \quad (2.36)$$

$$\text{Exactitud} = \frac{VP + VN}{VP + VN + FP + FN} \quad (2.37)$$

La precisión mide la proporción de predicciones positivas que fueron correctas, el recall mide la proporción de positivos reales que fueron identificados, y la exactitud mide la proporción total de predicciones correctas.

Curva ROC y área bajo la curva (AUC): La curva ROC (Receiver Operating Characteristic) evalúa el desempeño del modelo variando el umbral de clasificación. Se construye graficando la tasa de verdaderos positivos (recall) versus la tasa de falsos positivos ($\frac{FP}{FP+VN}$) para diferentes umbrales. El área bajo la curva ROC (AUC) resume el desempeño del modelo en un único valor entre 0 y 1, donde 0.5 indica un clasificador aleatorio y 1.0 indica un clasificador perfecto. Un modelo es considerado efectivo si $AUC > 0.7$.

Deviance y pruebas de bondad de ajuste: La deviance es el análogo logístico de la suma de cuadrados del error en regresión lineal y se utiliza para evaluar la bondad de ajuste. La deviance residual compara el modelo ajustado con el modelo saturado (que se ajusta perfectamente a los datos), mientras que la deviance nula compara el modelo ajustado con un modelo que solo contiene el intercepto. Un modelo con menor deviance residual que deviance nula indica mejor ajuste.

La prueba de Hosmer-Lemeshow es una prueba formal de bondad de ajuste que divide las predicciones en grupos basados en sus probabilidades predichas y compara los valores observados con los esperados. Si el p-valor es mayor que 0.05, el modelo tiene un ajuste adecuado.

Análisis de residuos: A diferencia de la regresión lineal donde se asume que los residuos siguen una distribución normal, los residuos en regresión logística (conocidos como residuos de Pearson o deviance) tienen propiedades distintas. Sin embargo, aún es útil examinar gráficamente los residuos para identificar patrones o observaciones influyentes.

Diferencias clave con regresión lineal: (1) No se asume normalidad de residuos, pero se verifica la bondad de ajuste mediante la deviance o pruebas como Hosmer-Lemeshow; (2) Las métricas de evaluación cambian de error cuadrático a tasas de clasificación correcta e incorrecta; (3) La heterocedasticidad en regresión logística es inherente al modelo binario y no es un problema como en regresión lineal; (4) La independencia de observaciones sigue siendo un supuesto crítico; (5) La multicolinealidad entre variables independientes se diagnostica de la misma manera que en regresión lineal.

2.3. Regresión ordinal

2.3.1. Modelo

La regresión ordinal es utilizada para modelar la relación entre una variable dependiente ordinal (posición de cada equipo en el ranking) y una o más variables independientes. Una variable ordinal es una variable cualitativa que presenta un orden inherente entre sus categorías, como en este caso puede ser la posición de cada equipo en la tabla de clasificación.

El modelo comúnmente utilizado en regresión ordinal, y que también se usará en este trabajo, es el modelo de probabilidades proporcionales, también conocido como modelo *logit* ordenado. Este modelo supone que la relación entre cada par de categorías de la variable dependiente es constante en todos los niveles de las variables independientes. Existen diferentes funciones link, como el *probit* o *clog - log*, pero en este caso, se usará el link *logit*. Matemáticamente, se expresa mediante la función *logit* acumulativa, que estima la probabilidad de que una observación pertenezca a una categoría específica o a una inferior, en función de una combinación lineal de las variables independientes.

Para especificar el modelo de regresión ordinal con k categorías en la variable dependiente Y , es necesario definir parámetros de corte (cutoffs) que establecen los umbrales entre categorías. Estos parámetros de corte deben satisfacer una restricción de orden:

$$-\infty < \gamma_1 \leq \gamma_2 \leq \gamma_3 \leq \dots \leq \gamma_{k-1} < \infty \quad (2.38)$$

Donde γ_j representa el parámetro de corte entre la categoría j y la categoría $j + 1$. Esta restricción asegura que el orden inherente de las categorías se preserve en el modelo. Por convención, se define $\gamma_0 = -\infty$ y $\gamma_k = \infty$.

La ecuación de un modelo de regresión ordinal con k categorías en la variable dependiente Y se basa en la probabilidad acumulativa de pertenecer a una categoría o a una inferior y se expresa de la siguiente manera:

$$\log \frac{P(Y \leq j)}{1 - P(Y \leq j)} = \log \frac{\gamma_j}{1 - \gamma_j} = \gamma_j - \mathbf{x}'\boldsymbol{\beta} \quad (2.39)$$

Donde:

- $P(Y \leq j)$ es la probabilidad acumulada de que la variable dependiente Y tome un valor menor o igual a j (con $j = 1, 2, \dots, k - 1$)
- γ_j es el parámetro de corte específico de cada categoría, que varía para cada j
- $X_1, X_2, \dots, X_p$ son las variables independientes
- $\beta_1, \beta_2, \dots, \beta_p$ son los coeficientes de regresión que indican el efecto de las variables independientes sobre la probabilidad de estar en una categoría mayor de Y

Es importante notar que el signo del coeficiente del predictor lineal es negativo, contrario al signo positivo utilizado comúnmente en las regresiones binarias.

Una característica interesante del modelo es que la razón de momios de las probabilidades para el evento $y_1 \leq j$ y el evento $y_2 \leq j$ es:

$$\frac{\frac{\gamma_j}{1-\gamma_j}}{\frac{\gamma_j}{1-\gamma_j}} = \exp[-(\mathbf{x}_1 - \mathbf{x}_2)'\boldsymbol{\beta}] \quad (2.40)$$

Independientemente de la categoría de respuesta j . Por esta razón, el modelo es conocido como el modelo de momios proporcionales (McCullagh, 1980).

Supuestos:

- **Probabilidades proporcionales:** las relaciones entre cada par de categorías de la variable dependiente son iguales en todos los niveles de las variables independientes
- **Independencia de las observaciones:** Cada observación debe ser independiente de las demás
- **Ausencia de multicolinealidad:** Las variables independientes no deben estar altamente correlacionadas entre sí
- **Linealidad:** Se asume que existe una relación lineal entre las variables independientes y las probabilidades logarítmicas de las categorías de la variable dependiente

2.3.2. Estimación

A diferencia de la regresión lineal, en el modelo de regresión ordinal los valores óptimos de los parámetros no tienen una solución cerrada como la de MCO. En su lugar, se utiliza la solución numérica del método de *Máxima Verosimilitud* (MV), que consiste en encontrar los valores de β y α_j que maximicen la probabilidad de observar los datos con los que se cuenta.

Para cada observación i , la probabilidad de que $Y_i = j$ se obtiene a partir de las probabilidades acumuladas:

$$P(Y_i = j) = P(Y_i \leq j) - P(Y_i \leq j - 1), \quad (2.41)$$

donde, a partir del modelo logit ordenado definido en la ecuación (2.30), las probabilidades acumuladas son:

$$P(Y_i \leq j) = \frac{1}{1 + \exp(-(\alpha_j - \mathbf{x}_i^\top \boldsymbol{\beta}))}, \quad j = 1, 2, \dots, k-1. \quad (2.42)$$

Con esto, la función de verosimilitud para una muestra de n observaciones independientes se expresa como:

$$L(\boldsymbol{\beta}, \boldsymbol{\alpha}) = \prod_{i=1}^n \prod_{j=1}^k [P(Y_i \leq j) - P(Y_i \leq j-1)]^{I(Y_i=j)}, \quad (2.43)$$

Donde $I(Y_i = j)$ es una función indicadora que toma el valor 1 si la observación i pertenece a la categoría j y 0 en caso contrario. Por convención, se define $P(Y_i \leq 0) = 0$ y $P(Y_i \leq k) = 1$.

En la práctica, es más conveniente maximizar el logaritmo de la verosimilitud, conocido como *log-verosimilitud*:

$$\ell(\boldsymbol{\beta}, \boldsymbol{\alpha}) = \sum_{i=1}^n \sum_{j=1}^k I(Y_i = j) \log[P(Y_i \leq j) - P(Y_i \leq j-1)]. \quad (2.44)$$

Dado que esta función no tiene solución analítica cerrada, los estimadores $\hat{\boldsymbol{\beta}}$ y $\hat{\boldsymbol{\alpha}}$ se obtienen numéricamente mediante algoritmos iterativos como el método de *Newton-Raphson*, que actualiza los parámetros en cada iteración de la siguiente manera:

$$\boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}^{(t)} - \left[\mathbf{H}(\boldsymbol{\theta}^{(t)}) \right]^{-1} \nabla \ell(\boldsymbol{\theta}^{(t)}), \quad (2.45)$$

Donde $\boldsymbol{\theta} = (\boldsymbol{\alpha}, \boldsymbol{\beta})^\top$ agrupa todos los parámetros del modelo, $\nabla \ell$ es el vector gradiente de la log-verosimilitud y $\mathbf{H}$ es la matriz Hessiana de segundas derivadas parciales. El algoritmo converge cuando los cambios entre iteraciones son suficientemente pequeños.

Es importante notar que, a diferencia del estimador MCO, los estimadores de máxima verosimilitud no son insesgados en muestras finitas, aunque sí son *consistentes* y *asintóticamente eficientes*, lo que indica que sus propiedades mejoran conforme el tamaño de muestra aumenta.

2.3.3. Inferencia

La inferencia en el modelo de regresión ordinal se basa en resultados asintóticos. Bajo condiciones de regularidad, los estimadores de máxima verosimilitud satisfacen:

$$\hat{\boldsymbol{\theta}} \stackrel{a}{\sim} \mathcal{N}(\boldsymbol{\theta}, \mathcal{I}(\boldsymbol{\theta})^{-1}), \quad (2.46)$$

Donde $\mathcal{I}(\boldsymbol{\theta})$ es la *matriz de información de Fisher*, definida como el valor esperado negativo de la Hessiana de la log-verosimilitud:

$$\mathcal{I}(\boldsymbol{\theta}) = -\mathbb{E}[\mathbf{H}(\boldsymbol{\theta})] = -\mathbb{E}\left[\frac{\partial^2 \ell}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}^\top}\right]. \quad (2.47)$$

En la práctica, $\mathcal{I}(\boldsymbol{\theta})$ se estima evaluando la Hessiana en $\hat{\boldsymbol{\theta}}$, de modo que la matriz de covarianzas estimada de los estimadores es:

$$\widehat{\text{Var}}(\hat{\boldsymbol{\theta}}) = \left[-\mathbf{H}(\hat{\boldsymbol{\theta}})\right]^{-1}. \quad (2.48)$$

Prueba z para coeficientes individuales: Para evaluar si una variable independiente tiene un efecto significativo sobre la variable ordinal, se plantea la hipótesis:

$$H_0 : \beta_j = 0 \quad \text{vs.} \quad H_1 : \beta_j \neq 0. \quad (2.49)$$

El estadístico de prueba es el estadístico de Wald:

$$z_j = \frac{\hat{\beta}_j}{\widehat{\text{ee}}(\hat{\beta}_j)}, \quad (2.50)$$

Donde $\widehat{\text{ee}}(\hat{\beta}_j)$ es la raíz cuadrada del j -ésimo elemento diagonal de $\widehat{\text{Var}}(\hat{\boldsymbol{\theta}})$. Bajo H_0 y de manera asintótica, $z_j \sim \mathcal{N}(0, 1)$, por lo que se rechaza H_0 si $|z_j| > z_{\alpha/2}$. De manera equivalente, se puede construir un intervalo de confianza asintótico del $(1 - \alpha) \times 100\%$ para β_j :

$$\hat{\beta}_j \pm z_{\alpha/2} \widehat{\text{ee}}(\hat{\beta}_j). \quad (2.51)$$

Prueba de razón de verosimilitudes: Para comparar dos modelos anidados, es decir, un modelo completo con p predictores y un modelo reducido con $p' < p$ predictores, se utiliza la prueba de razón de verosimilitudes. El estadístico se expresa de la siguiente manera:

$$\Lambda = -2 \left[\ell(\hat{\boldsymbol{\theta}}_{\text{reducido}}) - \ell(\hat{\boldsymbol{\theta}}_{\text{completo}}) \right], \quad (2.52)$$

que bajo H_0 (el modelo reducido es suficiente) sigue de manera asintótica una distribución $\chi^2_{p-p'}$. Un valor grande de Λ indica que el modelo completo se ajusta significativamente mejor que el reducido, lo que sugiere que las variables adicionales son relevantes.

2.3.4. Validación

La validación del modelo de regresión ordinal se lleva a cabo a través de la verificación del supuesto de proporcionalidad, la evaluación de la bondad de ajuste y la medición de la capacidad predictiva del modelo.

Supuesto de probabilidades proporcionales: El supuesto central del modelo logit ordenado es que los coeficientes $\boldsymbol{\beta}$ son iguales para todas las categorías de respuesta, es decir, que el efecto de cada

variable independiente sobre el momio acumulado es constante independientemente de la categoría j . Para verificarlo, se utiliza la *prueba de líneas paralelas*, que plantea:

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_{k-1}, \quad (2.53)$$

y cuyo estadístico de prueba sigue de manera asintótica una distribución $\chi^2_{(k-2) \times p}$. Si se rechaza H_0 , el supuesto de proporcionalidad no se sostiene y el modelo logit ordenado estándar no sería adecuado para los datos.

Bondad de ajuste: Para evaluar qué tan bien se ajusta el modelo a los datos, se utilizan pseudocoeeficientes R^2 , que son análogos al R^2 de la regresión lineal pero adaptados al contexto de máxima verosimilitud. Uno de los más utilizados es el R^2 de *McFadden*:

$$R^2_{\text{McFadden}} = 1 - \frac{\ell(\hat{\boldsymbol{\theta}})}{\ell(\hat{\boldsymbol{\theta}}_0)}, \quad (2.54)$$

Donde $\ell(\hat{\boldsymbol{\theta}})$ es la log-verosimilitud del modelo ajustado y $\ell(\hat{\boldsymbol{\theta}}_0)$ es la log-verosimilitud del modelo nulo, es decir, el modelo que solo incluye los interceptos α_j sin ninguna variable independiente. Es importante notar que este índice no se interpreta de la misma manera que el R^2 ordinario; valores entre 0.2 y 0.4 se consideran indicativos de un buen ajuste en modelos de esta naturaleza.

Capacidad predictiva: Adicionalmente, se puede evaluar la capacidad del modelo para predecir correctamente la categoría de cada observación a través de la *precisión de clasificación*, que se define como la proporción de observaciones correctamente clasificadas:

$$\text{Precisión} = \frac{1}{n} \sum_{i=1}^n I(\hat{Y}_i = Y_i), \quad (2.55)$$

Donde $\hat{Y}_i = \arg \max_j P(Y_i = j \mid \mathbf{x}_i)$ es la categoría con mayor probabilidad predicha para la observación i . Para evitar el sobreajuste, esta métrica se calcula preferentemente sobre un conjunto de prueba independiente del conjunto utilizado para ajustar el modelo.

2.3.5. Verificación del supuesto de proporcionalidad

El supuesto central del modelo logit ordenado es que los coeficientes β son iguales para todas las categorías de respuesta, es decir, que el efecto de cada variable independiente sobre el momio acumulado es constante independientemente de la categoría j . Este supuesto se conoce como el supuesto de proporcionalidad u odds proporcionales.

Para verificar si este supuesto se sostiene, se utiliza la prueba de líneas paralelas (parallel lines test). Esta prueba contrasta el modelo logit ordenado (modelo restringido) con un modelo logit parcialmente proporcional (modelo no restringido) donde los coeficientes pueden variar entre categorías.

La hipótesis a contrastar es:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_{k-1} \quad \text{vs.} \quad H_1 : \text{al menos un } \beta_j \text{ difiere} \quad (2.56)$$

El estadístico de prueba se basa en la razón de verosimilitudes:

$$\Lambda = -2 [\ell(\text{modelo restringido}) - \ell(\text{modelo no restringido})] \quad (2.57)$$

donde ℓ denota la log-verosimilitud. Bajo H_0 , este estadístico sigue de manera asintótica una distribución χ^2 con $p(k-2)$ grados de libertad,

donde p es el número de variables independientes y k es el número de categorías.

Si el p-valor es mayor que $\alpha = 0.05$, se concluye que no hay evidencia estadística suficiente para rechazar H_0 , y el supuesto de proporcionalidad se sostiene. Si el p-valor es menor que $\alpha = 0.05$, el supuesto se viola, lo que indica que el modelo logit ordenado estándar puede no ser adecuado para los datos, y se debería considerar un modelo logit parcialmente proporcional o logit multinomial.

Es importante notar que aunque la violación del supuesto de proporcionalidad es una preocupación teórica, en la práctica el modelo logit ordenado puede ser robusto a violaciones moderadas de este supuesto, especialmente cuando el tamaño de la muestra es pequeño.

2.3.6. Diagnósticos en regresión ordinal

A diferencia de la regresión lineal donde existen herramientas bien establecidas para diagnosticar problemas en el ajuste, los diagnósticos en regresión ordinal son menos directos. Sin embargo, es posible adaptar algunos conceptos de regresión lineal y logística al contexto ordinal.

Residuos en regresión ordinal: Existen varios tipos de residuos que pueden calcularse en un modelo de regresión ordinal. Los más comunes son:

- **Residuos de Pearson:** Se calculan como

$$r_{Pi} = \frac{y_i - \hat{p}_i}{\sqrt{\hat{p}_i(1 - \hat{p}_i)}} \quad (2.58)$$

donde y_i es la respuesta binaria (1 si la observación pertenece a la categoría predicha, 0 en caso contrario) y $\hat{p}_i$ es la probabilidad predicha.

- **Residuos de Deviance:** Basados en la contribución de cada observación a la deviance total del modelo, estos residuos tienen una distribución aproximadamente normal con media cero bajo el modelo correcto.

Análisis gráfico de residuos: Aunque los residuos en regresión ordinal no siguen una distribución normal (como en regresión lineal), es útil examinar gráficamente los residuos para identificar patrones o observaciones influyentes. Se pueden construir gráficas de residuos versus valores predichos para detectar heterocedasticidad o no linealidad.

Observaciones influyentes: Para identificar observaciones que tienen un impacto desproporcionado en las estimaciones de los coeficientes, se puede adaptar el concepto de distancia de Cook. Una aproximación es utilizar la distancia de Cook basada en la matriz Hessiana del modelo logístico ordenado:

$$D_i = (\hat{\beta} - \hat{\beta}_{(i)})' I(\hat{\beta})^{-1} (\hat{\beta} - \hat{\beta}_{(i)}) \quad (2.59)$$

donde $\hat{\beta}_{(i)}$ son los coeficientes estimados cuando la observación i se excluye del análisis, e $I(\hat{\beta})$ es la matriz de información de Fisher. Las observaciones con D_i grande indican influencia potencial en el modelo.

2.3.7. Bondad de ajuste y evaluación del modelo

La evaluación de qué tan bien el modelo se ajusta a los datos en regresión ordinal difiere del enfoque usado en regresión lineal, donde se emplean medidas como R^2 . En regresión ordinal, se utilizan pseudocoeficientes R^2 que son análogos al R^2 tradicional pero adaptados al contexto de máxima verosimilitud.

R^2 de McFadden: Es el pseudocoficiente R^2 más comúnmente utilizado:

$$R_{\text{McFadden}}^2 = 1 - \frac{\ell(\hat{\beta})}{\ell(\hat{\beta}_0)} \quad (2.60)$$

donde $\ell(\hat{\beta})$ es la log-verosimilitud del modelo ajustado y $\ell(\hat{\beta}_0)$ es la log-verosimilitud del modelo nulo (modelo que solo incluye los interceptos sin variables independientes).

Es importante notar que R_{McFadden}^2 toma valores entre 0 y 1, pero no se interpreta de la misma manera que el R^2 ordinario. En regresión ordinal, valores entre 0.2 y 0.4 se consideran indicativos de un buen ajuste, mientras que valores superiores a 0.5 son considerados excelentes.

R^2 de Nagelkerke: Otra medida popular es el pseudocoficiente R^2 de Nagelkerke, que escala el R^2 de McFadden para que pueda alcanzar un máximo de 1:

$$R_{\text{Nagelkerke}}^2 = \frac{1 - e^{2[\ell(\hat{\beta}_0) - \ell(\hat{\beta})]/n}}{1 - e^{2\ell(\hat{\beta}_0)/n}} \quad (2.61)$$

Criterios de información: Los criterios AIC y BIC pueden ser utilizados para comparar modelos de regresión ordinal con diferentes conjuntos de variables predictoras:

$$\text{AIC} = -2\ell(\hat{\beta}) + 2k, \quad \text{BIC} = -2\ell(\hat{\beta}) + k \ln(n) \quad (2.62)$$

donde k es el número de parámetros y n es el tamaño de la muestra. Modelos con menores valores de AIC o BIC son preferibles.

Capacidad predictiva: La capacidad del modelo para clasificar correctamente las observaciones en sus categorías correspondientes se puede evaluar mediante la precisión de clasificación:

$$\text{Precisión} = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(\hat{y}_i = y_i) \quad (2.63)$$

donde $\hat{y}_i = \arg\max_j P(Y_i = j | \mathbf{x}_i)$ es la categoría con mayor probabilidad predicha. Para evitar sobreajuste, esta métrica debe calcularse preferentemente sobre un conjunto de prueba independiente del conjunto utilizado para ajustar el modelo.

2.3.8. Métodos de penalización en regresión ordinal

Así como se discutió en la sección 2.1.9 para regresión lineal múltiple, los métodos de penalización (Lasso, Ridge y Elastic Net) pueden aplicarse también en el contexto de regresión ordinal. Estos métodos son especialmente útiles cuando existe multicolinealidad entre las variables independientes o cuando se desea una selección automática de variables.

Regresión ordinal con penalización Ridge: La función objetivo a minimizar se expresa como:

$$\min_{\boldsymbol{\beta}} = - \sum_{i=1}^n \ell_i(\boldsymbol{\beta}) + \lambda \sum_{j=1}^k \beta_j^2 \quad (2.64)$$

donde $\ell_i(\boldsymbol{\beta})$ es la contribución de la observación i a la log-verosimilitud. Ridge es especialmente útil cuando existe alta colinealidad entre las variables independientes, ya que tiende a estabilizar las estimaciones sin eliminar completamente ninguna variable.

Regresión ordinal con penalización Lasso: La función objetivo a minimizar es:

$$\min_{\beta} = - \sum_{i=1}^n \ell_i(\beta) + \lambda \sum_{j=1}^k |\beta_j| \quad (2.65)$$

Lasso puede reducir algunos coeficientes exactamente a cero, realizando automáticamente selección de variables. Esto es especialmente útil en regresión ordinal cuando se sospecha que algunas variables no son significativas y se desea un modelo más parsimonioso.

Regresión ordinal con penalización Elastic Net: Combina las penalizaciones de Ridge y Lasso:

$$\min_{\beta} = - \sum_{i=1}^n \ell_i(\beta) + \lambda \left(\alpha \sum_{j=1}^k |\beta_j| + (1 - \alpha) \sum_{j=1}^k \beta_j^2 \right) \quad (2.66)$$

donde $\alpha \in [0, 1]$ controla el balance entre Lasso y Ridge. Elastic Net es particularmente efectivo cuando hay grupos de variables correlacionadas.

La selección óptima del parámetro de penalización λ típicamente se realiza mediante validación cruzada, evaluando el desempeño del modelo en datos no vistos durante el entrenamiento.

2.4. Simulación de partidos: Modelo de Poisson

2.4.1. Modelo

La simulación de partidos es un método que permite estimar la probabilidad de que cada equipo termine en una posición determinada de la tabla al final de la temporada, sin necesidad de calcular explícitamente todas las combinaciones posibles de resultados. El enfoque seguido en este trabajo está basado en el modelo propuesto por Lee (1997), en el cual se modela la distribución de goles de cada

equipo mediante distribuciones de Poisson independientes y se simulan temporadas completas para estimar las probabilidades de clasificación.

Estimación de parámetros: Los parámetros del modelo (μ , α_H , ataque $_k$ y defensa $_k$ para cada equipo k) se estiman mediante el método de máxima verosimilitud, asumiendo que los goles de ambos equipos son independientes entre sí. Lee (1997) valida este supuesto de independencia a través de una prueba χ^2 sobre la tabla de frecuencias cruzadas de goles locales y visitantes por temporada, encontrando que no existe evidencia en contra de la independencia. Una vez estimados los parámetros, es posible calcular la distribución conjunta de goles para cualquier combinación de equipos de la siguiente manera:

$$P(X_{ij}^H = h, X_{ij}^A = a) = \frac{e^{-\lambda_{ij}^H} (\lambda_{ij}^H)^h}{h!} \cdot \frac{e^{-\lambda_{ij}^A} (\lambda_{ij}^A)^a}{a!} \quad (2.67)$$

y, a partir de esta distribución, obtener las probabilidades de victoria, empate y derrota para cada partido sumando sobre las combinaciones de marcadores correspondientes.

Simulación Monte Carlo: Dado que calcular la probabilidad exacta de que un equipo termine en cada posición de la tabla requiere evaluar todas las posibles combinaciones de resultados de los 380 partidos de la temporada, lo cual resulta computacionalmente inviable, se recurre a la simulación Monte Carlo como alternativa práctica. El procedimiento consiste en simular un número elevado de temporadas completas N , donde en cada temporada se genera el marcador de cada partido muestreando de manera independiente:

$$\tilde{X}_{ij}^H \sim \text{Poisson}(\hat{\lambda}_{ij}^H), \quad \tilde{X}_{ij}^A \sim \text{Poisson}(\hat{\lambda}_{ij}^A) \quad (2.68)$$

A partir de los marcadores simulados se asignan los puntos correspondientes (3 por victoria, 1 por empate, 0 por derrota) y se construye la tabla de posiciones de esa temporada. Al repetir este proceso N veces, se estima la probabilidad de que cada equipo termine en cada posición como la proporción de simulaciones en las que dicho resultado se observó. En este trabajo se utiliza $N = 1,000$ simulaciones, valor con el que Lee (1997) demuestra que las estimaciones convergen con suficiente precisión.

Supuestos

- **Distribución de Poisson:** El número de goles anotados por cada equipo en cada partido sigue una distribución de Poisson, lo que implica que los goles ocurren de manera aleatoria e independiente a una tasa constante a lo largo del partido.
- **Independencia de goles:** Los goles anotados por el equipo local y los anotados por el visitante son independientes entre sí, supuesto validado empíricamente por Lee (1997) mediante una prueba χ^2 .
- **Estacionariedad de parámetros:** Los parámetros de ataque y defensa de cada equipo se asumen constantes a lo largo de la temporada, sin considerar el efecto de lesiones, sanciones o cambios en el rendimiento a lo largo del tiempo.
- **Homogeneidad del calendario:** Se asume que cada equipo enfrenta a todos los demás en condiciones equivalentes, sin

considerar efectos de fatiga derivados de la participación en competencias europeas o de la acumulación de partidos.

Validación del supuesto de independencia: Siguiendo el procedimiento de Lee (1997), se verifica que los goles anotados por el equipo local y el equipo visitante son independientes entre sí. Para esto, se construye una tabla de frecuencias cruzadas con los goles de ambos equipos en cada uno de los 380 partidos de la temporada 2023-2024, y se aplica una prueba χ^2 de independencia sobre dicha tabla.

La hipótesis a contrastar es:

H_0 : los goles del equipo local y del visitante son independientes

H_1 : existe dependencia entre ambos.

El estadístico de prueba se calcula como:

$$\chi^2 = \sum_i \sum_j \frac{(O_{ij} - E_{ij})^2}{E_{ij}}, \quad (2.69)$$

Donde O_{ij} es la frecuencia observada de partidos en los que el equipo local anotó i goles y el visitante anotó j goles, y $E_{ij} = \frac{n_{i \cdot} \cdot n_{\cdot j}}{n}$ es la frecuencia esperada bajo el supuesto de independencia. La tabla de frecuencias observadas para la temporada 2023-2024 se muestra a continuación:

Al aplicar la prueba χ^2 sobre esta tabla se obtienen los siguientes resultados:

$$\chi^2 = 45,08, \quad \text{g.l.} = 42, \quad p\text{-valor} = 0,3442. \quad (2.70)$$

Cuadro 2.1. Frecuencias observadas de goles: local vs. visitante (2023-2024)

Local \ Visitante	0	1	2	3	4	5	6	8
0	11	20	19	7	5	3	2	1
1	22	38	24	17	7	1	0	0
2	24	31	27	10	4	1	0	0
3	18	26	13	4	2	0	0	0
4	5	9	6	4	2	0	0	0
5	8	5	1	0	0	0	0	0
6	1	2	0	0	0	0	0	0

Dado que el p -valor es de 0,3442, no se rechaza H_0 al nivel de significancia $\alpha = 0,05$. Esto indica que no existe evidencia estadística suficiente para afirmar que los goles del equipo local y del visitante están relacionados, lo que es consistente con el resultado reportado por Lee (1997) para temporadas anteriores de la Premier League. Por lo tanto, el supuesto de independencia del modelo de Poisson se sostiene para la temporada 2023-2024 y el modelo es adecuado para simular los marcadores de cada partido.

2.5. Análisis discriminante

El análisis discriminante se utiliza para clasificar en grupos a partir de variables predictoras. El objetivo es definir la función que maximiza la separación entre clases, minimizando al mismo tiempo la variabilidad dentro de cada grupo. En este caso, se usará para 2 ejercicios: en primer lugar, para estimar si un equipo se clasifica a la UEFA Champions League; y en segundo lugar y para un ejercicio adicional e

independiente, para estimar si un equipo desciende a segunda división. Las variantes que se utilizarán en esta investigación son el Análisis Discriminante Lineal (LDA) y el Análisis Discriminante Cuadrático (QDA).

2.5.1. Análisis discriminante lineal (LDA)

El LDA asume que las observaciones de cada clase k provienen de una distribución normal multivariada con media μ_k y una matriz de covarianza común Σ . De esta manera, se obtiene una función discriminante lineal que clasifica observaciones según la probabilidad de pertenecer a cada clase.

La regla de clasificación se basa en maximizar la función discriminante:

$$\delta_k(x) = X' \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k' \Sigma^{-1} \mu_k + \log(p_k) \quad (2.71)$$

Donde:

- μ_k es la media del grupo k
- Σ es la matriz de covarianza
- $p_k = \frac{N_k}{N}$ es la probabilidad a priori de la clase k

Al momento de utilizar el modelo, una observación x es clasificada en la clase k en la que tenga el mayor valor.

Supuestos del LDA:

- Las variables predictoras siguen una distribución normal multivariada dentro de cada grupo
- Las matrices de covarianza son iguales para todas las clases
- Las observaciones son independientes entre sí
- Las clases son mutuamente excluyentes

2.5.2. Análisis discriminante cuadrático (QDA)

El Análisis Discriminante Cuadrático (QDA) es una generalización del LDA que relaja el supuesto de igualdad de matrices de covarianza entre clases. Para este método, se permite que cada grupo k tenga su propia matriz de covarianza Σ_k y, como resultado, las fronteras de decisión ya no son lineales, sino superficies cuadráticas.

La función discriminante en QDA está dada por:

$$\delta_k(x) = -\frac{1}{2}\log(|\Sigma_k|) - \frac{1}{2}(x - \mu_k)'\Sigma_k^{-1}(x - \mu_k) + \log(p_k) \quad (2.72)$$

Al igual que en LDA, a una observación se le asigna la clase con mayor valor de la función.

Supuestos del QDA:

- Las variables predictoras siguen una distribución normal multivariada dentro de cada grupo
- Cada clase tiene su propia matriz de covarianza Σ_k
- Las observaciones son independientes
- Las clases son mutuamente excluyentes

2.5.3. Ventajas y desventajas de LDA y QDA

Aunque tanto el Análisis Discriminante Lineal (LDA) como el Análisis Discriminante Cuadrático (QDA) son métodos de clasificación que comparten supuestos comunes, difieren en su complejidad y en el supuesto crítico sobre la igualdad de matrices de covarianza. Esta sección presenta una comparación detallada de las ventajas y desventajas de ambos métodos para facilitar la selección del más apropiado según el contexto del problema.

Ventajas y desventajas del Análisis Discriminante Lineal (LDA):

- **Ventaja - Simplicidad computacional:** LDA es más simple de implementar y requiere menos poder computacional que QDA. Las fronteras de decisión lineales son más rápidas de calcular, especialmente cuando se trabaja con conjuntos de datos grandes.
- **Ventaja - Menor número de parámetros:** LDA estima una única matriz de covarianza común Σ para todas las clases, lo que requiere estimar $p(p+1)/2$ parámetros (donde p es el número de

variables). En contraste, QDA estima una matriz de covarianza distinta para cada clase, requiriendo $k \cdot p(p + 1)/2$ parámetros.

- **Ventaja - Mejor desempeño con muestras pequeñas:** Cuando el tamaño de la muestra es pequeño, LDA tiende a tener mejor desempeño que QDA porque hay menos parámetros a estimar. Con menos observaciones, la estimación de múltiples matrices de covarianza (como en QDA) puede ser inestable.
- **Ventaja - Interpretabilidad:** Las fronteras de decisión lineales son más fáciles de interpretar y visualizar que las fronteras cuadráticas. Esto facilita la comunicación de resultados a audiencias no técnicas.
- **Desventaja - Supuesto restrictivo:** LDA asume que todas las clases tienen la misma matriz de covarianza. Si este supuesto no se sostiene, el modelo puede tener un sesgo importante, resultando en predicciones sesgadas.
- **Desventaja - Menor flexibilidad:** Debido a su naturaleza lineal, LDA puede no capturar patrones complejos en los datos. Si las verdaderas fronteras de decisión son no lineales, LDA tendrá un desempeño pobre.

Ventajas y desventajas del Análisis Discriminante Cuadrático (QDA):

- **Ventaja - Mayor flexibilidad:** QDA relaja el supuesto de igualdad de matrices de covarianza, permitiendo fronteras de decisión cuadráticas más complejas. Esto lo hace más flexible para capturar patrones no lineales en los datos.

- **Ventaja - Mejor ajuste cuando el supuesto se viola:** Cuando las diferentes clases tienen estructuras de covarianza sustancialmente diferentes, QDA proporciona un ajuste significativamente mejor que LDA. El modelo es capaz de adaptarse a estas diferencias.
- **Ventaja - Desempeño con muestras grandes:** Cuando se dispone de una muestra suficientemente grande, QDA puede estimar con precisión las matrices de covarianza individuales de cada clase, permitiendo explotar la flexibilidad adicional del modelo.
- **Ventaja - Menos sesgado:** Al no imponer el supuesto restrictivo de covarianza común, QDA es menos propenso al sesgo de especificación que podría afectar a LDA.
- **Desventaja - Más parámetros a estimar:** QDA requiere estimar k matrices de covarianza (una por clase), lo que significa más parámetros que deben estimarse a partir de los datos. Esto incrementa la varianza de las estimaciones.
- **Desventaja - Complejidad computacional:** QDA es más computacionalmente intensivo que LDA, especialmente cuando el número de variables es grande o cuando se trabaja con múltiples clases.
- **Desventaja - Riesgo de sobreajuste:** Con un número elevado de parámetros y especialmente con muestras pequeñas, QDA corre un riesgo mayor de sobreajuste. El modelo puede aprender patrones espurios específicos de la muestra de entrenamiento que no se generalizan a datos nuevos.

- **Desventaja - Interpretabilidad reducida:** Las fronteras de decisión cuadráticas son más difíciles de visualizar e interpretar, particularmente cuando hay más de dos dimensiones.

Capítulo 3

Bases de datos y análisis exploratorio de datos

Este capítulo tiene el propósito de explicar la construcción y definición de variables de la base de datos.

3.1. Creación de base de datos

Para los propósitos de este trabajo, recopilé manualmente datos de 9 temporadas de la Premier League (2015/2016-2023/2024) sobre el desempeño y características de los 20 equipos por temporada. La base de datos está compuesta de 180 entradas con 43 variables sobre temas de desempeño dentro y fuera de la cancha. Para construir la base, la información fue recopilada del sitio oficial de la Premier League (Premier League, 2025), el sitio especializado en data de fútbol FBREF (FBREF, 2025) y el sitio especializado en transferencias de jugadores (Transfermarkt, 2025). Con esta información, las siguientes variables fueron creadas:

Cuadro 3.1. Desempeño en el campo de juego

Variable	Descripción y transformaciones	Rango
1. Goles a favor	Goles anotados a lo largo de la temporada	[20, 106]
2. Goles en contra	Goles recibidos a lo largo de la temporada	[22, 104]
3. Diferencia de goles	Calculada como la resta de goles a favor menos goles en contra	[−69, 79]
4. Porterías a cero	Cantidad de partidos sin recibir gol	[1, 21]
5. Tarjetas amarillas	Cantidad de tarjetas amarillas recibidas	[38, 109]
6. Tarjetas rojas	Cantidad de tarjetas rojas recibidas	[0, 7]
7. XGF	Goles anotados esperados a lo largo de la temporada	[28.8, 92.0]
8. XGC	Goles recibidos esperados a lo largo de la temporada	[23.8, 78.0]
9. GvsXG	Calculada como la diferencia entre goles anotados y goles anotados esperados	[−14.0, 27.4]
10. Tiros	Tiros realizados	[319, 781]
11. Tiros a gol	Tiros realizados con dirección a portería	[92, 656]
12. Goles de penal	Goles anotados de penalti	[0, 11]
13. Goles de cabeza	Goles anotados de cabeza	[1, 19]
14. Goles dentro del área	Goles anotados desde dentro del área	[17, 93]
15. Goles fuera del área	Goles anotados desde fuera del área	[0, 18]
16. Goles de contragolpe	Goles anotados en situación de contragolpe	[0, 13]
17. Fuera de lugar	Cantidad de fuera de lugar cometidos	[37, 108]
18. Autogoles	Cantidad de autogoles	[0, 7]
19. Penales provocados	Cantidad de penales provocados	[0, 14]
20. Atajadas	Cantidad de atajadas realizadas por el portero	[54, 179]
21. Despejes	Cantidad de despejes realizados	[227, 1308]

Cuadro 3.1 continuación

Variable	Descripción y transformaciones	Rango
22. Barridas	Cantidad de barridas realizadas	[173, 899]
23. Faltas	Cantidad de faltas cometidas	[289, 514]
24. Total de pases	Cantidad total de pases realizados	[7170, 27758]
25. Pases filtrados	Cantidad de pases filtrados realizados	[8, 168]
26. Pases hacia atrás	Cantidad de pases hacia atrás realizados	[160, 4796]
27. Centros	Cantidad de centros realizados	[428, 969]
28. Tiros de esquina	Cantidad de tiros de esquina	[128, 316]

Cuadro 3.2. Desempeño en el ranking

Variable	Descripción y transformaciones	Rango
29. Competencias europeas	Variable indicadora: toma el valor 1 si el equipo participó en un torneo europeo durante esa temporada, 0 en caso contrario	{0, 1}
30. Recién ascendido	Variable indicadora: toma el valor 1 si el equipo recién ascendió a la Premier League, 0 en caso contrario	{0, 1}
31. Champions League	Variable indicadora: toma el valor 1 si el equipo logró clasificarse a la UEFA Champions League, 0 en caso contrario	{0, 1}
32. Descenso	Variable indicadora: toma el valor 1 si el equipo descendió a la Championship al final de la temporada, 0 en caso contrario	{0, 1}

Cuadro 3.3. Características extra cancha


Variable	Descripción y transformaciones	Rango
33. Temporada	Indica la temporada a la que corresponde el registro	[15/16, 23/24]
34. Big 6	Variable indicadora: toma el valor 1 si el equipo pertenece al <i>Big 6</i> (Arsenal, Chelsea, Liverpool, Manchester City, Manchester United y Tottenham), 0 en caso contrario	{0, 1}
35. Gasto por transferencias	Dinero gastado en transferencias de jugadores, expresado en millones de euros	[0, 611.5]
36. Ingreso por transferencias	Dinero ingresado por venta de jugadores, expresado en millones de euros	[0, 278.3]
37. Jugadores nuevos	Cantidad de jugadores que llegaron al equipo	[4, 41]
38. Jugadores vendidos	Cantidad de jugadores que salieron del equipo	[4, 46]
39. Valor de la plantilla	Valor de mercado total de la plantilla, expresado en millones de euros	[99.9, 1460.0]
40. Cantidad de jugadores	Número total de jugadores en la plantilla	[25, 56]
41. Valor promedio de los jugadores	Calculado como el promedio del valor de mercado de todos los jugadores de la plantilla, expresado en millones de euros	[0.08, 40.56]
42. Asistencia promedio al estadio	Calculada como el promedio de asistentes por partido a lo largo de la temporada	[178, 75290]
43. Ventaja de local	Calculada como la diferencia porcentual entre los puntos obtenidos de local y de visitante	[−0.20, 0.43]

3.2. Análisis exploratorio de datos

3.2.1. Desempeño en el campo de juego

A continuación, se realizará un análisis exploratorio de datos para entender las posibles relaciones en las variables. Para analizar la primera división de fútbol inglesa, se analizarán datos de los últimos 9 años. Esta información incluye goles a favor y en contra, tipos de goles, tipos de pases, inversión en transferencias, asistencia al estadio, entre otras. El objetivo será encontrar qué variables influyen más en la posición en la tabla, así como en si un equipo podrá entrar a puestos de Champions League o salvarse de un posible descenso. A continuación se muestra un resumen de la diferencia de goles por posición en la tabla:

Figura 3.1. Diferencia de goles (goles a favor menos goles en contra) promedio por la posición de la tabla



Al observar en la gráfica 4.1 los cuartiles y el promedio, se identifica variabilidad entre la diferencia de goles a través de las posiciones, específicamente en las primeras 4 posiciones, en la 8 y en la 20. Al relacionarlo con la situación de los equipos, se podría sugerir un impacto en la posición de cada equipo por variables como Goles a Favor, Goles en Contra, Tiros a puerta, Goles de Contragolpe, Valor promedio de los jugadores, Inversión en transferencias o la Asistencia promedio, lo cual lleva a las siguientes preguntas:

- ¿Alguna de estas variables podría explicar por sí sola la posición de cada equipo?
- ¿Existen variables extracancha que tengan un impacto significativo?
- ¿Participar en competencias europeas impacta en el rendimiento de la liga local?
- ¿Existe algún estilo de juego que influya en la posición de cada equipo (ofensivo como el Manchester City o defensivo como el Brentford)?

Para tratar de responder estas preguntas se explorarán los datos para encontrar relaciones entre las variables dependientes (Posición en el ranking, clasificación a Champions League o salvación del descenso, según el modelo) y las variables independientes (goles, tiros, asistencia al estadio, transferencias, entre otras). Se comenzará con un análisis de tiros y goles, seguido de un análisis de correlación, para identificar posibles variables predictivas a través de los distintos modelos.

Distribución de tiros y goles

A continuación se presentan los histogramas de Tiros a Gol, Goles a favor y su división si los equipos pertenecen al Big 6¹ o si son recién ascendidos

Figura 3.2. Tiros a gol






Figura 3.3. Goles a favor




¹El Big 6 es un grupo de equipos considerados como los más relevantes de la liga en términos de historia, títulos y poder económico. Estos equipos son Arsenal, Chelsea, Liverpool, Manchester City, Manchester United y Tottenham Hotspur

Figura 3.4. Diferencia de goles



Se puede observar una concentración de tiros a gol entre 100 y 200 por temporada, Goles esperados entre 36 y 54 y Goles a Favor entre 35 y 62. Lo que podría decirnos que equipos fuera de estos rango puedan estar en posiciones muy altas o muy bajas. Asimismo, los equipos del Big 6 muestran una diferencia de goles muy superior al resto de la liga, mientras que los recién ascendidos tienden a tener una diferencia mucho menor. Lo que podría indicar que pertenecer a estos grupos podría predisponer el rendimiento durante la temporada.

Figura 3.5. Correlación



Se pueden observar 2 grupos de variables altamente correlacionados:


1. Variables relacionadas con goles anotados con variables relacionadas con cantidad de pases, asistencia al estadio y valor de la plantilla;
2. Variables relacionadas con goles recibidos con goles, pases y valor de plantilla.

Por este motivo, se explorarán variables relacionadas con goles, tiros, asistencia al estadio y valor de plantilla como paso previo a los modelos.

Se observará la relación entre la posición con el valor de los jugadores.

3.2.2. Características extra cancha

Figura 3.6. Relación entre valor promedio (millones de dólares estadounidenses) de jugadores y posición en la tabla



Al hacer un par de cálculos extras para obtener el valor promedio de los jugadores de los equipos dependiendo de su posición, se observa una clara relación entre un valor alto y una mejor posición en la tabla para los primeros 6 lugares, sin embargo de media tabla hacia abajo los valores promedio son similares, lo que indica que tener jugadores de valor alto no asegura la permanencia en la primera división y que esto podría ajustarse mejor a una regresión polinomial del tipo:

$$ValorPromJugador = \alpha_0 + \alpha_1 x + \alpha_2 x^2 + \alpha_3 x^3 + \epsilon \quad (3.1)$$

Donde x es la posición en la tabla

Capítulo 4

Análisis y modelos de la Premier League

En este penúltimo capítulo se analizarán los datos y se generarán modelos de predicción

4.1. Regresión Lineal

Como ejercicio, se realizarán dos regresiones lineales para entender qué variables pueden influir más en la posición final. Como primer ejercicio, el primer modelo podría estimar la posición de la siguiente manera:

$$Posición = 10.5035 - .187089 * DiferenciaGoles \quad (4.1)$$

Esto indica que la posición en la tabla se ve negativamente relacionada con la diferencia de goles; es decir por cada gol neto, la posición mejora en .187089 lugares.

Este modelo mostró un nivel alto de significancia; sin embargo tiene algunas limitantes; ya que asume que las posiciones son continuas y no enteras.

Como ejercicio adicional, se hará una regresión lineal múltiple y se hará uso del criterio de Akaike para determinar el modelo que utilice la menor cantidad de variables con la mayor significancia.

Al analizar los modelos finales después de la selección, el modelo que utilizó el criterio de AIC arrojó 5 variables como las más significativas: Goles a Favor, Goles en Contra, Goles de contragolpe, Centros y Participación en competencias europeas. El modelo fue el siguiente:

$$\begin{aligned} \text{Posición} = & 7.382702 - 0.148137 * GaF \\ & + 0.181642 * GaC - 0.172585 * GolContragolpe \quad (4.2) \\ & + 0.003628 * Centros - 1.727391 * CompetenciasEuropeas \end{aligned}$$

Este modelo indica que por cada gol a favor, la posición mejora en .1481 lugares; por el contrario, un gol en contra castiga más la posición y la baja en .1816 unidades. Los goles de contragolpe mejoran en .1725 unidades la posición, lo que podría beneficiar a equipos que recuperan el balón en zonas bajas y se despliegan rápidamente. Asimismo, el modelo arroja que la posición empeora en .0036 lugares por cada centro lanzado, lo cual a primer vistazo indica que este tipo de ataque no es tan eficiente. Finalmente, el modelo indica que si el equipo está participando en competencias europeas (Quedaron en el top 6 en la temporada anterior o ganaron la FA Cup o la Carabao Cup), su posición se beneficia en 2 unidades. Lo que indica que si un equipo tuvo buen rendimiento en un año, tiende a hacerlo bien al siguiente.

Ahora, este modelo sigue teniendo varias limitaciones ya que arroja resultados continuos que podrían salir del dominio. Por este motivo, se usará el modelo de regresión ordinal, el cuál arrojará la probabilidad de que cada equipo quede en cada posición de la tabla.

4.2. Regresión Ordinal

Para comparar este modelo con el de regresión múltiple se utilizaron las mismas variables para predecir la posición de la tabla: Goles a Favor, Goles en Contra, Goles de contragolpe, Centros y Participación en competencias europeas. Al observar los resultados, se puede notar que los coeficientes de las variables independientes son constantes para todas las posiciones, mientras que únicamente la ordenada al origen α_j cambia en cada ecuación. Por esta razón, el modelo se puede resumir de manera más compacta en la siguiente tabla, donde cada fila corresponde a una posición j de la tabla:

Cuadro 4.1. Parámetros de corte (α_j) del modelo de regresión ordinal

Posición	α_j
1	-10.26
2	-7.17
3	-5.19
4	-3.69
5	-2.36
6	-1.21
7	-0.06
8	1.06
9	2.03
10	2.82
11	3.56
12	4.29
13	4.99
14	5.67
15	6.34
16	7.05
17	7.29
18	9.07
19	10.80

Cuadro 4.2. Coeficientes (β) comunes del modelo de regresión ordinal

Variable	β
Goles a Favor (GaF)	-0.18
Goles en Contra (GaC)	0.19
Goles de Contragolpe	-0.11
Centros	0.003
Competencias Europeas	-1.07

Nota: Los coeficientes β son constantes para todas las posiciones debido al supuesto de proporcionalidad del modelo logit ordenado. Cada parámetro de corte α_j define el umbral específico entre las posiciones.

Nota: Los coeficientes de las variables independientes son constantes para todas las posiciones; únicamente la ordenada al origen α_j varía. Por lo tanto, la ecuación para cualquier posición j se obtiene sustituyendo el valor correspondiente de α_j en la siguiente expresión general:

$$\begin{aligned} \text{logit}(P(\text{Posición} \leq j)) = & \alpha_j - 0.18 \cdot GaF + 0.19 \cdot GaC \\ & - 0.11 \cdot GolContraGolpe + 0.003 \cdot Centros - 1.07 \cdot CompEuropeas \end{aligned} \quad (4.3)$$

Por ejemplo, para estimar la probabilidad de que un equipo quede en la posición 4 o inferior, se sustituye $\alpha_4 = -3.69$:

$$\begin{aligned} \text{logit}(P(\text{Posición} \leq 4)) = & -3.69 - 0.18 \cdot GaF + 0.19 \cdot GaC \\ & - 0.11 \cdot GolContraGolpe + 0.003 \cdot Centros - 1.07 \cdot CompEuropeas \end{aligned} \quad (4.4)$$

Al observar los coeficientes del modelo de regresión ordinal, se pueden identificar las variables con mayor influencia en la posición final de cada equipo. En primer lugar, los Goles a Favor presentan un coeficiente de $\hat{\beta} = -0.18$, lo que indica que por cada gol adicional anotado, el momio acumulado de quedar en una posición igual o peor se reduce en un factor de $e^{0.18} \approx 1.20$; es decir, anotar más goles mejora consistentemente la posición en la tabla. De manera análoga, los Goles en Contra presentan un coeficiente de $\hat{\beta} = 0.19$, lo que implica que cada gol recibido incrementa el momio de terminar en una posición peor en un factor de $e^{0.19} \approx 1.21$. Es interesante notar que el

coeficiente de los Goles en Contra es ligeramente mayor en valor absoluto que el de los Goles a Favor, lo que sugiere que la solidez defensiva tiene un peso marginalmente superior al poder ofensivo en la determinación de la posición final. Por su parte, los Goles de Contragolpe presentan un coeficiente de $\hat{\beta} = -0.11$, confirmando que este estilo de juego tiene un efecto positivo en la clasificación, lo cual es consistente con el rendimiento histórico de equipos que priorizan la organización defensiva y la transición rápida al ataque. En cuanto a los Centros, si bien el coeficiente por unidad es pequeño ($\hat{\beta} = 0.003$), el efecto acumulado a lo largo de una temporada es relevante: un equipo que lanza 100 centros adicionales multiplica su momio de terminar en una posición peor por un factor de $e^{0.3} \approx 1.35$, lo que indica que atacar predominantemente por las bandas no representa una estrategia eficiente en la Premier League. Finalmente, la Participación en Competencias Europeas es la variable con mayor magnitud en el modelo, con un coeficiente de $\hat{\beta} = -1.07$ que equivale a casi triplicar ($e^{1.07} \approx 2.92$) los momios de quedar bien posicionado. Esto se explica porque dicha variable es un proxy directo del rendimiento en la temporada anterior, reflejando que los equipos con buen desempeño reciente tienden a mantener esa tendencia en el siguiente año. Es importante recalcar que dado que la variable dependiente es la posición en el ranking (donde 1 es mejor que 20), un coeficiente negativo significa mejora en la posición.

Al evaluar el modelo se notó algo interesante, el Leicester City del 2016 que logró la hazaña de ser campeón, bajo este modelo solo tendría 0.002 % de probabilidad de quedar en primer lugar, mientras que era más factible que terminara en cuarto lugar (34.87 %). Aunque estadísticamente se esperaba un resultado muy distinto, el Leicester logró una de las mayores hazañas de la historia del deporte.

Cuadro 4.3. Coeficientes del modelo de regresión ordinal


Variable	$\hat{\beta}$	$e^{ \hat{\beta} }$	Efecto acumulado	Dirección
Goles a Favor	-0.18	1.20	+10 goles: $\times 6.05$	Mejora
Goles en Contra	+0.19	1.21	+10 goles: $\times 6.59$	Empeora
Goles de Contragolpe	-0.11	1.12	+5 goles: $\times 1.73$	Mejora
Centros	+0.003	1.00	+100 centros: $\times 1.35$	Empeora
Comp. Europeas	-1.07	2.92	Variable dummy	Mejora

Nota: Los coeficientes negativos indican mejora en la posición de la tabla (menor valor = mejor posición). $e^{|\hat{\beta}|}$ representa el cambio multiplicativo en el momio acumulado por unidad de la variable.

4.3. Simulación de partidos: Modelo de Poisson

Adicionalmente, se replicó el trabajo de Lee (1997) para la temporada 2023-2024, en la que a través de GLM se estimaron los parámetros de distribuciones Poisson independientes para estimar los goles de cada partido de la temporada y así estimar los puntos de cada equipo. Se corrieron 1,000 simulaciones de la temporada completa y se obtuvo la cantidad de puntos en cada una de ellas. Así, se estimó la probabilidad de cada equipo de finalizar la temporada en cada posición del ranking. A continuación, se pueden observar los resultados de las simulaciones, donde destaca que el Manchester City logró ser campeón, aunque la simulación predecía que lo haría el Arsenal:

Figura 4.1. Comparación de la posición simulada a través de una distribución Poisson y la posición real de la temporada 2023-2024



Para comparar los resultados de los modelos, se estimó la precisión de los modelos lineales, ordinales y de simulación de tres maneras:

- **Posición exacta:** Precisión exacta de la predicción del modelo lineal, ordinal o de simulación (Para el modelo lineal se redondea la estimación y para el ordinal y simulación se selecciona la posición con mayor probabilidad)
- **Posición ± 1 :** Precisión con margen de error de 1 posición
- **Posición ± 2 :** Precisión con margen de error de 2 posiciones

Además, el modelo ordinal se estresó para medir la posición en situaciones "normales", es decir, omitiendo las temporadas 19-20 y 20-21 debido a la pandemia. Los resultados fueron los siguientes:

Cuadro 4.4. Precisión de los modelos lineales, ordinales y simulación

Modelo	Posición exacta	Posición ± 1	Posición ± 2
Regresión Lineal	0.19	0.58	0.65
Regresión Ordinal	0.35	0.71	0.88
Regresión Ordinal (sin pandemia)	0.35	0.65	0.90
Simulación: Modelo de Poisson	0.35	0.70	0.80

Si bien la regresión lineal estuvo descartada desde un inicio al no cumplir los supuestos, los resultados muestran una mayor precisión del modelo ordinal y de simulación. La precisión exacta es de 35 % y en otros contextos puede parecer baja; sin embargo, si la comparamos con la probabilidad aleatoria de escoger la posición final, que es de 1 en 20 (5 %), se tienen 7 veces mayor probabilidad de obtener la posición exacta.

Para responder a la pregunta de cuál es la predicción de posición de cada modelo, se comparan a continuación los resultados de los tres modelos para la temporada 2023-2024. La posición predicha en cada caso se obtiene como la posición con mayor probabilidad o la estimación redondeada, según corresponda a cada modelo.

Cuadro 4.5. Comparación de posición real vs. predicha por modelo — Temporada 2023-2024

Equipo	Posición real	Reg. Lineal	Reg. Ordinal	Simulación Poisson
Manchester City	1	1	2	2
Arsenal	2	1	1	1
Liverpool	3	2	2	3
Aston Villa	4	7	6	5
Tottenham Hotspur	5	10	8	5
Chelsea	6	9	7	5
Newcastle United	7	6	5	4
Manchester United	8	9	8	8
West Ham United	9	13	12	15
Crystal Palace	10	11	9	9
Brighton	11	11	10	10
Bournemouth	12	14	13	15
Fulham	13	13	11	11
Wolverhampton	14	14	13	16
Everton	15	13	13	14
Brentford	16	13	12	11
Nottingham Forest	17	13	13	17
Luton Town	18	18	18	18
Burnley	19	18	18	19
Sheffield United	20	20	20	20
Precisión exacta	—	0.30	0.15	0.35
Precisión ± 1	—	0.60	0.60	0.70
Precisión ± 2	—	0.70	0.80	0.80

Al comparar los tres modelos para la temporada 2023-2024, se puede observar que la simulación de Poisson obtuvo la mayor precisión exacta con un 35 %, superando a la regresión lineal (30 %) y a la regresión ordinal (15 %). Sin embargo, al ampliar el margen de error a ± 1 posición, la simulación de Poisson también lidera con un 70 % de precisión, mientras que ambas regresiones alcanzan el 60 %. Con un margen de ± 2 posiciones, los tres modelos convergen: la regresión ordinal y la simulación de Poisson empatan con 80 %, y la regresión lineal alcanza 70 %. Es importante notar que los tres modelos

coinciden en predecir correctamente los extremos de la tabla: los tres primeros lugares (Manchester City, Arsenal y Liverpool) y los tres últimos (Luton Town, Burnley y Sheffield United), lo que indica que los modelos capturan bien los casos más diferenciados, pero tienen mayor dificultad para distinguir entre equipos de rendimiento similar en la zona media de la tabla.

4.4. Discriminación de dos poblaciones

Ahora, existen dos grupos de puestos en la tabla en el fútbol inglés. El top 4 es de suma importancia ya que da acceso a la UEFA Champions League. Además de ser un torneo internacional de renombre, da exposición mundial y genera ingresos adicionales y superiores al club. Asimismo, los últimos 3 lugares de la tabla son aquellos que representan el descenso, lo que genera un impacto en la imagen, moral y economía del club. Por estas razones, se harán 2 modelos: en primer lugar, para tratar de estimar si un equipo podrá quedar en el top 4; y en segundo lugar para estimar si podrá salvarse del descenso. En primer término se usarán las regresiones logísticas de Ridge y Lasso. En segundo término, se usará el método de discriminación lineal y cuadrática.

Logit

La Regresión Logística Simple es un método de regresión que permite estimar la probabilidad de una variable cualitativa binaria en función de una variable cuantitativa. Una de las principales aplicaciones de la regresión logística es la de clasificación binaria, en la que las observaciones se clasifican en un grupo u otro dependiendo del valor que tome la variable empleada como predictor. En particular, para este

trabajo se tratará de predecir si un equipo clasificará a Champions League y si se salvará del descenso. Como se mencionó previamente, se hará uso de dos subtipos de regresión logística: Lasso y Ridge.

Para cada lambda se tendrá una solución distinta, ya que esta controla el tamaño de los coeficientes. Por lo tanto, se utilizará validación cruzada para obtener la lambda que obtenga el mínimo error cuadrático medio.

Discriminantes

Además de la regresión logística, se usó un análisis discriminante para comparar diferentes métodos en los que se separan poblaciones. Se usaron discriminantes lineales y cuadráticos para tener una visión más completa sobre los resultados.

4.4.1. Champions League

Se utilizarán las variables GaF, GaC, GolContragolpe y CompetenciasEuropeas para realizar los siguientes modelos y, para medir la eficacia de los siguientes modelos, se utilizará el 70 % de la población como entrenamiento y un 30 % de prueba

Cuadro 4.6. Champions League: Precisión de los modelos de separación de poblaciones

Modelo	Precisión	Error Tipo 1	Error Tipo 2
Logit Lasso	0.16	0.83	0.00
Logit Ridge	0.14	0.86	0.00
Discriminante Lineal	0.94	0.04	0.02
Discriminante Cuadrático	0.90	0.06	0.04

Interpretación de los resultados

Regresión Logística (Lasso y Ridge): Ambos métodos de regresión logística mostraron un desempeño deficiente, con precisiones inferiores al 20 %. Esto sugiere que los modelos logísticos con penalización no capturan adecuadamente la relación entre las variables independientes y la clasificación a Champions League. La tasa de error Tipo II extremadamente alta (superior al 83 %) indica que los modelos tienden a predecir incorrectamente que los equipos NO clasificarán a Champions, cuando en realidad SÍ lo hacen. Este comportamiento puede deberse a que los datos de entrenamiento tienen un desbalance de clases o a que la relación entre predictores y la respuesta es más compleja que la que pueden capturar estos modelos.

Análisis Discriminante Lineal (LDA): El LDA demostró ser el método más efectivo con una precisión del 94.4 %. Este modelo asume que las variables independientes siguen una distribución normal multivariada con matrices de covarianza iguales entre clases. El bajo error Tipo I (1.9 %) es particularmente importante en este contexto, ya que significa que el modelo rara vez clasifica incorrectamente a equipos que NO clasificarán a Champions como si lo hicieran. Esto es crítico desde una perspectiva de riesgo, ya que un error Tipo I implicaría prepararse para una competición europea que finalmente no ocurrirá. El error Tipo II de 3.7 % indica que ocasionalmente el modelo no identifica equipos que sí clasificarán, pero esta tasa es razonablemente baja.

Análisis Discriminante Cuadrático (QDA): El QDA obtuvo una precisión del 90.7 %, menor que LDA pero aún considerablemente superior a los métodos logísticos. Al permitir matrices de covarianza diferentes para cada clase, QDA ofrece más flexibilidad. Sin embargo,

los errores ligeramente superiores a LDA (3.7 % Tipo I y 5.6 % Tipo II) sugieren que el supuesto restrictivo de LDA (covarianzas iguales) es razonablemente válido para estos datos.

Implicaciones prácticas

Desde la perspectiva de la gestión deportiva, el LDA proporciona un instrumento útil para identificar variables clave que influyen en la clasificación a Champions League. Los cinco predictores utilizados (Goles a Favor, Goles en Contra, Goles de Contragolpe, Centros y Competencias Europeas) son variables que los clubes pueden monitorear y optimizar durante la temporada.

El alto desempeño del LDA (94.4 %) sugiere que estas variables capturan adecuadamente los factores determinantes de la clasificación. Esto permite a los equipos establecer objetivos específicos: mejorar el número de goles a favor, reducir los goles en contra, y potenciar los goles de contragolpe, sabiendo que estos cambios probablemente resultarán en una mejor posición final en la tabla y mayores probabilidades de clasificación a Champions League.

Selección del modelo recomendado

Para propósitos de predicción y análisis en el contexto de este trabajo, se recomienda el uso del **Análisis Discriminante Lineal (LDA)** por las siguientes razones:

1. **Máxima precisión:** Con un 94.4 % de precisión, LDA supera significativamente a los demás métodos evaluados.
2. **Bajo error Tipo I:** La baja probabilidad de clasificar incorrectamente a equipos no clasificadores como clasificadores

(1.9%) es crítica para evitar preparaciones innecesarias para competiciones europeas.

3. **Interpretabilidad:** Las fronteras de decisión lineales son más fáciles de interpretar y comunicar a stakeholders no técnicos.
4. **Robustez:** El desempeño consistentemente alto sugiere que el modelo es robusto y generalizará bien a nuevos datos.

Análisis de una temporada

Adicionalmente, a continuación se presentan las predicciones de cada modelo para la temporada 2023-2024, donde el valor 1 indica que el modelo predijo que el equipo clasificaría a la UEFA Champions League y el valor 0 indica lo contrario.

Cuadro 4.7. Predicción de clasificación a Champions League
— Temporada 2023-2024

Equipo	Real	Logit Lasso	Logit Ridge	Disc. Lineal	Disc. Cuadrático
Manchester City	1	1	1	1	1
Arsenal	1	1	1	1	1
Liverpool	1	1	1	1	1
Aston Villa	1	0	0	0	0
Tottenham Hotspur	0	0	0	0	0
Chelsea	0	0	0	0	0
Newcastle United	0	0	0	1	0
Manchester United	0	0	0	0	0
West Ham United	0	0	0	0	0
Crystal Palace	0	0	0	0	0
Brighton	0	0	0	0	0
Bournemouth	0	0	0	0	0
Fulham	0	0	0	0	0
Wolverhampton	0	0	0	0	0
Everton	0	0	0	0	0
Brentford	0	0	0	0	0
Nottingham Forest	0	0	0	0	0
Luton Town	0	0	0	0	0
Burnley	0	0	0	0	0
Sheffield United	0	0	0	0	0
Precisión	—	0.95	0.95	0.90	0.95

Al observar los resultados para la temporada 2023-2024, se puede notar que los modelos de Logit Lasso, Logit Ridge y el Discriminante Cuadrático obtuvieron la mayor precisión con un 95 %, mientras que el Discriminante Lineal alcanzó un 90 %. El único error común a todos los modelos fue el caso de Aston Villa, que logró clasificarse a la Champions League en cuarto lugar pero ningún modelo lo predijo correctamente, lo que se explica porque esta temporada representó un rendimiento histórico del equipo, muy por encima de su desempeño en temporadas anteriores. Adicionalmente, el Discriminante Lineal cometió un error adicional al predecir que Newcastle United clasificaría, cuando en realidad terminó en séptima posición. Es

importante notar que los tres equipos clasificados de manera más esperada (Manchester City, Arsenal y Liverpool) fueron identificados correctamente por todos los modelos, lo que indica que los modelos capturan bien los casos más diferenciados.

4.4.2. Descenso

Se utilizarán las mismas variables y porcentajes de prueba que en el ejercicio de clasificación a Champions League

Cuadro 4.8. Descenso: Precisión de los modelos de separación de poblaciones

Modelo	Precisión	Error Tipo 1	Error Tipo 2
Logit Lasso	0.83	0.16	0.00
Logit Ridge	0.83	0.16	0.00
Discriminante Lineal	0.89	0.09	0.02
Discriminante Cuadrático	0.89	0.09	0.02

Interpretación de los resultados

Regresión Logística (Lasso y Ridge): Ambos métodos mostraron un desempeño significativamente mejor en la predicción de descenso (83.3%) comparado con su desempeño en la predicción de Champions League. Esto sugiere que la relación entre las variables predictivas y el riesgo de descenso es mejor capturada por modelos logísticos. Ambos métodos presentaron un error Tipo I de 16.6 %, lo que significa que ocasionalmente predicen que un equipo descenderá cuando en realidad no lo hará. Sin embargo, el error Tipo II es 0 %, indicando que el modelo nunca falla en identificar equipos que realmente descienden, lo cual es la situación ideal para este caso de uso

donde es crítico no subestimar el riesgo de descenso.

Análisis Discriminante Lineal y Cuadrático: Tanto LDA como QDA obtuvieron una precisión idéntica del 88.9 %, ligeramente superior a los métodos logísticos. Es notable que ambos métodos discriminantes tengan el mismo desempeño, sugiriendo nuevamente que el supuesto de covarianzas iguales es razonablemente válido. El error Tipo I de 9.2 % es inferior al de los métodos logísticos, indicando una mejor capacidad para evitar falsas alarmas sobre descenso. El error Tipo II de 1.9 % es muy bajo, lo que garantiza que raramente se pierda la identificación de equipos en riesgo real de descenso.

Implicaciones prácticas

A diferencia del caso de Champions League, donde es importante evitar falsas predicciones de clasificación, en el caso del descenso es más crítico no subestimar el riesgo. En este contexto, los métodos que minimicen el error Tipo II (falsos negativos en riesgo de descenso) son preferibles, incluso si ello implica un error Tipo I más alto.

Los resultados muestran que todos los modelos evaluados tienen error Tipo II muy bajo (entre 0 % y 1.9 %), lo que indica que son razonablemente efectivos en identificar equipos que realmente están en riesgo de descenso. Esto es particularmente importante porque permite a los equipos implementar medidas correctivas a tiempo.

El conjunto de variables utilizadas (Goles a Favor, Goles en Contra, Goles de Contragolpe y Centros) proporciona un buen indicador del desempeño general de un equipo. Un equipo que mantiene altos números de goles a favor, bajos de goles en contra, y consistencia en sus tácticas de contragolpe, tiene una probabilidad muy baja de descender.

Selección del modelo recomendado

Para propósitos de predicción de descenso, se recomienda el uso de **Análisis Discriminante Lineal o Cuadrático**, con LDA como primera opción por su simplicidad, bajo costo computacional e interpretabilidad:

1. **Balance entre errores:** Con 88.9% de precisión, LDA proporciona un buen balance entre evitar falsas alarmas (Error Tipo I de 9.2%) y no perder equipos realmente en riesgo (Error Tipo II de 1.9%).
2. **Minimización del Error Tipo II:** El error Tipo II extremadamente bajo garantiza que los equipos en riesgo real serán identificados.
3. **Aplicabilidad práctica:** Las variables utilizadas son monitoreables durante la temporada, permitiendo intervenciones proactivas.
4. **Consistencia:** El desempeño similar de LDA y QDA sugiere estabilidad del modelo ante cambios en los datos.

Análisis de una temporada

De manera análoga, a continuación se presentan las predicciones de cada modelo para identificar los equipos que descenderían a la Championship al final de la temporada 2023-2024, donde el valor 1 indica que el modelo predijo descenso y el valor 0 indica permanencia.

Cuadro 4.9. Predicción de descenso — Temporada 2023-2024

Equipo	Real	Logit Lasso	Logit Ridge	Disc. Lineal	Disc. Cuadrático
Manchester City	0	0	0	0	0
Arsenal	0	0	0	0	0
Liverpool	0	0	0	0	0
Aston Villa	0	0	0	0	0
Tottenham Hotspur	0	0	0	0	0
Chelsea	0	0	0	0	0
Newcastle United	0	0	0	0	0
Manchester United	0	0	0	0	0
West Ham United	0	0	0	0	0
Crystal Palace	0	0	0	0	0
Brighton	0	0	0	0	0
Bournemouth	0	0	0	0	0
Fulham	0	0	0	0	0
Wolverhampton	0	0	0	0	0
Everton	0	0	0	0	0
Brentford	0	0	0	0	0
Nottingham Forest	0	0	0	0	0
Luton Town	1	0	0	1	0
Burnley	1	1	1	1	1
Sheffield United	1	1	1	1	1
Precisión	—	0.95	0.95	1.00	0.95

Para la predicción del descenso, el Discriminante Lineal obtuvo una precisión perfecta del 100 %, identificando correctamente a los tres equipos que descendieron: Luton Town, Burnley y Sheffield United. Los modelos de Logit Lasso, Logit Ridge y el Discriminante Cuadrático alcanzaron una precisión del 95 %, fallando únicamente en el caso de Luton Town, que fue el equipo que más cerca estuvo de salvarse al terminar en el decimoctavo lugar con una diferencia de goles de -33 . Es importante notar que Burnley y Sheffield United fueron identificados como equipos en descenso por todos los modelos, lo que indica que su rendimiento a lo largo de la temporada los diferenciaba claramente del resto de la liga. En general, los resultados muestran que los modelos de discriminación son más precisos para

predecir el descenso que la clasificación a Champions League, lo que se explica porque los equipos que descienden suelen tener características deportivas más diferenciadas del resto de la tabla.

4.4.3. Importancia de variables en modelos de clasificación

Para entender qué variables contribuyen más a las predicciones de cada modelo de clasificación, se realizó un análisis de importancia utilizando SHAP values para modelos lineales con penalización (Logit Lasso y Ridge) y análisis de permutación para modelos discriminantes (LDA y QDA).

Importancia de variables - Clasificación a Champions League

Cuadro 4.10. Importancia de variables - Modelos de clasificación Champions League

Variable	Logit Lasso	Logit Ridge	LDA	QDA	Promedio
CompetenciasEuropeas	1.000	1.000	0.286	0.333	0.655
GaC	0.075	0.046	1.000	1.000	0.530
GaF	0.055	0.034	0.714	0.667	0.368
Centros	0.000	0.002	0.143	0.333	0.120
GolContragolpe	0.108	0.108	0.143	-0.167	0.048

Análisis Champions League:

El análisis de importancia de variables para clasificación a Champions League muestra diferencias notables entre modelos lineales y discriminantes:

Competencias Europeas (Promedio: 0.655): Es la variable más importante en modelos con penalización (Lasso y Ridge con valor

1.000), indicando que haber participado en competiciones europeas en la temporada anterior es un predictor lineal muy fuerte de clasificación posterior. Sin embargo, LDA y QDA le asignan menor importancia relativa (0.286-0.333), sugiriendo que estos modelos capturan información adicional mediante efectos no lineales.

Goles en Contra (Promedio: 0.530): Presenta un patrón inverso. Tiene baja importancia en modelos lineales (0.046-0.075) pero importancia máxima en modelos discriminantes (1.000). Esto indica que la relación entre defensa y clasificación a Champions es principalmente no lineal, capturada de manera más efectiva por LDA y QDA. Una defensa sólida es fundamental, y su impacto no es simplemente proporcional a los goles concedidos.

Goles a Favor (Promedio: 0.368): Tiene importancia moderada en LDA/QDA (0.667-0.714) pero muy baja en modelos lineales (0.034-0.055), sugiriendo que la capacidad ofensiva es menos determinante que otros factores cuando se consideran efectos lineales.

Centros y Goles de Contragolpe: Ambas variables tienen importancia baja (0.120 y 0.048 respectivamente), confirmando que tácticas específicas como centros o contragolpes son menos determinantes que factores defensivos globales.

Importancia de variables - Riesgo de Descenso

Cuadro 4.11. Importancia de variables - Modelos de clasificación Riesgo de Descenso

Variable	Logit Lasso	Logit Ridge	LDA	QDA	Promedio
GaC	0.775	0.102	1.000	1.000	0.719
GaF	1.000	0.099	0.750	0.667	0.629
CompetenciasEuropeas	0.000	1.000	0.000	0.333	0.333
GolContragolpe	0.942	0.312	0.500	-0.167	0.397
Centros	0.004	0.004	0.000	0.333	0.085

Análisis de Descenso:

Para predecir riesgo de descenso, el patrón de importancia es más homogéneo entre modelos, con diferencias notables respecto a Champions League:

Goles en Contra (Promedio: 0.719): Es el predictor más importante de descenso. Tiene importancia muy alta en Logit Lasso (0.775) e importancia máxima en LDA/QDA (1.000). Esto refleja que una defensa débil es el factor más determinante del riesgo de descenso, consistente en todos los enfoques modeladores.

Goles a Favor (Promedio: 0.629): La segunda variable más importante, con máxima importancia en Logit Lasso (1.000) y alta en LDA/QDA (0.667-0.750). Equipos con baja capacidad ofensiva tienen dificultad para acumular puntos suficientes y evitar el descenso.

Goles de Contragolpe (Promedio: 0.397): Tiene importancia moderada a alta, especialmente en Logit Lasso (0.942), sugiriendo que equipos con defensas débiles que además se enfocan en anotar goles de contragolpe enfrentan mayor riesgo de descenso.

Competencias Europeas (Promedio: 0.333): Tiene

importancia moderada pero altamente variable entre modelos (0 en Lasso y LDA, 1.0 en Ridge, 0.333 en QDA), indicando una relación menos clara con el descenso que en Champions League.

Centros (Promedio: 0.085): Es prácticamente irrelevante para predecir descenso, confirmando que el volumen de centros no es un factor determinante del riesgo en ningún modelo.

Comparación entre Champions League y Descenso

Las diferencias en el ranking de importancia entre ambos objetivos son significativas:

Cuadro 4.12. Ranking de importancia: Champions vs. Descenso

Ranking	Champions League	Descenso
1º	CompetenciasEuropeas (0.655)	GaC (0.719)
2º	GaC (0.530)	GaF (0.629)
3º	GaF (0.368)	GolContragolpe (0.397)
4º	Centros (0.120)	CompetenciasEuropeas (0.333)
5º	GolContragolpe (0.048)	Centros (0.085)

Esta comparación revela que mientras la clasificación a Champions League está impulsada principalmente por continuidad y experiencia (Competencias Europeas), evitar el descenso depende más de factores defensivos y ofensivos puros (Goles en Contra y Goles a Favor). Esto sugiere estrategias diferentes según el objetivo del equipo.

Validación de selección de variables

El análisis de importancia confirma la relevancia de todas las variables seleccionadas. Aunque Centros tiene baja importancia en

ambos casos, su inclusión no compromete la precisión de los modelos y permite capturar estilos de juego diversos. Las variables principales (CompetenciasEuropeas, GaC, GaF) muestran importancia consistentemente alta, validando su utilidad predictiva.

Capítulo 5

Conclusiones

Las variables que demuestran un mayor impacto en la estimación de los resultados de un equipo son los Goles a Favor, los Goles en Contra, Goles de Contragolpe, Centros y la Participación en Competencias Europeas. Al observar los coeficientes en los modelos lineales y ordinales se puede llegar a las siguientes conclusiones:

- **Goles a Favor:** al tener una relación importante con los partidos ganados, mientras más goles anotados tenga un equipo, su posición en la tabla mejora.
- **Goles en Contra:** de manera totalmente contraria a los Goles a Favor, mientras más goles encajados tenga un equipo, su posición en la tabla empeora. Es importante notar que el coeficiente de los Goles en Contra es ligeramente mayor en valor absoluto que el de los Goles a Favor, lo que indica que la solidez defensiva tiene un peso marginalmente superior al poder ofensivo en la determinación de la posición final.
- **Goles de Contragolpe:** en los modelos, existe una relación

positiva entre los goles por contragolpe y la posición en la tabla. Es decir, los equipos que juegan al contragolpe suelen beneficiarse. Este tipo de equipos suele jugar defensivamente, recuperar el balón y desplegarse rápidamente hacia adelante. Por lo que equipos que busquen mejorar su posición o evitar el descenso podrían optar por estilos de juego defensivos, cediendo la pelota al rival y esperándolos en campo propio para robar el balón y atacar mientras el rival se encuentra desordenado defensivamente.

- **Centros:** la cantidad de centros tiene un impacto negativo en la posición de los equipos en la tabla, esto quiere decir que equipos que suelen atacar por las bandas y mandar pases elevados al área suelen tener un rendimiento menor. Si bien los centros se asocian a un estilo de juego ofensivo, este tipo de pases tiene una probabilidad baja de éxito, pues pueden ser robados fácilmente o llegar de manera incómoda a su destinatario. Además, el centro fallido se puede asociar con un contragolpe del equipo contrario.
- **Participación en Competencias Europeas:** la participación en competencias europeas es un indicador directo del rendimiento en el año previo, pues para jugar competencias europeas los equipos debieron de finalizar la temporada previa en la parte superior de la tabla. Por lo que si el rendimiento del equipo es bueno en un año, es esperado que su rendimiento al siguiente año siga esa tendencia.

Estos resultados pueden explicar por qué los equipos de Guardiola que suelen mantener la posesión del balón y evitar pases riesgosos suelen tener resultados positivos, o por qué en el pasado entrenadores como

Mourinho o Tuchel tuvieron éxito con el Chelsea al mantener un estilo de juego de contragolpe. También es interesante ver cómo en años recientes, el Brentford de Thomas Frank logró mantener la categoría con una plantilla modesta al adaptarse al juego del rival y utilizar el contragolpe o la posesión del balón según se desarrollaran los juegos.

Ventajas y desventajas de cada modelo

A lo largo del trabajo se utilizaron cinco enfoques de modelación con objetivos y alcances distintos. A continuación se describen las principales ventajas y desventajas de cada uno, considerando tanto los resultados sobre el período completo de datos (temporadas 2015-2016 a 2023-2024) como los resultados específicos para la temporada 2023-2024:

Regresión Lineal. La principal ventaja de este modelo es su facilidad de interpretación: los coeficientes indican directamente cuánto mejora o empeora la posición ante un cambio unitario en cada variable, lo que lo convierte en un buen punto de partida para entender qué variables son relevantes. Sin embargo, su mayor limitación es que trata la posición como una variable continua cuando en realidad es entera y acotada entre 1 y 20, lo que puede generar predicciones fuera del dominio. Esto se refleja en sus resultados sobre el período completo, donde obtuvo la precisión exacta más baja de los tres modelos de posición con 19 %, una precisión de 58 % con margen ± 1 y de 65 % con margen ± 2 . Para la temporada 2023-2024 mejoró a 30 % de precisión exacta, lo que sugiere que su desempeño es variable entre temporadas.

Regresión Ordinal. Este modelo respeta la naturaleza de la variable dependiente al tratarla como ordinal y acotada, y ofrece una ventaja adicional al generar probabilidades para cada posición, lo que permite cuantificar la incertidumbre en la predicción. Sobre el período

completo, la regresión ordinal obtuvo la mayor precisión exacta de los tres modelos de posición con 35 %, una precisión de 71 % con margen ± 1 y de 88 % con margen ± 2 , siendo este último el mejor resultado de todos los modelos evaluados. Estos resultados son consistentes con los de la temporada 2023-2024, donde alcanzó 80 % de precisión con margen ± 2 , lo que lo convierte en el modelo más robusto para la planeación de temporada. No obstante, su interpretación es más compleja que la del modelo lineal, particularmente por el signo negativo del predictor lineal, y su precisión exacta para la temporada 2023-2024 fue la más baja de los tres modelos de posición (15 %), lo que indica que tiende a ser más conservador en sus predicciones puntuales.

Simulación de Poisson. Sobre el período completo, este modelo empató con la regresión ordinal en precisión exacta (35 %) y obtuvo 70 % con margen ± 1 y 80 % con margen ± 2 . Para la temporada 2023-2024 mantuvo esa consistencia al obtener la mayor precisión exacta entre los modelos (35 %) y la mejor precisión con margen ± 1 (70 %). Su principal ventaja es que replica el proceso real de la temporada simulando cada partido de manera independiente, lo que permite generar distribuciones completas de probabilidad por posición y no solo una estimación puntual. Sin embargo, es el modelo computacionalmente más costoso al requerir 1,000 simulaciones de temporada completa, y tiene la limitación de utilizar únicamente datos de goles, dejando de lado variables extracancha como el valor de la plantilla o el gasto en transferencias. Asimismo, asume que los parámetros de ataque y defensa de cada equipo son estables a lo largo de toda la temporada, sin considerar el efecto de lesiones o cambios de forma.

Discriminantes Lineal y Cuadrático. Para las preguntas

binarias de clasificación a Champions League y descenso, los discriminantes fueron los modelos más precisos. Sobre el período completo de datos, el Discriminante Lineal obtuvo una precisión del 94 % para Champions League y del 89 % para descenso, superando en ambos casos a los modelos de Logit Lasso y Ridge. Para la temporada 2023-2024, el Discriminante Lineal logró una precisión perfecta del 100 % en la predicción del descenso, identificando correctamente a Luton Town, Burnley y Sheffield United, y un 90 % en Champions League. Su ventaja principal es que maximiza la separación entre grupos, lo que resulta especialmente efectivo cuando los equipos en zonas extremas de la tabla tienen características claramente diferenciadas del resto. La desventaja de ambos modelos es que únicamente responden preguntas binarias y no predicen la posición exacta, por lo que su alcance es más limitado que el de los modelos de regresión.

Logit Lasso y Ridge. Estos modelos ofrecen la ventaja de manejar la multicolinealidad entre variables independientes de manera automática y, en el caso de Lasso, darle peso solo a las variables más relevantes. Sin embargo, sobre el período completo de datos obtuvieron los resultados más bajos para la clasificación a Champions League, con una precisión de 16 % para Lasso y 14 % para Ridge, muy por debajo de los discriminantes. Para descenso su desempeño mejoró al 83 % en ambos casos, aunque sin superar a los discriminantes. Para la temporada 2023-2024 alcanzaron 95 % de precisión tanto en Champions como en descenso, fallando únicamente en Aston Villa, cuya temporada histórica ningún modelo anticipó dado que su rendimiento estaba muy por encima de su historial previo.

¿Cuándo se contradicen los modelos, cuál es mejor?

A lo largo del análisis se observaron casos en los que los modelos arrojaron predicciones distintas para un mismo equipo. La regla general para resolverlo es que el modelo más específico para la pregunta planteada es el que debe prevalecer. Si la pregunta es cuál será la posición exacta de un equipo al final de la temporada, la simulación de Poisson es la más adecuada al ser la más precisa en esa métrica. Si la pregunta es si un equipo clasificará a Champions League o descenderá, los discriminantes lineales y cuadráticos son los más confiables al estar diseñados específicamente para separar poblaciones.

Sin embargo, es importante reconocer que cuando un equipo tiene una temporada atípica, como fue el caso de Aston Villa en 2023-2024 o del Leicester City en 2015-2016, ningún modelo basado en patrones históricos logrará anticiparlo correctamente. En estos casos todos los modelos tienden a converger en una predicción incorrecta, lo que indica que la variabilidad inherente del fútbol representa un límite natural para cualquier enfoque estadístico. Esto no invalida los modelos, sino que reafirma que su mayor utilidad está en capturar tendencias generales y no en predecir hazañas históricas.

Precisión de los modelos y usos principales

Hablando de los modelos estadísticos, el modelo ordinal y la simulación (Modelo de Poisson) mostraron ser una herramienta útil para identificar en qué posición podría quedar cada equipo según su rendimiento, incrementando la probabilidad de encontrar la posición exacta de 5 % (en un caso aleatorio) a 35 %, además de una precisión

de 70–71 % al estimar la posición con un margen de error de 1 lugar y de 80–88 % con un margen de error de 2 lugares, sobresaliendo ligeramente el modelo ordinal en esta última comparación. Por lo que, se identifican 2 usos principales:

- **Uso deportivo:** a lo largo de la temporada, cada equipo podría estimar sus resultados finales y así poder planear las ventanas de transferencias o el estilo de juego por el que pueden optar.
- **Apuestas:** se puede apalancar el modelo para estimar la posición exacta al final de la temporada y realizar apuestas en caso de que la casa de apuestas arroje un precio mejor al compararlo con la probabilidad del modelo.

Asimismo, si se habla de los modelos de discriminación de poblaciones, tanto en la clasificación a Champions League o la salvación del descenso, el Discriminante Lineal mostró el mejor rendimiento, teniendo una precisión superior al 89 % en el conjunto de prueba histórico y de 100 % para el descenso en la temporada 2023-2024. Asimismo, el Discriminante Cuadrático tuvo resultados cercanos. Por lo que los equipos que buscan salvarse del descenso o entrar a competencias europeas podrían apalancar el modelo propuesto para establecer objetivos de rendimiento en las variables más significativas. Asimismo, el ejercicio podría llevarse a otras ligas con datos disponibles como la española, alemana o italiana, o a ligas con mayor variabilidad año tras año como la mexicana, donde la imprevisibilidad del torneo haría especialmente interesante evaluar qué tan bien se sostienen estos modelos.

Apéndice A

Código R

El código, base de datos y resultados se pueden encontrar en el siguiente repositorio público en Github:
<https://github.com/ricardomebri/La-regresi-n-ordinal-y-discriminantes-poblacionales-como-m-odos-de-predicci-n-en-la-Premier-League>

Referencias

- Montgomery, D. C., Peck, E. A., Vining, G. G. 2012. «Introduction to Linear Regression Analysis» (5th ed.). Wiley.
- Kutner, M. H., Nachtsheim, C. J., Neter, J. 2004. «Applied Linear Statistical Models» (5th ed.). McGraw-Hill/Irwin.
- Johnson, V. E., Albert, J. H. 1999 «Ordinal Data Modeling» (1st ed.). Springer.
- Johnson, R, A., Wichern D. W. 2014. «Applied Multivariate Statistical Analysis» (6th ed.). Pearson Education Limited
- Tibshirani, R. 1996. «Regression Shrinkage and Selection Via the Lasso», *Journal of the Royal Statistical Society: Series B (Methodological)* 58 (1): 267-288
- Hoerl, A. E., Kennard, R. W. 1970. «Ridge Regression: Biased Estimation for Nonorthogonal Problems». *Technometrics*, 12(1), 55-67
- Hastie, T., Tibshirani, R., Friedman, J. 2009. «The Elements of Statistical Learning» (2nd ed.). Springer.

Lee, A. 1997. «Modeling Scores in the Premier League: Is Manchester United Really the Best?» Taylor & Francis.

*La regresión ordinal y discriminantes
poblacionales como métodos de
predicción del rendimiento en la Premier League*
escrito por Ricardo Odilón Méndez Bribiesca,
se terminó de imprimir el XXXX de 2026
en XXXXXXXX.
XXXXX XXXx, colonia XXXXX,
Ciudad de México.