

INSTITUTO TECNOLÓGICO AUTÓNOMO DE MÉXICO



**Métodos de predicción aplicados al
rendimiento de la Premier League**

TESIS

QUE PARA OBTENER EL TÍTULO DE

LICENCIADO EN ACTUARÍA /
MATEMÁTICAS APLICADAS

PRESENTA

RICARDO ODILÓN MÉNDEZ BRIBIESCA

ASESORA

JORGE FRANCISCO DE LA VEGA GÓNGORA

«Con fundamento en los artículos 21 y 27 de la Ley Federal del Derecho de Autor y como titular de los derechos moral y patrimonial de la obra titulada “**Métodos de predicción aplicados al rendimiento de la Premier League**”, otorgo de manera gratuita y permanente al Instituto Tecnológico Autónomo de México y a la Biblioteca Raúl Baillères Jr., la autorización para que fijen la obra en cualquier medio, incluido el electrónico, y la divulguen entre sus usuarios, profesores, estudiantes o terceras personas, sin que pueda percibir por tal divulgación una contraprestación.»

FECHA

RICARDO ODILÓN MÉNDEZ BRIBIESCA

*A mis padres,
por su esfuerzo.*

Agradecimientos

El siguiente trabajo está dedicado a mi familia, amigos, profesores y compañeros que me han acompañado a lo largo de mi vida y que me han permitido desarrollar dos de mis mayores gustos: fútbol y matemáticas.

A mi mamá por apoyarme a lo largo de mi vida y a mi papá por escucharme y ver tantos partidos de fútbol conmigo. A mi hermana Bere por regalarme mi primera playera del Tottenham y acercarme a este gran equipo. A mi hermana Sofía por apoyarme en momentos estresantes de la carrera. A mis cuñados Rafa y Daniel por las pláticas de la liga inglesa y a mi sobrino Rafita por traer alegría a la familia. A Barbie por motivarme y darme consejos para LaTeX.

A Rodri por ser de mis mejores amigos y darme tan buenas ideas para este trabajo. A Sebas por las risas durante la pandemia y la carrera. A todos los grandes amigos que fui haciendo durante el camino: Caraveo, Regina, Polo, Dodo, Sou, Sop, Ale, Parente, Lomelí y Monse.

A todos los profesores y profesoras que tuve el gusto de conocer durante mi tiempo en el ITAM.

Finalmente, a Jorge Francisco de la Vega Góngora por su apoyo y dedicación para poder desarrollar este trabajo.

Resumen

La presente tesis consiste en estudiar potenciales factores que influyen en el rendimiento de un equipo de la primera división inglesa de fútbol. Estos factores incluirán variables deportivas como goles, pases, intercepciones, lesiones y no deportivas como traspasos, inversión financiera, asistencia al estadio, etc. Estas características y variables permitirán llevar a cabo simulaciones realistas de temporadas completas y determinar resultados de interés: en primer lugar, el ranking de cada equipo; en segundo lugar, si cada equipo se clasifica a la UEFA Champions League y en tercer lugar, si cada equipo descenderá a la segunda división.

La información utilizada incluye bases de datos desde la temporada 2015-2016 hasta la temporada 2023-2024 de todos los equipos que participaron en la Premier League durante esos años. Se exploraron los datos para entender qué variables podrían tener mayor relevancia y así abordar el problema con una variedad de modelos con la finalidad de predecir la posición de cada equipo basada en las variables que resultaron más significativas.

La Premier League fue la competencia elegida para este trabajo por

ser de las ligas más competitivas y de las más vistosas de fútbol profesional. Como resultado colateral, se pudo consolidar una base de datos que contiene datos deportivos y extradeportivos, ya que no fue posible encontrar una base de datos única que incluyera todas las variables consideradas en la investigación. En el futuro, podría ser interesante extender un análisis similar a otro tipo de ligas de fútbol, como la Liga MX, y tratar de encontrar un modelo adecuado que, como aficionado, es difícil de imaginar.

Índice general

Introducción	1
1. Contexto	3
1.1. El fútbol	3
1.2. La liga inglesa	4
1.3. Planteamiento del problema a resolver	5
2. Metodología	7
2.1. Regresión lineal múltiple	7
2.1.1. Modelo	7
2.1.2. Selección de variables	9
2.1.3. Estimación	9
2.1.4. Inferencia	11
2.1.5. Validación	13
2.1.6. Distancias de Cook	14
2.1.7. Normalidad de los residuales	14
2.1.8. Homoscedasticidad e independencia de los residuales	15
2.1.9. Métodos de penalización: Lasso, Ridge y Elastic Net	16
2.2. Regresión Logit	18

2.2.1.	Modelo Logit	18
2.2.2.	Regresión Logit con penalización Lasso	19
2.2.3.	Regresión Logit con penalización Ridge	20
2.2.4.	Validación y diagnósticos en regresión logística	20
2.2.5.	Selección automática de variables mediante penalización: Lasso y Ridge	23
2.3.	Regresión ordinal	28
2.3.1.	Modelo	28
2.3.2.	Estimación	30
2.3.3.	Inferencia	32
2.3.4.	Validación	34
2.3.5.	Verificación del supuesto de proporcionalidad	35
2.3.6.	Diagnósticos en regresión ordinal	36
2.3.7.	Bondad de ajuste y evaluación del modelo	38
2.3.8.	Métodos de penalización en regresión ordinal	39
2.3.9.	Selección de variables en regresión ordinal	40
2.4.	Simulación de partidos: Modelo de Poisson	44
2.4.1.	Modelo	44
2.4.2.	Limitación de selección de variables en modelo de Poisson	48
2.5.	Análisis discriminante	49
2.5.1.	Análisis discriminante lineal (LDA)	50
2.5.2.	Análisis discriminante cuadrático (QDA)	51
2.5.3.	Ventajas y desventajas de LDA y QDA	51
2.5.4.	Importancia de variables en análisis discriminante: SHAP	52
3.	Bases de datos y análisis exploratorio de datos	58
3.1.	Creación de base de datos	58

3.2.	Análisis exploratorio de datos	64
3.2.1.	Desempeño en el campo de juego	64
3.2.2.	Correlación	68
3.2.3.	Características extra cancha	69
3.2.4.	Síntesis del análisis exploratorio y selección de variables para modelado	70
4.	Análisis y modelos de la Premier League	73
4.1.	Regresión Lineal	73
4.1.1.	Modelo univariado	74
4.1.2.	Modelo múltiple completo	74
4.1.3.	Selección automática de modelo con AIC	75
4.1.4.	Interpretación del modelo final	76
4.1.5.	Precisión del modelo en test set	78
4.2.	Regresión Ordinal	79
4.2.1.	Motivación y enfoque	79
4.2.2.	Procedimiento de selección de variables	79
4.2.3.	Parámetros del modelo	79
4.2.4.	Ecuación general del modelo	80
4.2.5.	Interpretación de coeficientes	81
4.2.6.	Verificación del supuesto de proporcionalidad	82
4.2.7.	Precisión del modelo en test set	82
4.2.8.	Caso ilustrativo: Leicester City 2016	83
4.3.	Simulación de partidos: Modelo de Poisson	83
4.3.1.	Enfoque metodológico	83
4.3.2.	Parámetros estimados	84
4.3.3.	Resultados de simulación	84
4.3.4.	Precisión del modelo	85
4.3.5.	Comparación con modelos de regresión	86

4.3.6. Interpretación	87
4.4. Discriminación de dos poblaciones: Clasificación a Champions League y Descenso	87
4.4.1. Motivación	87
4.4.2. Clasificación a Champions League	88
4.4.3. Predicción de Descenso	93
5. Conclusiones	100
A. Código R	107
Referencias	109

Índice de cuadros

2.1. Comparación de Ridge y Lasso para regresión logística .	27
2.2. Frecuencias observadas de goles: local vs. visitante (2023-2024)	47
3.1. Desempeño en el campo de juego	59
3.2. Desempeño en el ranking	60
3.3. Características extra cancha	61
3.4. Desempeño en el campo de juego: Leicester City 2015-2016	62
3.5. Características de ranking: Leicester City 2015-2016 . .	63
3.6. Características extra cancha: Leicester City 2015-2016 .	63
4.1. Comparación de coeficientes: modelo completo vs. modelo final (selección AIC)	75
4.2. Precisión del modelo de Regresión Lineal en test set . .	78
4.3. Parámetros de corte (α_j) del modelo de regresión ordinal	80
4.4. Coeficientes (β) del modelo de regresión ordinal	80
4.5. Precisión del modelo de Regresión Ordinal en test set .	82
4.6. Posición real vs. simulada (Poisson) — Temporada 2023-2024	85
4.7. Precisión del modelo Poisson en test set	86
4.8. Comparación de precisión: Lineal vs. Ordinal vs. Poisson	86

4.9. Precisión de modelos para clasificación a Champions League	89
4.10. Coeficientes Lasso para predicción de Champions League	90
4.11. Predicción de Champions League 2023-2024 — Todos los modelos	92
4.12. Precisión de modelos para predicción de descenso	95
4.13. Coeficientes Lasso para predicción de descenso	95
4.14. Comparación de modelos: Champions vs. Descenso . . .	96
4.15. Predicción de Descenso 2023-2024 — Todos los modelos	98

Índice de figuras

3.1. Diferencia de goles (goles a favor menos goles en contra) promedio por la posición de la tabla	65
3.2. Tiros a gol	66
3.3. Goles a favor	67
3.4. Diferencia de goles	67
3.5. Correlación	68
3.6. Relación entre valor promedio (millones de dólares estadounidenses) de jugadores y posición en la tabla . .	69

Introducción

Disertación

La motivación para realizar este trabajo es poder combinar mi afición por el fútbol inglés y mi gusto por la estadística, y así realizar un análisis que pueda determinar qué factores pueden influir en el rendimiento de un equipo durante una temporada futbolística. Se aplicarán métodos vistos durante las materias de la carrera para hacer un análisis exploratorio de datos, regresiones lineales, regresiones logarítmicas y discriminantes lineales y cuadráticos. Asimismo, se utilizará el modelo de regresión ordinal, que es un método no visto en las clases regulares.

La Premier League es de las ligas de fútbol más populares en el mundo. Su método de clasificación para torneos internacionales, para ascender/descender y, en general su competitividad, son los principales motivos por los que he decidido realizar este análisis y, así, entender mejor qué variables influyen en el rendimiento de cada equipo.

El trabajo consta de 5 capítulos: el primero contextualizará sobre el fútbol inglés, su método de clasificación y el problema a resolver; el

segundo capítulo hablará de algunos modelos estadísticos que pueden utilizarse para resolver el problema planteado; el tercero hablará de la base de datos a utilizarse en el análisis, cómo se definirán las variables necesarias y se hará un análisis exploratorio de datos; en el capítulo 4, se realizan los modelos pertinentes y se comparan entre sí para entender su relevancia; finalmente, en el capítulo 5, se darán las conclusiones del análisis.

Objetivo

La meta principal del trabajo es, por una parte, entender qué variables deportivas y extradeportivas influyen en el rendimiento de cada equipo para estimar la probabilidad de que se dé cierto ranqueo de la tabla de posiciones, y, por otra parte, la probabilidad de que los equipos logren clasificarse a la UEFA Champions League o mantenerse en la primera división. Para esto, se usarán los datos de las ligas desde la temporada 2015/2016 hasta la temporada 2023/2024 y métodos de comparación entre modelos para seleccionar cuáles son las variables más relevantes.

Capítulo 1

Contexto

1.1. El fútbol

El fútbol es un deporte colectivo donde dos equipos de 11 jugadores se enfrentan y, mediante diferentes estrategias y planteamientos, tratan de meter gol en la portería del equipo rival. Los jugadores pueden usar cualquier parte del cuerpo, excepto los brazos y manos. Los once jugadores de cada equipo tienen funciones diferentes: los delanteros marcan goles, los mediocampistas recuperan el balón y crean estrategias de juego, los defensas protegen la portería y los porteros evitan los goles rivales. Los partidos duran 90 minutos de tiempo regular, más tiempo de compensación si así lo considera el árbitro, y el equipo que anote más goles gana el partido. El fútbol surgió en el siglo XIX en Inglaterra y se convirtió en el deporte más popular del mundo en el siglo XX.

La Federación Internacional de Asociaciones de Fútbol (FIFA), fundada en 1904, es el organismo regulador del fútbol mundial y actualmente agrupa a 211 federaciones nacionales. La FIFA es

responsable de organizar las principales competiciones del fútbol a nivel internacional, siendo la más importante la Copa del Mundo, que se disputa cada cuatro años desde 1930. Este torneo reúne a las selecciones nacionales más competitivas del mundo y se ha convertido en el evento deportivo más prestigioso a nivel global. La Copa del Mundo se caracteriza por ser una competición de gran magnitud e impacto, tanto económico como cultural, generando una euforia sin precedentes en los países participantes y en los aficionados alrededor del planeta.

La popularidad del fútbol a nivel mundial es innegable. Estudios recientes estiman que aproximadamente 4 mil millones de personas en el mundo son aficionadas al fútbol, lo que representa más del 50 % de la población global. Durante la Copa del Mundo, el interés se concentra de manera masiva en esta competición. Es importante notar que la final del Mundial 2026 fue vista por entre 1.8 y 2.2 mil millones de espectadores a través de televisión, demostrando la capacidad del fútbol de generar audiencias masivas y reunir a aficionados de todas partes del mundo. Este fenómeno global de afición por el fútbol es especialmente relevante en competiciones como la Premier League, cuya proyección internacional la convierte en una de las ligas de fútbol profesional más vistas y analizadas a nivel mundial.

1.2. La liga inglesa

La primera división inglesa, también conocida como *Premier League*, es la máxima categoría de clubes en Inglaterra. Fundada en 1992, se separó de la Football League para incrementar el nivel de juego. La liga consta de 20 equipos que se enfrentan entre todos de local y de visita, resultando en un total de $2\binom{20}{2} = 380$ partidos a lo largo del

año. Cada partido puede resultar en victoria, empate o derrota para cada equipo, lo que otorga 3 puntos, 1 punto o 0 puntos, respectivamente. Cada jornada, estos puntos se van acumulando y determinan un ranking u ordenamiento de los equipos. En caso de que haya empate en puntos, existen criterios de desempate como la diferencia de goles, los goles anotados, las tarjetas recibidas, entre otros. Los tres últimos equipos en el ranking descienden a la Championship (segunda división) y, usualmente, los cuatro primeros se clasifican a la UEFA Champions League, la competencia de clubes más prestigiosa a nivel mundial. La Premier League se caracteriza por ser de las más competitivas a nivel mundial. Equipos como el Arsenal, Chelsea, Liverpool, Manchester City, Manchester United y Tottenham (conocidos como el “Big 6”) luchan por el título y por las posiciones para clasificar a competencias europeas. Aunque en ocasiones, equipos fuera de este grupo, como el Leicester City en la temporada 2016-2017, logran clasificarse para torneos europeos e incluso ganar el campeonato.

1.3. Planteamiento del problema a resolver

A lo largo de cada temporada, se registran estadísticas y datos de cada encuentro (goles, tiros, pases, faltas, entre otras) y extracancha (gasto en transferencia, asistencia al estadio, entre otras) que podrían relacionarse o asociarse con la posición de cada equipo en el ranking al final de la temporada. Es por esto que en este trabajo se considerarán distintos métodos para predecir la variable dependiente, que se define como la posición en el ranking o la clasificación a la Champions League o el descenso a la segunda división, a través de variables independientes o predictores (pases, goles, faltas, entre otras). Casas de

apuestas y trabajos de investigación, como *Statistical Analysis of the Effectiveness of the FIFA World Rankings* (McHale & Davies, 2007) o *Competitive Balance in National European Soccer Competitions* (Haan, 2007) han utilizado este tipo de información para desarrollar modelos de predicción y discriminación del comportamiento de los equipos para entender mejor este deporte. Por otra parte, existen otro tipo de competencias con otras estructuras diferentes a la estandar de la liga inglesa, en donde posicionar a los equipos puede ser más difícil, por ejemplo, en las ligas con round robin o knockout donde la competencia es fragmentada. En esos casos, existen otros métodos de ranqueo que no serán cubiertos en este trabajo, pero para mayor referencia se puede consultar el libro de Clive Beggs, *Soccer Analytics* (2024).

Capítulo 2

Metodología

2.1. Regresión lineal múltiple

2.1.1. Modelo

La regresión lineal múltiple estudia la construcción de modelos para explicar o representar la esperanza condicional de una variable dependiente o respuesta con respecto a un conjunto de variables independientes o predictores, $E(Y|X_1, X_2, \dots, X_p)$, asumiendo que la forma de la esperanza condicional es una función lineal en los predictores. Es decir, se utilizará el modelo de regresión lineal múltiple, como un acercamiento previo, para explicar y predecir la variable “Score” a partir de las variables predictivas (43 características observadas).

El modelo de regresión lineal múltiple se puede expresar de la siguiente forma:

$$Y = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + \dots + \beta_k X_{ik} + \varepsilon, \quad (2.1)$$

Donde:

- Y es la variable dependiente (el resultado a predecir)
- $X_{i1}, X_{i2}, \dots, X_{ik}$ son las variables independientes (factores que potencialmente se relacionan con Y)
- β_0 es la ordenada al origen (la constante que representa el valor de Y cuando todas las X_{ik} son cero)
- $\beta_1, \beta_2, \dots, \beta_k$ son los coeficientes de regresión que indican la magnitud y dirección de la influencia de cada X_{ik} sobre Y
- ε es el término de error, que captura la variabilidad en Y que no puede ser explicada por las variables independientes

Supuestos:

- Linealidad: La relación entre las variables dependiente e independientes es lineal ($y = x\beta + \epsilon$)
- Independencia: Las observaciones son independientes entre sí ($y_1, \dots, y_n$ es una muestra independiente)
- Homocedasticidad: Los errores tienen varianza constante para todos los niveles de las variables independientes ($Var(\epsilon) = \sigma^2$)
- Normalidad de los residuos: Los errores del modelo siguen una distribución normal $\epsilon \sim N(0, \sigma^2 I_n)$, donde I_n es una matriz identidad de dimensión $n \times n$.

2.1.2. Selección de variables

Se utilizará el método AIC (Criterio de Información de Akaike) para seleccionar el modelo que mejor balance tenga entre cantidad de variables y ajuste del modelo. La métrica AIC se expresa como:

$$\text{AIC} = 2k - 2\ln(\hat{L}) \quad (2.2)$$

Donde

- k es el número de parámetros estimados en el modelo
- $\hat{L}$ es el valor máximo de la verosimilitud del modelo, que mide qué tan bien ajusta los datos observados

Bajo este criterio, conforme AIC sea menor, mejor se ajusta el modelo. El procedimiento iterativo comienza con el modelo completo y remueve variables iterativamente, seleccionando aquella cuya eliminación más reduce el AIC, hasta alcanzar el mínimo global. AIC balancea la precisión del ajuste con la complejidad del modelo, penalizando la inclusión de variables adicionales de forma más suave que BIC, lo que favorece modelos con mejor poder predictivo en muestras de tamaño moderado.

2.1.3. Estimación

Para estimar el vector de coeficientes $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_k)^\top$, se utiliza el método de *Mínimos Cuadrados Ordinarios* (MCO), que consiste en encontrar los valores de $\boldsymbol{\beta}$ que minimicen la suma de cuadrados de los residuos. En notación matricial, el modelo se puede expresar como:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad (2.3)$$

Donde:

- $\mathbf{y} \in \mathbb{R}^n$ es el vector de respuestas
- $\mathbf{X} \in \mathbb{R}^{n \times (k+1)}$ es la matriz de diseño, cuya primera columna es un vector de unos
- $\boldsymbol{\beta} \in \mathbb{R}^{k+1}$ es el vector de parámetros a estimar
- $\boldsymbol{\varepsilon} \in \mathbb{R}^n$ es el vector de errores, con $\mathbb{E}[\boldsymbol{\varepsilon}] = \mathbf{0}$ y $\text{Var}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}$

La función que se busca minimizar es la suma de cuadrados de los residuos:

$$S(\boldsymbol{\beta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) = \mathbf{y}^\top \mathbf{y} - 2\boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{y} + \boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{X} \boldsymbol{\beta}. \quad (2.4)$$

Para obtener el mínimo, se calcula el gradiente de $S(\boldsymbol{\beta})$ con respecto a $\boldsymbol{\beta}$ y se iguala a cero:

$$\frac{\partial S}{\partial \boldsymbol{\beta}} = -2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X} \boldsymbol{\beta} = \mathbf{0}. \quad (2.5)$$

Esto conduce a las llamadas *ecuaciones normales*:

$$\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}. \quad (2.6)$$

Siempre que las columnas de $\mathbf{X}$ sean linealmente independientes, la matriz $\mathbf{X}^\top \mathbf{X}$ es invertible y la solución única es:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}. \quad (2.7)$$

Es importante notar que bajo los supuestos del modelo, este estimador es *insesgado*, es decir, $\mathbb{E}[\hat{\boldsymbol{\beta}}] = \boldsymbol{\beta}$, y su matriz de covarianzas es:

$$\text{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}. \quad (2.8)$$

Adicionalmente, el *Teorema de Gauss-Markov* garantiza que $\hat{\boldsymbol{\beta}}$ es el Mejor Estimador Lineal Insesgado (MELI): entre todos los estimadores lineales insesgados de $\boldsymbol{\beta}$, el estimador MCO tiene la menor varianza posible.

Dado que la varianza del error σ^2 también es desconocida, se estima a partir de los residuos del modelo $\hat{\boldsymbol{\varepsilon}} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}$ de la siguiente manera:

$$\hat{\sigma}^2 = \frac{\hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}}}{n - k - 1} = \frac{SCE}{n - k - 1}, \quad (2.9)$$

Donde $SCE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$ es la Suma de Cuadrados del Error y $n - k - 1$ son los grados de libertad del error. Este estimador también es insesgado, es decir, $\mathbb{E}[\hat{\sigma}^2] = \sigma^2$.

2.1.4. Inferencia

Una vez obtenidos los estimadores, el siguiente paso es determinar si los coeficientes del modelo son estadísticamente significativos. Para esto, se asume adicionalmente que $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$, lo que implica que:

$$\hat{\boldsymbol{\beta}} \sim \mathcal{N}\left(\boldsymbol{\beta}, \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}\right). \quad (2.10)$$

Prueba t para coeficientes individuales: Para evaluar si una variable independiente tiene un efecto significativo sobre Y , se plantea la hipótesis:

$$H_0 : \beta_j = 0 \quad \text{vs.} \quad H_1 : \beta_j \neq 0. \quad (2.11)$$

El estadístico de prueba se expresa de la siguiente manera:

$$t_j = \frac{\hat{\beta}_j}{\hat{\sigma}\sqrt{c_{jj}}}, \quad (2.12)$$

Donde c_{jj} es el j -ésimo elemento diagonal de $(\mathbf{X}^\top \mathbf{X})^{-1}$. Bajo H_0 , este estadístico sigue una distribución t_{n-k-1} , por lo que se rechaza H_0 si $|t_j| > t_{\alpha/2, n-k-1}$. De manera equivalente, se puede construir un intervalo de confianza del $(1 - \alpha) \times 100\%$ para β_j :

$$\hat{\beta}_j \pm t_{\alpha/2, n-k-1} \hat{\sigma}\sqrt{c_{jj}}. \quad (2.13)$$

Prueba F de significancia global: Adicionalmente, se puede evaluar si el modelo en su conjunto tiene poder explicativo a través de la prueba F , que plantea:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0 \quad \text{vs.} \quad H_1 : \exists j \text{ tal que } \beta_j \neq 0. \quad (2.14)$$

Para esto, se descompone la variabilidad total de $\mathbf{y}$ como $SCT = SCR + SCE$, donde:

$$SCR = \hat{\boldsymbol{\beta}}^\top \mathbf{X}^\top \mathbf{y} - n\bar{y}^2 \quad (\text{Suma de Cuadrados de la Regresión}) \quad (2.15)$$

$$SCE = \mathbf{y}^\top \mathbf{y} - \hat{\boldsymbol{\beta}}^\top \mathbf{X}^\top \mathbf{y} \quad (\text{Suma de Cuadrados del Error}) \quad (2.16)$$

El estadístico F se obtiene como el cociente entre los cuadrados medios de la regresión y del error:

$$F = \frac{SCR/k}{SCE/(n-k-1)} \quad (2.17)$$

Bajo H_0 y el supuesto de normalidad, $F \sim F_{k, n-k-1}$, por lo que se rechaza H_0 si $F > F_{\alpha, k, n-k-1}$. Es importante notar que un valor F

grande indica que el modelo explica una proporción relevante de la variabilidad de Y , lo que indica que al menos una de las variables independientes es útil para predecir la respuesta.

2.1.5. Validación

La validación del modelo se lleva a cabo en dos etapas: la verificación de los supuestos sobre los errores y la medición de la calidad del ajuste.

Coefficiente de determinación R^2 : Para medir qué tan bien se ajusta el modelo a los datos, se utiliza el coeficiente de determinación, que representa la proporción de la variabilidad total de $\mathbf{y}$ que es explicada por el modelo:

$$R^2 = \frac{SCR}{SCT} = 1 - \frac{SCE}{SCT}, \quad R^2 \in [0, 1]. \quad (2.18)$$

Sin embargo, R^2 aumenta mecánicamente con cada variable que se agrega al modelo, aunque ésta no aporte información real. Por este motivo, se utiliza el coeficiente de determinación ajustado, que penaliza la inclusión de variables innecesarias:

$$R_{\text{adj}}^2 = 1 - \frac{SCE/(n - k - 1)}{SCT/(n - 1)} = 1 - (1 - R^2) \frac{n - 1}{n - k - 1} \quad (2.19)$$

Análisis de residuos: Los residuos $\hat{\varepsilon}_i = y_i - \hat{y}_i$ son la principal herramienta para verificar los supuestos del modelo. Para facilitar su análisis, se definen los *residuos estandarizados*:

$$r_i = \frac{\hat{\varepsilon}_i}{\hat{\sigma} \sqrt{1 - h_{ii}}}, \quad (2.20)$$

Donde h_{ii} es el i -ésimo elemento diagonal de la *matriz sombrero* $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$. Bajo los supuestos del modelo, $r_i \overset{\text{aprox.}}{\sim} \mathcal{N}(0, 1)$.

2.1.6. Distancias de Cook

La distancia de Cook es una medida que identifica observaciones influyentes en el modelo de regresión lineal. Una observación es considerada influyente si su eliminación causa cambios sustanciales en los coeficientes estimados del modelo. La distancia de Cook para la observación i se define como:

$$D_i = \frac{(y_i - \hat{y}_i)^2}{k \cdot \hat{\sigma}^2} \cdot \frac{h_{ii}}{1 - h_{ii}} \quad (2.21)$$

Donde:

- $y_i - \hat{y}_i$ es el residuo de la observación i
- k es el número de variables independientes
- $\hat{\sigma}^2$ es la estimación de la varianza del error
- h_{ii} es el i -ésimo elemento diagonal de la matriz sombrero $H = X(X'X)^{-1}X'$

Como regla general, se considera que una observación es influyente si $D_i > \frac{4}{n}$, donde n es el número de observaciones. Es importante identificar estas observaciones influyentes, ya que pueden distorsionar significativamente las estimaciones de los coeficientes del modelo y, consecuentemente, afectar la precisión de las predicciones.

2.1.7. Normalidad de los residuales

El supuesto de normalidad establece que los errores del modelo deben seguir una distribución normal. Para verificar este supuesto se pueden utilizar tanto pruebas visuales como pruebas estadísticas formales.

Pruebas visuales: El gráfico Q-Q (Quantile-Quantile) es una herramienta gráfica que compara los cuantiles de los residuos estandarizados con los cuantiles teóricos de una distribución normal estándar. Si los puntos se alinean aproximadamente sobre la línea de referencia de 45 grados, el supuesto de normalidad se sostiene.

Pruebas formales: La prueba de Shapiro-Wilk es una de las más utilizadas para evaluar normalidad. Esta prueba plantea:

$$H_0 : \text{los residuos siguen una distribución normal} \quad (2.22)$$

$$H_1 : \text{los residuos no siguen una distribución normal} \quad (2.23)$$

Si el p-valor de la prueba es mayor que el nivel de significancia $\alpha = 0.05$, no se rechaza H_0 y se concluye que los residuos provienen de una distribución normal. Es importante notar que ligeras desviaciones de la normalidad pueden ser tolerables cuando el tamaño de la muestra es grande, debido al Teorema del Límite Central.

2.1.8. Homoscedasticidad e independencia de los residuales

Homoscedasticidad: Este supuesto establece que la varianza de los errores es constante para todos los niveles de las variables independientes. Para verificarlo se pueden utilizar gráficas de residuos estandarizados contra valores predichos. Si los residuos se distribuyen de manera aleatoria sin patrones discernibles alrededor de cero, el supuesto de homoscedasticidad se sostiene.

Adicionalmente, la prueba de Breusch-Pagan puede utilizarse para contrastar formalmente este supuesto. Esta prueba plantea:

$$H_0 : \text{Var}(\varepsilon_i) = \sigma^2 \quad \text{vs.} \quad H_1 : \text{Var}(\varepsilon_i) \neq \sigma^2 \quad (2.24)$$

Si el p-valor es mayor que $\alpha = 0.05$, se concluye que existe homocedasticidad en los residuos.

Independencia: El supuesto de independencia establece que los residuos no están correlacionados entre sí. Para verificar la ausencia de autocorrelación se utiliza la prueba de Durbin-Watson, cuyo estadístico se define como:

$$DW = \frac{\sum_{i=2}^n (\hat{\varepsilon}_i - \hat{\varepsilon}_{i-1})^2}{\sum_{i=1}^n \hat{\varepsilon}_i^2} \quad (2.25)$$

El estadístico de Durbin-Watson toma valores entre 0 y 4. Un valor cercano a 2 indica ausencia de autocorrelación, mientras que valores cercanos a 0 sugieren autocorrelación positiva y valores cercanos a 4 sugieren autocorrelación negativa. Es importante notar que este supuesto es especialmente relevante en datos de series de tiempo; en datos de corte transversal, como los utilizados en este trabajo, suele ser menos crítico.

2.1.9. Métodos de penalización: Lasso, Ridge y Elastic Net

Los métodos de penalización son técnicas de regularización que reducen la complejidad del modelo al penalizar el tamaño de los coeficientes estimados. Estos métodos son especialmente útiles cuando existe multicolinealidad entre las variables independientes o cuando se desea una selección automática de variables. A continuación se presentan tres variantes principales que se aplican a través de la modificación de la función objetivo a minimizar.

Ridge (Tikhonov): Este método aplica una penalización cuadrática sobre los coeficientes. La función objetivo a minimizar es:

$$\min_{\beta} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^k \beta_j^2 \quad (2.26)$$

Donde $\lambda \geq 0$ es el parámetro de penalización. Conforme λ aumenta, los coeficientes se reducen continuamente hacia cero, pero ninguno se anula completamente. Ridge es especialmente útil cuando existe alta colinealidad entre las variables independientes, ya que tiende a estabilizar las estimaciones.

Lasso (Least Absolute Shrinkage and Selection Operator):

Este método aplica una penalización sobre el valor absoluto de los coeficientes. La función objetivo a minimizar es:

$$\min_{\beta} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^k |\beta_j| \quad (2.27)$$

A diferencia de Ridge, Lasso puede reducir algunos coeficientes exactamente a cero, realizando automáticamente selección de variables. Esto es especialmente útil cuando se sospecha que algunas variables no son significativas y se desea un modelo más parsimonioso.

Elastic Net: Este método combina las penalizaciones de Ridge y Lasso, proporcionando un balance entre ambos enfoques. La función objetivo a minimizar es:

$$\min_{\beta} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \left(\alpha \sum_{j=1}^k |\beta_j| + (1 - \alpha) \sum_{j=1}^k \beta_j^2 \right) \quad (2.28)$$

Donde $\alpha \in [0, 1]$ es un parámetro que controla el balance entre Lasso ($\alpha = 1$) y Ridge ($\alpha = 0$). Elastic Net combina las ventajas de ambos métodos: la selección automática de variables de Lasso con la

estabilidad de Ridge, siendo particularmente efectivo cuando hay grupos de variables correlacionadas.

Es importante notar que en todos estos métodos, la magnitud de la penalización está controlada por el parámetro λ . Un valor $\lambda = 0$ corresponde al modelo de regresión lineal ordinaria sin penalización, mientras que valores grandes de λ resultan en modelos más simples pero potencialmente con mayor sesgo. La selección óptima de λ típicamente se realiza mediante validación cruzada.

2.2. Regresión Logit

La regresión logística se usa cuando la variable dependiente es una variable binaria que solo toma de manera genérica los valores 0 para indicar fracaso y 1 para indicar éxito. Este modelo será de utilidad para 2 ejercicios: en primer lugar, definir el estatus de clasificación a la Champions League (se considerará 0 como no clasificado y 1 como clasificado); y en segundo lugar, definir el estatus de descenso a la segunda división (se considerará 0 como no descendido y 1 como descendido).

2.2.1. Modelo Logit

Si en lugar de modelar directamente la probabilidad de éxito θ_j , primero se considera el momio de éxito, que se define como:

$$Momio = \frac{\theta_j}{1 - \theta_j} \quad (2.29)$$

que es la proporción de la probabilidad de que se tenga un éxito entre la probabilidad de fracaso. Es importante notar que el momio puede

tomar valores en $(0, \infty)$ y su interpretación depende del rango en el que se encuentre:

- Si $\frac{\theta_j}{1-\theta_j} < 1$, la probabilidad de clasificarse a Champions League es menor a la de no clasificarse, es decir, $\theta_j < 0.5$
- Si $\frac{\theta_j}{1-\theta_j} = 1$, ambos eventos son igualmente probables, es decir, $\theta_j = 0.5$
- Si $\frac{\theta_j}{1-\theta_j} > 1$, la probabilidad de clasificarse a Champions League es mayor a la de no clasificarse, es decir, $\theta_j > 0.5$

El modelo logit se define como:

$$\text{logit}(\theta_j) = \log(\text{momio}) = \log\left(\frac{\theta_j}{1-\theta_j}\right) = x'\beta \quad (2.30)$$

De donde se obtiene que:

$$\frac{\theta_j}{1-\theta_j} = \exp[x'\beta] \quad (2.31)$$

Y de donde:

$$\theta_j = \frac{1}{1 + \exp[-x'\beta]} \quad (2.32)$$

2.2.2. Regresión Logit con penalización Lasso

Tal como se describió en la sección 2.1.9, la penalización Lasso puede aplicarse también en el contexto de regresión logística. La función objetivo a minimizar se expresa como:

$$\min_{\beta} = - \sum_{i=1}^n [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] + \lambda \sum_{j=1}^k |\beta_j| \quad (2.33)$$

Donde:

- $p_i = \frac{1}{1 + \exp[-(\beta_0 + \sum_{j=1}^k \beta_j x_{ij})]}$
- $\lambda \geq 0$ es el parámetro de penalización de los coeficientes

Lasso es útil en regresión logística cuando se sospecha que algunas variables no son significativas, permitiendo realizar selección automática de variables. Conforme λ aumenta, más coeficientes se reducen exactamente a cero.

2.2.3. Regresión Logit con penalización Ridge

De manera similar, la penalización Ridge puede aplicarse en regresión logística (ver sección 2.1.9 para detalles conceptuales). La función objetivo a minimizar es:

$$\min_{\beta} = - \sum_{i=1}^n [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] + \lambda \sum_{j=1}^k \beta_j^2 \quad (2.34)$$

Donde:

- $p_i = \frac{1}{1 + \exp[-(\beta_0 + \sum_{j=1}^k \beta_j x_{ij})]}$
- $\lambda \geq 0$ es el parámetro de penalización de los coeficientes

Ridge es especialmente útil en regresión logística cuando existe alta colinealidad entre las variables independientes, ya que tiende a estabilizar las estimaciones sin eliminar completamente ninguna variable.

2.2.4. Validación y diagnósticos en regresión logística

La validación de un modelo de regresión logística difiere en varios aspectos de la regresión lineal múltiple, principalmente porque la

variable dependiente es binaria y las métricas de evaluación son diferentes. A continuación se presentan las herramientas principales para validar un modelo logístico.

Matriz de confusión y métricas de clasificación: A diferencia de la regresión lineal que predice valores continuos, la regresión logística predice probabilidades que se convierten en clasificaciones binarias (usualmente usando un umbral de 0.5). La matriz de confusión resume las predicciones correctas e incorrectas:

- **Verdaderos Positivos (VP):** Observaciones positivas correctamente clasificadas
- **Verdaderos Negativos (VN):** Observaciones negativas correctamente clasificadas
- **Falsos Positivos (FP):** Observaciones negativas incorrectamente clasificadas como positivas
- **Falsos Negativos (FN):** Observaciones positivas incorrectamente clasificadas como negativas

A partir de la matriz de confusión se derivan métricas de desempeño:

$$\text{Precisión} = \frac{VP}{VP + FP} \quad (2.35)$$

$$\text{Recall} = \frac{VP}{VP + FN} \quad (2.36)$$

$$\text{Exactitud} = \frac{VP + VN}{VP + VN + FP + FN} \quad (2.37)$$

La precisión mide la proporción de predicciones positivas que fueron correctas, el recall mide la proporción de positivos reales que fueron

identificados, y la exactitud mide la proporción total de predicciones correctas.

Curva ROC y área bajo la curva (AUC): La curva ROC (Receiver Operating Characteristic) evalúa el desempeño del modelo variando el umbral de clasificación. Se construye graficando la tasa de verdaderos positivos (recall) versus la tasa de falsos positivos ($\frac{FP}{FP+VN}$) para diferentes umbrales. El área bajo la curva ROC (AUC) resume el desempeño del modelo en un único valor entre 0 y 1, donde 0.5 indica un clasificador aleatorio y 1.0 indica un clasificador perfecto. Un modelo es considerado efectivo si $AUC > 0.7$.

Devianza y pruebas de bondad de ajuste: La devianza es el análogo logístico de la suma de cuadrados del error en regresión lineal y se utiliza para evaluar la bondad de ajuste. La devianza residual compara el modelo ajustado con el modelo saturado (que se ajusta perfectamente a los datos), mientras que la devianza nula compara el modelo ajustado con un modelo que solo contiene el intercepto. Un modelo con menor devianza residual que devianza nula indica mejor ajuste.

La prueba de Hosmer-Lemeshow es una prueba formal de bondad de ajuste que divide las predicciones en grupos basados en sus probabilidades predichas y compara los valores observados con los esperados. Si el p-valor es mayor que 0.05, el modelo tiene un ajuste adecuado.

Análisis de residuos: A diferencia de la regresión lineal donde se asume que los residuos siguen una distribución normal, los residuos en regresión logística (conocidos como residuos de Pearson o devianza) tienen propiedades distintas. Sin embargo, aún es útil examinar gráficamente los residuos para identificar patrones o observaciones influyentes.

Diferencias clave con regresión lineal: (1) No se asume normalidad de residuos, pero se verifica la bondad de ajuste mediante la devianza o pruebas como Hosmer-Lemeshow; (2) Las métricas de evaluación cambian de error cuadrático a tasas de clasificación correcta e incorrecta; (3) La heterocedasticidad en regresión logística es inherente al modelo binario y no es un problema como en regresión lineal; (4) La independencia de observaciones sigue siendo un supuesto crítico; (5) La multicolinealidad entre variables independientes se diagnostica de la misma manera que en regresión lineal.

2.2.5. Selección automática de variables mediante penalización: Lasso y Ridge

A diferencia de los procedimientos anteriores que requieren comparación iterativa de modelos (regresión ordinal con LRT) o cálculo de importancias post-hoc (SHAP para discriminantes), la regresión logística penalizada integra la selección de variables *dentro* del proceso de estimación mediante penalización.

El problema de multicolinealidad en regresión logística

En regresión logística estándar, la función objetivo es maximizar la log-verosimilitud:

$$\ell(\beta) = \sum_{i=1}^n [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] \quad (2.38)$$

donde $p_i = \frac{1}{1 + e^{-\beta^T \mathbf{x}_i}}$ es la probabilidad predicha.

Sin embargo, cuando existen variables correlacionadas (multicolinealidad), los estimadores $\hat{\beta}$ se vuelven inestables: pequeños cambios en los datos generan grandes cambios en los coeficientes

estimados. Esto degrada tanto la interpretabilidad como el poder predictivo en datos nuevos.

Además, en el contexto de clasificación binaria (Champions League sí/no, Descenso sí/no), tener muchas variables correlacionadas lleva a:

- Sobreajuste: el modelo memoriza ruido en el conjunto de entrenamiento
- Coeficientes inflados: $|\hat{\beta}_j|$ muy grandes, lo que da confianza falsa en predicciones
- Convergencia lenta: los algoritmos iterativos requieren más iteraciones

Ridge: penalización L2

Ridge aborda este problema agregando una penalización al cuadrado de los coeficientes:

$$\ell(\boldsymbol{\beta}) - \lambda \sum_{j=1}^p \beta_j^2 \quad (2.39)$$

donde $\lambda \geq 0$ es un parámetro de penalización. Conceptualmente, esto es equivalente a:

$$\max_{\boldsymbol{\beta}} \ell(\boldsymbol{\beta}) \quad \text{sujeto a} \quad \sum_{j=1}^p \beta_j^2 \leq t \quad (2.40)$$

donde t y λ están relacionados inversamente (mayor λ significa restricción más fuerte).

Propiedades de Ridge

- **Reduce coeficientes uniformemente:** Encoge todos los coeficientes hacia cero, pero ninguno llega exactamente a cero.
- **Mantiene todas las variables:** Aunque con coeficientes reducidos, Ridge preserva todas las variables en el modelo final.
- **Maneja multicolinealidad:** Al penalizar magnitud, distribuye el efecto entre variables correlacionadas en lugar de crear inestabilidad.
- **Mejor generalización:** Modelos Ridge típicamente predicen mejor en datos de prueba que regresión logística estándar.

Lasso: penalización L1

Lasso utiliza penalización del valor absoluto:

$$\ell(\beta) - \lambda \sum_{j=1}^p |\beta_j| \quad (2.41)$$

equivalente a:

$$\max_{\beta} \ell(\beta) \quad \text{sujeto a} \quad \sum_{j=1}^p |\beta_j| \leq t \quad (2.42)$$

Propiedades clave de Lasso

- **Selección automática:** A diferencia de Ridge, Lasso empuja *exactamente* algunos coeficientes a cero. Esto proporciona selección automática de variables: si $\hat{\beta}_j = 0$, la variable j es removida del modelo.

- **Solución geométrica:** La geometría de la restricción L1 (un “diamante” en el espacio de parámetros) hace más probable que la solución óptima ocurra en las esquinas, donde muchos coeficientes son exactamente cero.
- **Interpretabilidad:** El modelo final es naturalmente más parsimonioso que Ridge, facilitando interpretación.
- **Trade-off:** Aunque Lasso hace selección automática, puede ser menos estable que Ridge cuando hay alta correlación entre variables (puede elegir arbitrariamente cuál variable mantener entre un grupo de correlacionadas).

Selección de λ mediante validación cruzada

Tanto Ridge como Lasso requieren elegir el parámetro λ . El enfoque estándar es **validación cruzada de k-pliegues**:

1. Particionar datos de entrenamiento en k subconjuntos (típicamente $k = 5$ o $k = 10$)
2. Para cada valor de λ en una grilla: entrenar modelo en $k - 1$ pliegues y evaluar error en el pliegue restante
3. Calcular error promedio de validación cruzada (CV) para cada λ :

$$CV(\lambda) = \frac{1}{k} \sum_{i=1}^k \text{Error}_i(\lambda) \quad (2.43)$$

4. Seleccionar λ^* que minimiza $CV(\lambda)$
5. Entrenar modelo final con λ^* en todos los datos de entrenamiento

La CV es preferible a AIC/BIC en este contexto porque:

- No requiere asumir una forma particular de distribución de errores
- Evalúa directamente desempeño en datos no vistos
- Es agnóstica al modelo (funciona para cualquier λ)

Comparación Ridge vs. Lasso

Aspecto	Ridge	Lasso
Penalización	$L2: \sum \beta_j^2$	$L1: \sum \beta_j $
Coefficientes	Encogidos, pero > 0	Algunos exactamente cero
Selección	No (mantiene todas)	Sí (automática)
Interpretabilidad	Moderada	Alta
Multicolinealidad	Muy robusta	Menos robusta
Mejor para	Predicción pura	Interpretación + Predicción

Cuadro 2.1. Comparación de Ridge y Lasso para regresión logística

Aplicación en este trabajo

En este estudio se aplican ambas penalizaciones (Ridge y Lasso) para dos razones:

1. **Lasso** proporciona un conjunto explícito de variables seleccionadas, comparable con los de regresión ordinal (LRT) y discriminantes (SHAP).
2. **Ridge** ofrece una alternativa cuando multicolinealidad es severa, permitiendo evaluar si la selección de variables es robusta (es decir,

si Lasso y Ridge eligen variables similares, hay confianza en que esas variables son verdaderamente relevantes).

El parámetro λ es seleccionado mediante validación cruzada de 10 pliegues en el conjunto de entrenamiento, garantizando que la selección de variables no es sobreajustada.

2.3. Regresión ordinal

2.3.1. Modelo

La regresión ordinal es utilizada para modelar la relación entre una variable dependiente ordinal (posición de cada equipo en el ranking) y una o más variables independientes. Una variable ordinal es una variable cualitativa que presenta un orden inherente entre sus categorías, como en este caso puede ser la posición de cada equipo en la tabla de clasificación.

El modelo comúnmente utilizado en regresión ordinal, y que también se usará en este trabajo, es el modelo de probabilidades proporcionales, también conocido como modelo *logit* ordenado. Este modelo supone que la relación entre cada par de categorías de la variable dependiente es constante en todos los niveles de las variables independientes. Existen diferentes funciones liga o enlace, como el *probit* o *clog - log*, pero en este caso, se usará la liga *logit*. Matemáticamente, se expresa mediante la función *logit* acumulativa, que estima la probabilidad de que una observación pertenezca a una categoría específica o a una inferior, en función de una combinación lineal de las variables independientes. El modelo de regresión ordinal, supone la existencia de una variable latente continua Y asociada con cada respuesta. El objetivo es modelar esta variable continua Y en lugar de las categorías directamente.

Para especificar el modelo de regresión ordinal con k categorías en la

variable dependiente Y , es necesario definir parámetros de corte (cutoffs) que establecen los umbrales entre categorías. Estos parámetros de corte deben satisfacer una restricción de orden:

$$-\infty < \gamma_1 \leq \gamma_2 \leq \gamma_3 \leq \dots \leq \gamma_{k-1} < \infty \quad (2.44)$$

Donde γ_j representa el parámetro de corte entre la categoría j y la categoría $j + 1$. Esta restricción asegura que el orden inherente de las categorías se preserve en el modelo. Por convención, se define $\gamma_0 = -\infty$ y $\gamma_k = \infty$.

La ecuación de un modelo de regresión ordinal con k categorías en la variable dependiente Y se basa en la probabilidad acumulativa de pertenecer a una categoría o a una inferior y se expresa de la siguiente manera:

$$\log \frac{P(Y \leq j)}{1 - P(Y \leq j)} = \log \frac{\gamma_j}{1 - \gamma_j} = \gamma_j - \mathbf{x}'\boldsymbol{\beta} \quad (2.45)$$

Donde:

- $P(Y \leq j)$ es la probabilidad acumulada de que la variable dependiente Y tome un valor menor o igual a j (con $j = 1, 2, \dots, k - 1$)
- γ_j es el parámetro de corte específico de cada categoría, que varía para cada j
- $X_1, X_2, \dots, X_p$ son las variables independientes
- $\beta_1, \beta_2, \dots, \beta_p$ son los coeficientes de regresión que indican el efecto de las variables independientes sobre la probabilidad de estar en una categoría mayor de Y

Es importante notar que el signo del coeficiente del predictor lineal es negativo, contrario al signo positivo utilizado comúnmente en las regresiones binarias.

Una característica interesante del modelo es que la razón de momios de las probabilidades para el evento $y_1 \leq j$ y el evento $y_2 \leq j$ es:

$$\frac{\frac{\gamma_{j1}}{1-\gamma_{j1}}}{\frac{\gamma_{j2}}{1-\gamma_{j2}}} = \exp[-(\mathbf{x}_1 - \mathbf{x}_2)' \boldsymbol{\beta}] \quad (2.46)$$

Independientemente de la categoría de respuesta j . Por esta razón, el modelo es conocido como el modelo de momios proporcionales (McCullagh, 1980).

Supuestos:

- **Probabilidades proporcionales:** las relaciones entre cada par de categorías de la variable dependiente son iguales en todos los niveles de las variables independientes
- **Independencia de las observaciones:** Cada observación debe ser independiente de las demás
- **Ausencia de multicolinealidad:** Las variables independientes no deben estar altamente correlacionadas entre sí
- **Linealidad:** Se asume que existe una relación lineal entre las variables independientes y las probabilidades logarítmicas de las categorías de la variable dependiente

2.3.2. Estimación

A diferencia de la regresión lineal, en el modelo de regresión ordinal los valores óptimos de los parámetros no tienen una solución cerrada como la de MCO. En su lugar, se utiliza la solución numérica del método

de *Máxima Verosimilitud* (MV), que consiste en encontrar los valores de β y α_j que maximicen la probabilidad de observar los datos con los que se cuenta.

Para cada observación i , la probabilidad de que $Y_i = j$ se obtiene a partir de las probabilidades acumuladas:

$$P(Y_i = j) = P(Y_i \leq j) - P(Y_i \leq j - 1), \quad (2.47)$$

donde, a partir del modelo logit ordenado definido en la ecuación (2.30), las probabilidades acumuladas son:

$$P(Y_i \leq j) = \frac{1}{1 + \exp(-(\alpha_j - \mathbf{x}_i^\top \beta))}, \quad j = 1, 2, \dots, k - 1. \quad (2.48)$$

Con esto, la función de verosimilitud para una muestra de n observaciones independientes se expresa como:

$$L(\beta, \alpha) = \prod_{i=1}^n \prod_{j=1}^k [P(Y_i \leq j) - P(Y_i \leq j - 1)]^{I(Y_i=j)}, \quad (2.49)$$

Donde $I(Y_i = j)$ es una función indicadora que toma el valor 1 si la observación i pertenece a la categoría j y 0 en caso contrario. Por convención, se define $P(Y_i \leq 0) = 0$ y $P(Y_i \leq k) = 1$.

En la práctica, es más conveniente maximizar el logaritmo de la verosimilitud, conocido como *log-verosimilitud*:

$$\ell(\beta, \alpha) = \sum_{i=1}^n \sum_{j=1}^k I(Y_i = j) \log[P(Y_i \leq j) - P(Y_i \leq j - 1)]. \quad (2.50)$$

Dado que esta función no tiene solución analítica cerrada, los estimadores $\hat{\beta}$ y $\hat{\alpha}$ se obtienen numéricamente mediante algoritmos

iterativos como el método de *Newton-Raphson*, que actualiza los parámetros en cada iteración de la siguiente manera:

$$\boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}^{(t)} - \left[\mathbf{H}(\boldsymbol{\theta}^{(t)}) \right]^{-1} \nabla \ell(\boldsymbol{\theta}^{(t)}), \quad (2.51)$$

Donde $\boldsymbol{\theta} = (\boldsymbol{\alpha}, \boldsymbol{\beta})^\top$ agrupa todos los parámetros del modelo, $\nabla \ell$ es el vector gradiente de la log-verosimilitud y $\mathbf{H}$ es la matriz Hessiana de segundas derivadas parciales. El algoritmo converge cuando los cambios entre iteraciones son suficientemente pequeños.

Es importante notar que, a diferencia del estimador MCO, los estimadores de máxima verosimilitud no son insesgados en muestras finitas, aunque sí son *consistentes* y *asintóticamente eficientes*, lo que indica que sus propiedades mejoran conforme el tamaño de muestra aumenta.

2.3.3. Inferencia

La inferencia en el modelo de regresión ordinal se basa en resultados asintóticos. Bajo condiciones de regularidad, los estimadores de máxima verosimilitud satisfacen:

$$\hat{\boldsymbol{\theta}} \stackrel{a}{\sim} \mathcal{N}(\boldsymbol{\theta}, \mathcal{I}(\boldsymbol{\theta})^{-1}), \quad (2.52)$$

Donde $\mathcal{I}(\boldsymbol{\theta})$ es la *matriz de información de Fisher*, definida como el valor esperado negativo de la Hessiana de la log-verosimilitud:

$$\mathcal{I}(\boldsymbol{\theta}) = -\mathbb{E}[\mathbf{H}(\boldsymbol{\theta})] = -\mathbb{E}\left[\frac{\partial^2 \ell}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}^\top}\right]. \quad (2.53)$$

En la práctica, $\mathcal{I}(\boldsymbol{\theta})$ se estima evaluando la Hessiana en $\hat{\boldsymbol{\theta}}$, de modo que la matriz de covarianzas estimada de los estimadores es:

$$\widehat{\text{Var}}(\hat{\boldsymbol{\theta}}) = \left[-\mathbf{H}(\hat{\boldsymbol{\theta}}) \right]^{-1}. \quad (2.54)$$

Prueba z para coeficientes individuales: Para evaluar si una variable independiente tiene un efecto significativo sobre la variable ordinal, se plantea la hipótesis:

$$H_0 : \beta_j = 0 \quad \text{vs.} \quad H_1 : \beta_j \neq 0. \quad (2.55)$$

El estadístico de prueba es el estadístico de Wald:

$$z_j = \frac{\hat{\beta}_j}{\widehat{\text{e}}\widehat{\text{e}}(\hat{\beta}_j)}, \quad (2.56)$$

Donde $\widehat{\text{e}}\widehat{\text{e}}(\hat{\beta}_j)$ es la raíz cuadrada del j -ésimo elemento diagonal de $\widehat{\text{Var}}(\hat{\boldsymbol{\theta}})$. Bajo H_0 y de manera asintótica, $z_j \sim \mathcal{N}(0, 1)$, por lo que se rechaza H_0 si $|z_j| > z_{\alpha/2}$. De manera equivalente, se puede construir un intervalo de confianza asintótico del $(1 - \alpha) \times 100\%$ para β_j :

$$\hat{\beta}_j \pm z_{\alpha/2} \widehat{\text{e}}\widehat{\text{e}}(\hat{\beta}_j). \quad (2.57)$$

donde $\widehat{\text{e}}\widehat{\text{e}}$ es el error estándar del coeficiente estimado.

Prueba de razón de verosimilitudes: Para comparar dos modelos anidados, es decir, un modelo completo con p predictores y un modelo reducido con $p' < p$ predictores, se utiliza la prueba de razón de verosimilitudes. El estadístico se expresa de la siguiente manera:

$$\Lambda = -2 \left[\ell(\hat{\boldsymbol{\theta}}_{\text{reducido}}) - \ell(\hat{\boldsymbol{\theta}}_{\text{completo}}) \right], \quad (2.58)$$

que bajo H_0 (el modelo reducido es suficiente) sigue de manera asintótica una distribución $\chi^2_{p-p'}$. Un valor grande de Λ indica que el modelo completo se ajusta significativamente mejor que el reducido, lo que sugiere que las variables adicionales son relevantes.

2.3.4. Validación

La validación del modelo de regresión ordinal se lleva a cabo a través de la verificación del supuesto de proporcionalidad, la evaluación de la bondad de ajuste y la medición de la capacidad predictiva del modelo.

Supuesto de probabilidades proporcionales: El supuesto central del modelo logit ordenado es que los coeficientes β son iguales para todas las categorías de respuesta, es decir, que el efecto de cada variable independiente sobre el momio acumulado es constante independientemente de la categoría j . Para verificarlo, se utiliza la *prueba de líneas paralelas*, que plantea:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_{k-1}, \quad (2.59)$$

y cuyo estadístico de prueba sigue de manera asintótica una distribución $\chi^2_{(k-2) \times p}$. Si se rechaza H_0 , el supuesto de proporcionalidad no se sostiene y el modelo logit ordenado estándar no sería adecuado para los datos.

Bondad de ajuste: Para evaluar qué tan bien se ajusta el modelo a los datos, se utilizan pseudocoeeficientes R^2 , que son análogos al R^2 de la regresión lineal pero adaptados al contexto de máxima verosimilitud. Uno de los más utilizados es el R^2 de McFadden:

$$R^2_{\text{McFadden}} = 1 - \frac{\ell(\hat{\theta})}{\ell(\hat{\theta}_0)}, \quad (2.60)$$

Donde $\ell(\hat{\theta})$ es la log-verosimilitud del modelo ajustado y $\ell(\hat{\theta}_0)$ es la log-verosimilitud del modelo nulo, es decir, el modelo que solo incluye los interceptos α_j sin ninguna variable independiente. Es importante notar que este índice no se interpreta de la misma manera que el R^2

ordinario; valores entre 0.2 y 0.4 se consideran indicativos de un buen ajuste en modelos de esta naturaleza.

Capacidad predictiva: Adicionalmente, se puede evaluar la capacidad del modelo para predecir correctamente la categoría de cada observación a través de la *precisión de clasificación*, que se define como la proporción de observaciones correctamente clasificadas:

$$\text{Precisión} = \frac{1}{n} \sum_{i=1}^n I(\hat{Y}_i = Y_i), \quad (2.61)$$

Donde $\hat{Y}_i = \arg \max_j P(Y_i = j \mid \mathbf{x}_i)$ es la categoría con mayor probabilidad predicha para la observación i . Para evitar el sobreajuste, esta métrica se calcula preferentemente sobre un conjunto de prueba independiente del conjunto utilizado para ajustar el modelo.

2.3.5. Verificación del supuesto de proporcionalidad

El supuesto central del modelo logit ordenado es que los coeficientes β son iguales para todas las categorías de respuesta, es decir, que el efecto de cada variable independiente sobre el momio acumulado es constante independientemente de la categoría j . Este supuesto se conoce como el supuesto de proporcionalidad u odds proporcionales.

Para verificar si este supuesto se sostiene, se utiliza la prueba de líneas paralelas (parallel lines test). Esta prueba contrasta el modelo logit ordenado (modelo restringido) con un modelo logit parcialmente proporcional (modelo no restringido) donde los coeficientes pueden variar entre categorías.

La hipótesis a contrastar es:

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_{k-1} \quad \text{vs.} \quad H_1 : \text{al menos un } \beta_j \text{ difiere} \quad (2.62)$$

El estadístico de prueba se basa en la razón de verosimilitudes:

$$\Lambda = -2 [\ell(\text{modelo restringido}) - \ell(\text{modelo no restringido})] \quad (2.63)$$

donde ℓ denota la log-verosimilitud. Bajo H_0 , este estadístico sigue de manera asintótica una distribución χ^2 con $p(k-2)$ grados de libertad, donde p es el número de variables independientes y k es el número de categorías.

Si el p-valor es mayor que $\alpha = 0.05$, se concluye que no hay evidencia estadística suficiente para rechazar H_0 , y el supuesto de proporcionalidad se sostiene. Si el p-valor es menor que $\alpha = 0.05$, el supuesto se viola, lo que indica que el modelo logit ordenado estándar puede no ser adecuado para los datos, y se debería considerar un modelo logit parcialmente proporcional o logit multinomial.

Es importante notar que aunque la violación del supuesto de proporcionalidad es una preocupación teórica, en la práctica el modelo logit ordenado puede ser robusto a violaciones moderadas de este supuesto, especialmente cuando el tamaño de la muestra es pequeño.

2.3.6. Diagnósticos en regresión ordinal

A diferencia de la regresión lineal donde existen herramientas bien establecidas para diagnosticar problemas en el ajuste, los diagnósticos en regresión ordinal son menos directos. Sin embargo, es posible adaptar algunos conceptos de regresión lineal y logística al contexto ordinal.

Residuos en regresión ordinal: Existen varios tipos de residuos que pueden calcularse en un modelo de regresión ordinal. Los más comunes son:

- **Residuos de Pearson:** Se calculan como

$$r_{Pi} = \frac{y_i - \hat{p}_i}{\sqrt{\hat{p}_i(1 - \hat{p}_i)}} \quad (2.64)$$

donde y_i es la respuesta binaria (1 si la observación pertenece a la categoría predicha, 0 en caso contrario) y $\hat{p}_i$ es la probabilidad predicha.

- **Residuos de Deviance:** Basados en la contribución de cada observación a la devianza total del modelo, estos residuos tienen una distribución aproximadamente normal con media cero bajo el modelo correcto.

Análisis gráfico de residuos: Aunque los residuos en regresión ordinal no siguen una distribución normal (como en regresión lineal), es útil examinar gráficamente los residuos para identificar patrones o observaciones influyentes. Se pueden construir gráficas de residuos versus valores predichos para detectar heterocedasticidad o no linealidad.

Observaciones influyentes: Para identificar observaciones que tienen un impacto desproporcionado en las estimaciones de los coeficientes, se puede adaptar el concepto de distancia de Cook. Una aproximación es utilizar la distancia de Cook basada en la matriz Hessiana del modelo logístico ordenado:

$$D_i = (\hat{\beta} - \hat{\beta}_{(i)})' I(\hat{\beta})^{-1} (\hat{\beta} - \hat{\beta}_{(i)}) \quad (2.65)$$

donde $\hat{\beta}_{(i)}$ son los coeficientes estimados cuando la observación i se excluye del análisis, e $I(\hat{\beta})$ es la matriz de información de Fisher. Las observaciones con D_i grande indican influencia potencial en el modelo.

2.3.7. Bondad de ajuste y evaluación del modelo

La evaluación de qué tan bien el modelo se ajusta a los datos en regresión ordinal difiere del enfoque usado en regresión lineal, donde se emplean medidas como R^2 . En regresión ordinal, se utilizan pseudocoeeficientes R^2 que son análogos al R^2 tradicional pero adaptados al contexto de máxima verosimilitud.

R^2 de McFadden: Es el pseudocoeeficiente R^2 más comúnmente utilizado:

$$R_{\text{McFadden}}^2 = 1 - \frac{\ell(\hat{\beta})}{\ell(\hat{\beta}_0)} \quad (2.66)$$

donde $\ell(\hat{\beta})$ es la log-verosimilitud del modelo ajustado y $\ell(\hat{\beta}_0)$ es la log-verosimilitud del modelo nulo (modelo que solo incluye los interceptos sin variables independientes).

Es importante notar que R_{McFadden}^2 toma valores entre 0 y 1, pero no se interpreta de la misma manera que el R^2 ordinario. En regresión ordinal, valores entre 0.2 y 0.4 se consideran indicativos de un buen ajuste, mientras que valores superiores a 0.5 son considerados excelentes.

R^2 de Nagelkerke: Otra medida popular es el pseudocoeeficiente R^2 de Nagelkerke, que escala el R^2 de McFadden para que pueda alcanzar un máximo de 1:

$$R_{\text{Nagelkerke}}^2 = \frac{1 - e^{2[\ell(\hat{\beta}_0) - \ell(\hat{\beta})]/n}}{1 - e^{2\ell(\hat{\beta}_0)/n}} \quad (2.67)$$

Criterios de información: Los criterios AIC y BIC pueden ser utilizados para comparar modelos de regresión ordinal con diferentes conjuntos de variables predictoras:

$$\text{AIC} = -2\ell(\hat{\beta}) + 2k, \quad \text{BIC} = -2\ell(\hat{\beta}) + k \ln(n) \quad (2.68)$$

donde k es el número de parámetros y n es el tamaño de la muestra. Modelos con menores valores de AIC o BIC son preferibles.

Capacidad predictiva: La capacidad del modelo para clasificar correctamente las observaciones en sus categorías correspondientes se puede evaluar mediante la precisión de clasificación:

$$\text{Precisión} = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(\hat{y}_i = y_i) \quad (2.69)$$

donde $\hat{y}_i = \arg \max_j P(Y_i = j | \mathbf{x}_i)$ es la categoría con mayor probabilidad predicha. Para evitar sobreajuste, esta métrica debe calcularse preferentemente sobre un conjunto de prueba independiente del conjunto utilizado para ajustar el modelo.

2.3.8. Métodos de penalización en regresión ordinal

Así como se discutió en la sección 2.1.9 para regresión lineal múltiple, los métodos de penalización (Lasso, Ridge y Elastic Net) pueden aplicarse también en el contexto de regresión ordinal. Estos métodos son especialmente útiles cuando existe multicolinealidad entre las variables independientes o cuando se desea una selección automática de variables.

Regresión ordinal con penalización Ridge: La función objetivo a minimizar se expresa como:

$$\min_{\boldsymbol{\beta}} = - \sum_{i=1}^n \ell_i(\boldsymbol{\beta}) + \lambda \sum_{j=1}^k \beta_j^2 \quad (2.70)$$

donde $\ell_i(\boldsymbol{\beta})$ es la contribución de la observación i a la log-verosimilitud. Ridge es especialmente útil cuando existe alta colinealidad entre las variables independientes, ya que tiende a

estabilizar las estimaciones sin eliminar completamente ninguna variable.

Regresión ordinal con penalización Lasso: La función objetivo a minimizar es:

$$\min_{\beta} = - \sum_{i=1}^n \ell_i(\beta) + \lambda \sum_{j=1}^k |\beta_j| \quad (2.71)$$

Lasso puede reducir algunos coeficientes exactamente a cero, realizando automáticamente selección de variables. Esto es especialmente útil en regresión ordinal cuando se sospecha que algunas variables no son significativas y se desea un modelo más parsimonioso.

Regresión ordinal con penalización Elastic Net: Combina las penalizaciones de Ridge y Lasso:

$$\min_{\beta} = - \sum_{i=1}^n \ell_i(\beta) + \lambda \left(\alpha \sum_{j=1}^k |\beta_j| + (1 - \alpha) \sum_{j=1}^k \beta_j^2 \right) \quad (2.72)$$

donde $\alpha \in [0, 1]$ controla el balance entre Lasso y Ridge. Elastic Net es particularmente efectivo cuando hay grupos de variables correlacionadas.

La selección óptima del parámetro de penalización λ típicamente se realiza mediante validación cruzada, evaluando el desempeño del modelo en datos no vistos durante el entrenamiento.

2.3.9. Selección de variables en regresión ordinal

A diferencia de la regresión lineal, donde los criterios de información (AIC, BIC) pueden aplicarse directamente, la regresión ordinal presenta particularidades que requieren un enfoque distinto.

Limitaciones de AIC en regresión ordinal

En regresión lineal, el AIC es aplicable porque la función objetivo es la suma de cuadrados, que puede ser evaluada incrementalmente. Sin embargo, en modelos de máxima verosimilitud como la regresión ordinal, el AIC depende de la verosimilitud del modelo completo:

$$AIC = 2k - 2 \ln(\hat{L}(\boldsymbol{\beta})) \quad (2.73)$$

donde $\hat{L}(\boldsymbol{\beta})$ es la log-verosimilitud evaluada en los estimadores máximo verosímiles. Aunque AIC es teóricamente válido para regresión ordinal, en la práctica stepwise automático con AIC no está implementado en la mayoría de librerías (como VGAM en R) porque:

1. La estimación de parámetros en cada paso requiere iteraciones de Newton-Raphson, haciéndolo computacionalmente costoso.
2. La estructura de los umbrales α_j cambia con cada variable removida, complicando las comparaciones directas.
3. El supuesto de proporcionalidad del modelo puede violarse dependiendo del conjunto de variables, invalidando comparaciones simples.

Prueba de razón de verosimilitudes (LRT)

La alternativa estándar es usar la **Prueba de Razón de Verosimilitudes** (Likelihood Ratio Test, LRT), que compara dos modelos anidados:

$$\Lambda = -2[\ln(\hat{L}_{\text{restringido}}) - \ln(\hat{L}_{\text{completo}})] \quad (2.74)$$

Bajo la hipótesis nula H_0 (el modelo restringido es suficiente), Λ sigue una distribución χ^2 con grados de libertad igual a la diferencia en el número de parámetros entre ambos modelos.

En el contexto de selección de variables, la LRT permite evaluar si remover una variable particular degrada significativamente el ajuste. Si el p-valor es alto (típicamente $p > 0.05$), la variable no aporta información significativa y puede ser removida sin pérdida notable.

Procedimiento de selección mediante drop

El método de selección propuesto en este trabajo utiliza el enfoque iterativo de *backward elimination* basado en LRT:

1. **Modelo inicial:** Ajustar regresión ordinal con todas las variables disponibles.
2. **Evaluación de impacto:** Para cada variable x_j , calcular Λ_j comparando:
 - Modelo completo: k variables
 - Modelo sin x_j : $k - 1$ variables
3. **Identificación de candidato:** Seleccionar la variable con mayor p-valor asociado a su Λ_j (es decir, la variable cuya remoción causa menor degradación en verosimilitud).
4. **Decisión:**
 - Si $p_j > \alpha$ (típicamente $\alpha = 0.05$): remover la variable y repetir con el nuevo modelo.
 - Si todos los $p_j \leq \alpha$: detener; todas las variables restantes son significativas.

5. **Validación final:** Comparar modelo inicial vs. modelo final usando LRT global para asegurar que el ajuste no se degradó significativamente ($p > 0.05$).

Ventajas de este enfoque

A diferencia de otras estrategias, este procedimiento tiene varias ventajas teóricas:

1. **Principio de parsimonia:** Mantiene solo variables que contribuyen significativamente, reduciendo complejidad sin sacrificar ajuste.
2. **Robustez estadística:** Basado en LRT, que tiene propiedades bien caracterizadas bajo normalidad asintótica.
3. **Interpretabilidad:** Los umbrales α_j del modelo final son estimados consistentemente con un conjunto menor de variables, facilitando la interpretación.
4. **Evita multicolinealidad:** Al remover variables correlacionadas, el modelo final sufre menos de inestabilidad de parámetros.

Limitación importante: Supuesto de proporcionalidad

Un punto crítico es que este procedimiento asume que el supuesto de proporcionalidad se mantiene a través de los modelos anidados. Si al remover una variable se viola este supuesto en el modelo reducido, la validez de la LRT se ve comprometida. Por ello, el procedimiento incluye verificación del supuesto en el modelo final mediante la prueba de líneas paralelas (Sección 2.3.5).

2.4. Simulación de partidos: Modelo de Poisson

2.4.1. Modelo

La simulación de partidos es un método que permite estimar la probabilidad de que cada equipo termine en una posición determinada de la tabla al final de la temporada, sin necesidad de calcular explícitamente todas las combinaciones posibles de resultados. El enfoque seguido en este trabajo está basado en el modelo propuesto por Lee (1997), en el cual se modela la distribución de goles de cada equipo mediante distribuciones de Poisson independientes y se simulan temporadas completas para estimar las probabilidades de clasificación.

Estimación de parámetros: Los parámetros del modelo (μ , α_H , ataque $_k$ y defensa $_k$ para cada equipo k) se estiman mediante el método de máxima verosimilitud, asumiendo que los goles de ambos equipos son independientes entre sí. Lee (1997) valida este supuesto de independencia a través de una prueba χ^2 sobre la tabla de frecuencias cruzadas de goles locales y visitantes por temporada, encontrando que no existe evidencia en contra de la independencia. Una vez estimados los parámetros, es posible calcular la distribución conjunta de goles para cualquier combinación de equipos de la siguiente manera:

$$P(X_{ij}^H = h, X_{ij}^A = a) = \frac{e^{-\lambda_{ij}^H} (\lambda_{ij}^H)^h}{h!} \cdot \frac{e^{-\lambda_{ij}^A} (\lambda_{ij}^A)^a}{a!} \quad (2.75)$$

y, a partir de esta distribución, obtener las probabilidades de victoria, empate y derrota para cada partido sumando sobre las combinaciones de marcadores correspondientes.

Simulación Monte Carlo: Dado que calcular la probabilidad exacta de que un equipo termine en cada posición de la tabla requiere evaluar todas las posibles combinaciones de resultados de los 380 partidos de la temporada, lo cual resulta computacionalmente inviable, se recurre a la simulación Monte Carlo como alternativa práctica. El procedimiento consiste en simular un número elevado de temporadas completas N , donde en cada temporada se genera el marcador de cada partido muestreando de manera independiente:

$$\tilde{X}_{ij}^H \sim \text{Poisson}(\hat{\lambda}_{ij}^H), \quad \tilde{X}_{ij}^A \sim \text{Poisson}(\hat{\lambda}_{ij}^A) \quad (2.76)$$

A partir de los marcadores simulados se asignan los puntos correspondientes (3 por victoria, 1 por empate, 0 por derrota) y se construye la tabla de posiciones de esa temporada. Al repetir este proceso N veces, se estima la probabilidad de que cada equipo termine en cada posición como la proporción de simulaciones en las que dicho resultado se observó. En este trabajo se utiliza $N = 1,000$ simulaciones, valor con el que Lee (1997) demuestra que las estimaciones convergen con suficiente precisión.

Supuestos

- **Distribución de Poisson:** El número de goles anotados por cada equipo en cada partido sigue una distribución de Poisson, lo que implica que los goles ocurren de manera aleatoria e independiente a una tasa constante a lo largo del partido.
- **Independencia de goles:** Los goles anotados por el equipo local y los anotados por el visitante son independientes entre sí, supuesto validado empíricamente por Lee (1997) mediante una prueba χ^2 .

- **Estacionariedad de parámetros:** Los parámetros de ataque y defensa de cada equipo se asumen constantes a lo largo de la temporada, sin considerar el efecto de lesiones, sanciones o cambios en el rendimiento a lo largo del tiempo.
- **Homogeneidad del calendario:** Se asume que cada equipo enfrenta a todos los demás en condiciones equivalentes, sin considerar efectos de fatiga derivados de la participación en competencias europeas o de la acumulación de partidos.

Validación del supuesto de independencia: Siguiendo el procedimiento de Lee (1997), se verifica que los goles anotados por el equipo local y el equipo visitante son independientes entre sí. Para esto, se construye una tabla de frecuencias cruzadas con los goles de ambos equipos en cada uno de los 380 partidos de la temporada 2023-2024, y se aplica una prueba χ^2 de independencia sobre dicha tabla.

La hipótesis a contrastar es:

H_0 : los goles del equipo local y del visitante son independientes

H_1 : existe dependencia entre ambos.

El estadístico de prueba se calcula como:

$$\chi^2 = \sum_i \sum_j \frac{(O_{ij} - E_{ij})^2}{E_{ij}}, \quad (2.77)$$

Donde O_{ij} es la frecuencia observada de partidos en los que el equipo local anotó i goles y el visitante anotó j goles, y $E_{ij} = \frac{n_{i \cdot} \cdot n_{\cdot j}}{n}$ es la frecuencia esperada bajo el supuesto de independencia. La tabla de

frecuencias observadas para la temporada 2023-2024 se muestra a continuación:

Cuadro 2.2. Frecuencias observadas de goles: local vs. visitante (2023-2024)

Local \ Visitante	0	1	2	3	4	5	6	8
0	11	20	19	7	5	3	2	1
1	22	38	24	17	7	1	0	0
2	24	31	27	10	4	1	0	0
3	18	26	13	4	2	0	0	0
4	5	9	6	4	2	0	0	0
5	8	5	1	0	0	0	0	0
6	1	2	0	0	0	0	0	0

Al aplicar la prueba χ^2 sobre esta tabla se obtienen los siguientes resultados:

$$\chi^2 = 45.08 \quad \text{g.l.} = 42 \quad p\text{-valor} = 0.3442 \quad (2.78)$$

Dado que el p -valor es de 0,3442, no se rechaza H_0 al nivel de significancia $\alpha = 0,05$. Esto indica que no existe evidencia estadística suficiente para afirmar que los goles del equipo local y del visitante están relacionados, lo que es consistente con el resultado reportado por Lee (1997) para temporadas anteriores de la Premier League. Por lo tanto, el supuesto de independencia del modelo de Poisson se sostiene para la temporada 2023-2024 y el modelo es adecuado para simular los marcadores de cada partido.

2.4.2. Limitación de selección de variables en modelo de Poisson

A diferencia de los modelos anteriores (regresión ordinal, logística, análisis discriminante), el modelo de Poisson presentado en este trabajo está diseñado con un propósito distinto: no predecir una variable dependiente de resultado (posición, Champions, descenso), sino *simular* partidos individuales y, de esa simulación, derivar distribuciones de probabilidad de posiciones finales.

¿Por qué Poisson no aplica selección de variables estándar?

El modelo de Poisson estima dos parámetros por equipo:

- α_k : parámetro de ataque (capacidad de anotar goles)
- δ_k : parámetro de defensa (vulnerabilidad a goles)

Estos parámetros se estiman directamente de los goles observados (GaF y GaC históricas), usando máxima verosimilitud. No hay un conjunto de “variables independientes” $\mathbf{x}$ como en regresión, sino que los datos de entrada al modelo son ya agregados (goles por temporada, no características detalladas de cada equipo).

Por lo tanto:

1. **No hay “selección” de variables:** El modelo Poisson utiliza todos los goles observados en su forma natural. No se remueve ninguno.
2. **Parámetros fijos:** α_k y δ_k son propiedades del equipo, no de un subconjunto de predictores.
3. **Objetivo diferente:** El modelo busca explicar variabilidad en marcadores de partidos, no en posición final o clasificación.

Validación del modelo Poisson

En su lugar, la validación de este modelo se realiza mediante:

1. **Bondad de ajuste:** Verificar que la distribución simulada de goles es consistente con la observada (test χ^2 de independencia, Sección 2.4.1).
2. **Precisión de predicción:** Comparar probabilidades simuladas de posiciones finales contra posiciones reales observadas (métricas: precisión exacta, error ± 1 , error ± 2).
3. **Robustez temporal:** Evaluar si el modelo entrenado en temporadas pasadas (2015-2023) predice bien la temporada más reciente (2023-2024), indicando que los parámetros son estables.

Estos criterios no involucran selección de variables, sino validación de la capacidad predictiva global del modelo.

2.5. Análisis discriminante

El análisis discriminante se utiliza para clasificar en grupos preexistentes o definidos de antemano a partir de variables predictoras. El objetivo es definir la función que maximiza la separación entre clases, minimizando al mismo tiempo la variabilidad dentro de cada grupo. En este caso, se usará para 2 ejercicios: en primer lugar, para estimar si un equipo se clasifica a la UEFA Champions League, es decir, los equipos que quedan en el top 4 en el ranking; y en segundo lugar para un ejercicio adicional e independiente, para estimar si un equipo desciende a segunda división, es decir, los equipos que terminan la temporada en las últimas 3 posiciones del ranking. Las variantes que

se utilizarán en esta investigación son el Análisis Discriminante Lineal (LDA) y el Análisis Discriminante Cuadrático (QDA).

2.5.1. Análisis discriminante lineal (LDA)

El LDA asume que las observaciones de cada clase k provienen de una distribución normal multivariada con media μ_k y una matriz de covarianza común Σ . De esta manera, se obtiene una función discriminante lineal que clasifica observaciones según la probabilidad de pertenecer a cada clase.

La regla de clasificación se basa en maximizar la función discriminante:

$$\delta_k(x) = X'\Sigma^{-1}\mu_k - \frac{1}{2}\mu'_k\Sigma^{-1}\mu_k + \log(p_k) \quad (2.79)$$

Donde:

- μ_k es la media del grupo k
- Σ es la matriz de covarianza
- $p_k = \frac{N_k}{N}$ es la probabilidad a priori de la clase k

Al momento de utilizar el modelo, una observación x es clasificada en la clase k en la que tenga el mayor valor.

Supuestos del LDA:

- Las variables predictoras siguen una distribución normal multivariada dentro de cada grupo
- Las matrices de covarianza son iguales para todas las clases

- Las observaciones son independientes entre sí
- Las clases son mutuamente excluyentes

2.5.2. Análisis discriminante cuadrático (QDA)

El Análisis Discriminante Cuadrático (QDA) es una generalización del LDA que relaja el supuesto de igualdad de matrices de covarianza entre clases. Para este método, se permite que cada grupo k tenga su propia matriz de covarianza Σ_k y, como resultado, las fronteras de decisión ya no son lineales, sino superficies cuadráticas.

La función discriminante en QDA está dada por:

$$\delta_k(x) = -\frac{1}{2}\log(|\Sigma_k|) - \frac{1}{2}(x - \mu_k)'\Sigma_k^{-1}(x - \mu_k) + \log(p_k) \quad (2.80)$$

Al igual que en LDA, a una observación se le asigna la clase con mayor valor de la función.

Supuestos del QDA:

- Las variables predictoras siguen una distribución normal multivariada dentro de cada grupo
- Cada clase tiene su propia matriz de covarianza Σ_k
- Las observaciones son independientes
- Las clases son mutuamente excluyentes

2.5.3. Ventajas y desventajas de LDA y QDA

Aunque tanto el Análisis Discriminante Lineal (LDA) como el Análisis Discriminante Cuadrático (QDA) son métodos de clasificación

que comparten supuestos comunes, difieren en su complejidad y en el supuesto crítico sobre la igualdad de matrices de covarianza. El siguiente cuadro presenta una comparación detallada de ambos métodos para facilitar la selección del más apropiado según el contexto del problema.

Aspecto	LDA (Lineal)	QDA (Cuadrático)
Complejidad	Más simple. Fronteras lineales rápidas	Más complejo. Mayor cálculo
Parámetros	Una matriz: $\frac{p(p+1)}{2}$	Múltiples: $k \cdot \frac{p(p+1)}{2}$
Muestras pequeñas	Mejor desempeño	Peor desempeño
Interpretabilidad	Excelente (fronteras simples)	Compleja (fronteras cuadrática)
Flexibilidad	Baja (solo lineal)	Alta (captura no linealidad)
Mejor para	n pequeño, interpretabilidad	n grande, frontera compleja

Recomendación: Seleccionar LDA si se prioriza la simplicidad e interpretabilidad con muestras pequeñas. Elegir QDA si se tienen suficientes observaciones y se sospecha que las matrices de covarianza difieren entre grupos.

2.5.4. Importancia de variables en análisis discriminante: SHAP

A diferencia de la regresión ordinal, donde la selección de variables puede basarse en pruebas de razón de verosimilitudes, el análisis

discriminante (tanto lineal como cuadrático) carece de un procedimiento automático estándar para eliminar variables. Los métodos tradicionales de stepwise selection no están diseñados para problemas de clasificación de este tipo.

El problema de interpretabilidad en análisis discriminante

En LDA y QDA, el resultado final es una regla de clasificación que asigna cada observación a una clase maximizando la función discriminante $\delta_k(x)$. Sin embargo, estos modelos no producen directamente medidas de importancia de variables. Es decir:

- No hay coeficientes β_j explícitos (como en regresión)
- No hay p-valores asociados a cada variable
- No es claro cuál variable contribuye más a la discriminación entre grupos

Esto plantea un desafío: ¿cómo saber cuáles variables son verdaderamente necesarias para la clasificación?

Teoría de valores de Shapley

Para resolver este problema, se recurre a los valores de Shapley, un concepto de teoría de juegos que proporciona una manera principada de asignar importancia a cada variable en cualquier modelo predictivo.

El valor de Shapley para una variable j se define como:

$$\phi_j = \frac{1}{|M|!} \sum_{S \subseteq M \setminus \{j\}} \frac{|S|!(|M| - |S| - 1)!}{|M|!} [f(S \cup \{j\}) - f(S)] \quad (2.81)$$

donde:

- M es el conjunto de todas las variables
- S es un subconjunto de variables (sin j)
- $f(S)$ es el valor predicho del modelo usando solo variables en S
- La suma se toma sobre todas las posibles coaliciones S

En términos prácticos, ϕ_j cuantifica la contribución marginal promedio de la variable j a través de todas las posibles combinaciones de otras variables. Tiene tres propiedades deseables:

1. **Eficiencia:** $\sum_j \phi_j = f(\{M\}) - f(\emptyset)$ (la suma de importancias explica completamente la diferencia entre predicción con todas las variables y sin ninguna).
2. **Simetría:** Si dos variables tienen el mismo impacto marginal en todas las coaliciones, tienen el mismo ϕ_j .
3. **Nulidad:** Si una variable no cambia la predicción en ninguna coalición, entonces $\phi_j = 0$.

SHAP: Aplicación práctica a análisis discriminante

SHAP es una implementación de los valores de Shapley diseñada para ser computacionalmente eficiente y aplicable a cualquier modelo de machine learning, incluyendo LDA y QDA.

Para un problema de clasificación binaria (e.g., clasificar a Champions League o no), SHAP proporciona:

1. **Importancia global:** Para toda la población de test, ¿cuál variable j tiene el mayor $|\phi_j|$ promedio? Esto da un ranking de variables por relevancia discriminante.

2. **Importancia local:** Para una observación específica, ¿cuál variable j contribuyó más a que fuera clasificada en la clase predicha?
3. **Dirección del efecto:** No solo magnitud, sino si la variable empuja hacia la clase 0 o la clase 1 (visualización mediante gráficos como SHAP summary plots).

Selección de variables mediante SHAP

El procedimiento de selección propuesto es:

1. **Entrenar modelo:** Ajustar LDA (o QDA) con todas las k variables disponibles en el conjunto de entrenamiento.
2. **Calcular SHAP values:** En el conjunto de prueba, calcular ϕ_j para cada variable j usando la biblioteca SHAP.
3. **Ranking de importancia:** Ordenar variables de mayor a menor $|\phi_j|$ promedio. Esto produce un ranking objetivo, basado en cuánto cada variable contribuyó a las predicciones reales del modelo.
4. **Selección de umbral:** Existen varias estrategias:
 - *Codo:* Graficar $|\phi_j|$ vs. ranking. Donde la curva presenta un “codo” (cambio de pendiente), retener variables hasta ese punto.
 - *Acumulativo:* Retener suficientes variables para explicar el 80-90 % de la importancia total ($\sum_{j=1}^m |\phi_j| / \sum_{j=1}^k |\phi_j|$).
 - *Estadístico:* Usar prueba de hipótesis sobre si ϕ_j es significativamente diferente de cero (bajo bootstrap).

5. **Validación cruzada:** Entrenar nuevo modelo LDA/QDA usando solo las variables seleccionadas. Comparar precisión en test set contra modelo con todas las variables (diferencia $< 2\%$ indica que las variables removidas solo aportaban ruido).

Ventajas de SHAP sobre alternativas

1. **Agnóstico al modelo:** A diferencia de importancia basada en varianza o coeficientes, SHAP funciona con cualquier modelo, incluyendo LDA/QDA que no tienen parámetros interpretables directamente.
2. **Principios teóricos sólidos:** Basado en teoría de juegos, no en heurísticas ad hoc.
3. **Interpretabilidad local y global:** Proporciona tanto explicaciones globales (ranking de variables) como locales (por qué se clasificó una observación específica de cierta forma).
4. **Detección de no-linealidades:** Captura interacciones entre variables que métodos simples (e.g., correlación) no detectan.

Limitaciones y consideraciones

1. **Costo computacional:** Calcular SHAP values exactos requiere evaluar el modelo en 2^k coaliciones. Para $k > 15$ variables, típicamente se usa una aproximación.
2. **Dependencia de datos de entrenamiento:** SHAP values se calculan condicionados en la distribución del conjunto de datos usado. Si los datos de prueba son muy distintos, el ranking puede cambiar.

3. **No es prueba de significancia:** Un $|\phi_j|$ pequeño no prueba que la variable sea estadísticamente no significativa, solo que contribuye poco a las predicciones del modelo específico.

Capítulo 3

Bases de datos y análisis exploratorio de datos

Este capítulo tiene el propósito de explicar la construcción y definición de variables de la base de datos.

3.1. Creación de base de datos

Para los propósitos de este trabajo, se recopilaron manualmente datos de 9 temporadas de la Premier League (2015/2016-2023/2024) sobre el desempeño y características de los 20 equipos por temporada. La base de datos está compuesta de 180 entradas con 43 variables sobre temas de desempeño dentro y fuera de la cancha. Para construir la base, la información fue recopilada del sitio oficial de la Premier League (Premier League, 2025), el sitio especializado en data de fútbol FBREF (FBREF, 2025) y el sitio especializado en transferencias de jugadores (Transfermarkt, 2025). Con esta información, las siguientes variables fueron creadas por temporada:

Cuadro 3.1. Desempeño en el campo de juego

Variable	Descripción y transformaciones	Rango
1. Goles a favor	Goles anotados a lo largo de la temporada	[20, 106]
2. Goles en contra	Goles recibidos a lo largo de la temporada	[22, 104]
3. Diferencia de goles	Calculada como la resta de goles a favor menos goles en contra	[−69, 79]
4. Porterías a cero	Cantidad de partidos sin recibir gol	[1, 21]
5. Tarjetas amarillas	Cantidad de tarjetas amarillas recibidas	[38, 109]
6. Tarjetas rojas	Cantidad de tarjetas rojas recibidas	[0, 7]
7. XGF	Goles anotados esperados a lo largo de la temporada	[28.8, 92.0]
8. XGC	Goles recibidos esperados a lo largo de la temporada	[23.8, 78.0]
9. GvsXG	Calculada como la diferencia entre goles anotados y goles anotados esperados	[−14.0, 27.4]
10. Tiros	Tiros realizados	[319, 781]
11. Tiros a gol	Tiros realizados con dirección a portería	[92, 656]
12. Goles de penal	Goles anotados de penalti	[0, 11]
13. Goles de cabeza	Goles anotados de cabeza	[1, 19]
14. Goles dentro del área	Goles anotados desde dentro del área	[17, 93]
15. Goles fuera del área	Goles anotados desde fuera del área	[0, 18]
16. Goles de contragolpe	Goles anotados en situación de contragolpe	[0, 13]
17. Fuera de lugar	Cantidad de fueros de lugar cometidos	[37, 108]
18. Autogoles	Cantidad de autogoles	[0, 7]
19. Penales provocados	Cantidad de penales provocados	[0, 14]
20. Atajadas	Cantidad de atajadas realizadas por el portero	[54, 179]
21. Despejes	Cantidad de despejes realizados	[227, 1308]

Cuadro 3.1 continuación

Variable	Descripción y transformaciones	Rango
22. Barridas	Cantidad de barridas realizadas	[173, 899]
23. Faltas	Cantidad de faltas cometidas	[289, 514]
24. Total de pases	Cantidad total de pases realizados	[7170, 27758]
25. Pases filtrados	Cantidad de pases filtrados realizados	[8, 168]
26. Pases hacia atrás	Cantidad de pases hacia atrás realizados	[160, 4796]
27. Centros	Cantidad de centros realizados	[428, 969]
28. Tiros de esquina	Cantidad de tiros de esquina	[128, 316]

Cuadro 3.2. Desempeño en el ranking

Variable	Descripción y transformaciones	Rango
29. Competencias europeas	Variable indicadora: toma el valor 1 si el equipo participó en un torneo europeo durante esa temporada, 0 en caso contrario	{0, 1}
30. Recién ascendido	Variable indicadora: toma el valor 1 si el equipo recién ascendió a la Premier League, 0 en caso contrario	{0, 1}
31. Champions League	Variable indicadora: toma el valor 1 si el equipo logró clasificarse a la UEFA Champions League, 0 en caso contrario	{0, 1}
32. Descenso	Variable indicadora: toma el valor 1 si el equipo descendió a la Championship al final de la temporada, 0 en caso contrario	{0, 1}

Cuadro 3.3. Características extra cancha

Variable	Descripción y transformaciones	Rango
33. Temporada	Indica la temporada a la que corresponde el registro	[15/16, 23/24]
34. Big 6	Variable indicadora: toma el valor 1 si el equipo pertenece al <i>Big 6</i> (Arsenal, Chelsea, Liverpool, Manchester City, Manchester United y Tottenham), 0 en caso contrario	{0, 1}
35. Gasto por transferencias	Dinero gastado en transferencias de jugadores, expresado en millones de euros	[0, 611.5]
36. Ingreso por transferencias	Dinero ingresado por venta de jugadores, expresado en millones de euros	[0, 278.3]
37. Jugadores nuevos	Cantidad de jugadores que llegaron al equipo	[4, 41]
38. Jugadores vendidos	Cantidad de jugadores que salieron del equipo	[4, 46]
39. Valor de la plantilla	Valor de mercado total de la plantilla, expresado en millones de euros	[99.9, 1460.0]
40. Cantidad de jugadores	Número total de jugadores en la plantilla	[25, 56]
41. Valor promedio de los jugadores	Calculado como el promedio del valor de mercado de todos los jugadores de la plantilla, expresado en millones de euros	[0.08, 40.56]
42. Asistencia promedio al estadio	Calculada como el promedio de asistentes por partido a lo largo de la temporada	[178, 75290]
43. Ventaja de local	Calculada como la diferencia porcentual entre los puntos obtenidos de local y de visitante	[−0.20, 0.43]

Ejemplo de aplicación: Leicester City, Temporada 2015-2016

El Leicester City de la temporada 2015-2016 representa un caso excepcional en la historia de la Premier League. Bajo la dirección técnica de Claudio Ranieri, el equipo logró ganar el título de campeón de forma sorpresiva, partiendo desde una posición de desventaja. A continuación, se presenta un ejemplo completo de cómo se registran todas las variables de nuestro conjunto de datos para este equipo histórico.

Desempeño en el Campo de Juego:

Variable	Valor Leicester City 15/16
Posición Final	1
Goles a Favor (GaF)	68
Goles en Contra (GaC)	36
Diferencia de Goles (DF)	32
Porterías a Cero (P0)	15
Tarjetas Amarillas (TA)	48
Tarjetas Rojas (TR)	3
Tiros	522
Tiros a Gol	179
Goles de Contragolpe	6
Centros	762

Cuadro 3.4. Desempeño en el campo de juego: Leicester City 2015-2016

Características de Ranking y Competición:

Variable	Valor
Competencias Europeas	No (0)
Recién Ascendido	No (0)
Champions League	Sí (1)
Descenso	No (0)
Pertenece al Big 6	No (0)

**Cuadro 3.5. Características de ranking: Leicester City
2015-2016**

Características Extra Cancha:

Variable	Valor
Gasto en Transferencias (M€)	49.9
Ingresos por Transferencias (M€)	9.4
Jugadores Nuevos	25
Jugadores Vendidos	32
Valor Total de Plantilla (M€)	161.1
Número de Jugadores	35
Valor Promedio por Jugador (M€)	4.60
Asistencia Promedio al Estadio	31,998

**Cuadro 3.6. Características extra cancha: Leicester City
2015-2016**

Interpretación del ejemplo: Este caso ilustra cómo un equipo que no pertenecía al Big 6 y no tenía participación en competiciones europeas previas logró dominar la liga mediante un desempeño defensivo sobresaliente (36 goles en contra, la quinta mejor defensa), combinado con una eficiencia ofensiva excepcional (68 goles a favor). La plantilla del Leicester fue relativamente modesta en términos de valor de mercado (161.1 millones de euros) comparada con otros

equipos de élite, pero su gestión fue eficiente, con un gasto de transferencias de tan solo 49.9 millones de euros. Este ejemplo demuestra la importancia de las variables capturadas en nuestra base de datos para explicar el rendimiento de los equipos, independientemente de su historial o valor inicial.

3.2. Análisis exploratorio de datos

3.2.1. Desempeño en el campo de juego


A continuación, se realizará un análisis exploratorio de datos para entender las posibles relaciones en las variables. Para analizar la primera división de fútbol inglesa, se considerarán datos desde la temporada 2015/2016 hasta la temporada 2023/2024. Esta información incluye goles a favor y en contra, tipos de goles, tipos de pases, inversión en transferencias, asistencia al estadio, entre otras. El objetivo será encontrar qué variables influyen más en la posición en la tabla, así como en si un equipo podrá entrar a puestos de Champions League o salvarse de un posible descenso, lo cual lleva a las siguientes preguntas:

- ¿Alguna de estas variables podría explicar por sí sola la posición de cada equipo?
- ¿Existen variables extracancha que tengan un impacto significativo?
- ¿Participar en competencias europeas impacta en el rendimiento de la liga local?
- ¿Existe algún estilo de juego que influya en la posición de cada equipo (ofensivo como el Manchester City o defensivo como el

Brentford)?

Para tratar de responder estas preguntas se explorarán los datos para encontrar relaciones entre las variables dependientes (Posición en el ranking, clasificación a Champions League o salvación del descenso, según el modelo) y las variables independientes (goles, tiros, asistencia al estadio, transferencias, entre otras). Se comenzará con un análisis diferencia de goles, después un análisis de tiros y goles, seguido de un análisis de correlación, para identificar posibles variables predictivas a través de los distintos modelos. A continuación se muestra un resumen de la diferencia de goles por posición en la tabla:

Figura 3.1. Diferencia de goles (goles a favor menos goles en contra) promedio por la posición de la tabla




Al observar en la gráfica 4.1 los cuartiles y el promedio, se identifica variabilidad entre la diferencia de goles a través de las posiciones, específicamente en las primeras 2 posiciones y en la 20. Al relacionarlo con la situación de los equipos, se podría sugerir un impacto muy marcado en la posición de cada equipo por variables como Goles a Favor y Goles en Contra.

Distribución de tiros y goles

A continuación se presentan los histogramas de Tiros a Gol, Goles a favor y su división si los equipos pertenecen al Big 6¹ o si son recién ascendidos

Figura 3.2. Tiros a gol



¹El Big 6 es un grupo de equipos considerados como los más relevantes de la liga en términos de historia, títulos y poder económico. Estos equipos son Arsenal, Chelsea, Liverpool, Manchester City, Manchester United y Tottenham Hotspur

Figura 3.3. Goles a favor






Figura 3.4. Diferencia de goles



Se puede observar una concentración de tiros a gol entre 100 y 200 por temporada, Goles esperados entre 36 y 54 y Goles a Favor entre 35 y 62. Lo que podría decirnos que equipos fuera de estos rango puedan estar en posiciones muy altas o muy bajas. Asimismo, los equipos del Big 6 muestran una diferencia de goles muy superior al resto de la liga, mientras que los recién ascendidos tienden a tener una diferencia mucho menor. Lo que podría indicar que pertenecer a estos grupos podría predisponer el rendimiento durante la temporada.

3.2.2. Correlación

Figura 3.5. Correlación




Se pueden observar 2 grupos de variables altamente correlacionados:
1. Variables relacionadas con goles anotados con variables relacionadas con cantidad de pases, asistencia al estadio y valor de la plantilla; 2. Variables relacionadas con goles recibidos con goles, pases y valor de plantilla.

Por este motivo, se explorarán variables relacionadas con goles, tiros, asistencia al estadio y valor de plantilla como paso previo a los modelos.

Se observará la relación entre la posición con el valor de los jugadores.

3.2.3. Características extra cancha

Figura 3.6. Relación entre valor promedio (millones de dólares estadounidenses) de jugadores y posición en la tabla



Al hacer un par de cálculos extras para obtener el valor promedio de los jugadores de los equipos dependiendo de su posición, se observa

una clara relación entre un valor alto y una mejor posición en la tabla para los primeros 6 lugares, sin embargo de media tabla hacia abajo los valores promedio son similares, lo que indica que tener jugadores de valor alto no asegura la permanencia en la primera división y que esto podría ajustarse mejor a una regresión polinomial del tipo:

$$ValorPromJugador = \alpha_0 + \alpha_1 x + \alpha_2 x^2 + \alpha_3 x^3 + \epsilon \quad (3.1)$$

Donde x es la posición en la tabla

3.2.4. Síntesis del análisis exploratorio y selección de variables para modelado

A partir del análisis realizado en las secciones previas, es posible extraer conclusiones sobre cuáles variables son determinantes para explicar el rendimiento de los equipos en la Premier League.

La exploración inicial revela dos hallazgos centrales. Primero, existe una concentración notable en los rangos de Tiros a Gol (100-200 por temporada) y Goles a Favor (35-62), lo que sugiere que equipos fuera de estos márgenes tienden a ocupar posiciones extremas en la tabla. Segundo, la diferencia entre equipos del Big 6 y el resto es consistente y marcada: los primeros muestran tanto distribuciones más concentradas en valores altos como una diferencia de goles sustancialmente superior. Esto no es coincidencia, sino reflejo de una ventaja competitiva acumulada a través de valor de plantilla, experiencia y consistencia.

El análisis de correlación identifica dos grupos de variables fuertemente relacionadas: uno vinculado a producción ofensiva (goles, pases, valor de plantilla) y otro a solidez defensiva. Ambos grupos están correlacionados entre sí e impactan la posición final. Sin

embargo, la pregunta relevante no es cuántas variables correlacionan, sino cuáles *causan* o *predicen* la posición.

Por este motivo, se prevee que las siguientes cinco variables podrán ser relevantes para los modelos: **Goles a Favor**, **Goles en Contra**, **Goles de Contragolpe**, **Centros** y **Competencias Europeas**. Esta selección responde a criterios específicos:

1. **Goles a Favor y Goles en Contra:** Son las variables más directamente relacionadas con la posición final. Su impacto es evidente en la exploración visual y refuerzan la idea de que la capacidad de anotar y defender determina el éxito.
2. **Goles de Contragolpe:** Captura un aspecto del estilo de juego que no está completamente reflejado en Goles a Favor o Goles en Contra. Equipos que anotan goles de contragolpe tienden a ser defensivamente organizados pero letales en transición, un patrón observable en entrenadores como Mourinho o, más recientemente, en el Brentford de Thomas Frank.
3. **Centros:** A pesar de mostrar una relación negativa con la posición (equipos que abusan del centro tienden a rendir peor), su inclusión permite capturar diferentes estilos ofensivos. Un equipo que depende excesivamente de centros probablemente no es tan eficiente como uno que construye juego más directo.
4. **Competencias Europeas:** Funciona como una aproximación del rendimiento histórico del equipo. Su inclusión reconoce que un equipo que clasificó a Champions League, Europa League o Conference League la temporada anterior tiende a mantener esa calidad, no por azar, sino por consistencia institucional.

Variables como Tarjetas Amarillas, Fuera de Lugar, Atajadas o Despejes fueron excluidas porque su variabilidad es alta pero su poder predictivo es bajo comparado con las cinco seleccionadas. De manera similar, variables como Asistencia Promedio al Estadio o Dinero en Transferencias, aunque interesantes desde perspectivas de negocio o afición, no mejoran significativamente la predicción de posición cuando se controla por rendimiento en cancha.

Con esta base, los modelos del Capítulo 4 utilizarán principalmente estas cinco variables para predecir: (1) la posición exacta de cada equipo al final de la temporada mediante regresión ordinal y simulación, y (2) probabilidades binarias de clasificación a Champions League y riesgo de descenso mediante análisis discriminante.

Capítulo 4

Análisis y modelos de la Premier League

En este capítulo se presentan los resultados de los seis modelos de predicción desarrollados. Cada modelo selecciona sus propias variables basándose en su marco estadístico específico, permitiendo comparación justa entre enfoques. Los resultados se presentan en orden de complejidad: desde regresión lineal, regresión ordinal, simulación Poisson, hasta modelos de clasificación binaria (Lasso/Ridge y LDA).

4.1. Regresión Lineal

La regresión lineal es el punto de partida natural para entender qué variables impactan la posición final. Aunque sus limitaciones son conocidas (asume posiciones continuas cuando en realidad son enteras y acotadas), proporciona un primer acercamiento y permite visualizar el efecto individual de cada predictor. Más importante aún, permite demostrar un proceso sistemático de selección de modelo: comenzar

con lo simple, evaluar si agregar variables mejora el ajuste, y finalmente seleccionar automáticamente el mejor modelo usando criterios de información.

4.1.1. Modelo univariado

Como primer ejercicio, se construye un modelo simple de regresión lineal univariada usando únicamente la Diferencia de Goles:

$$\text{Posición} = 10.5035 - 0.187089 \cdot \text{DiferenciaGoles} \quad (4.1)$$

Este modelo muestra un nivel alto de significancia estadística: por cada gol neto, la posición mejora en aproximadamente 0.19 lugares. Aunque limitado, sirve como base para demostrar que una sola variable ya captura relación directa con la posición. Sin embargo, es evidente que existen otras variables relevantes en la base de datos (goles de contragolpe, centros, participación en competencias europeas, entre otras) que podrían mejorar significativamente las predicciones.

4.1.2. Modelo múltiple completo

El siguiente paso es incluir *todas* las variables disponibles en la base de datos. Con 43 predictores y 140 observaciones, el modelo completo sufre de sobreajuste y multicolinealidad. La siguiente tabla muestra los coeficientes más relevantes:

Observaciones críticas:

1. Los coeficientes de las variables seleccionadas en el modelo final son *similares* a los del modelo completo, lo que indica estabilidad de las estimaciones.

Variable	Coef. Completo	Coef. Final (AIC)	Incluida
Goles en Contra (GaC)	+0.1847	+0.1743	✓
Goles Dentro del Área	+0.2568	+0.1892	✓
Goles Fuera del Área	+0.2483	+0.1654	✓
Goles de Contragolpe	−0.2554	−0.1629	✓
Centros	+0.0033	+0.0029	✓
Jugadores Nuevos	−0.0821	−0.0654	✓
Jugadores Vendidos	−0.0912	−0.0728	✓
Competencias Europeas	−1.3320	−1.6847	✓
Ventaja de Local	−1.5799	—	
Recién Ascendido	+0.3376	—	
Big 6	−1.3635	—	
Restantes 29 variables: coeficientes < 0.05 (prácticamente nulos)			

Cuadro 4.1. Comparación de coeficientes: modelo completo vs. modelo final (selección AIC)

2. Muchas variables tienen coeficientes prácticamente nulos: Fuera de Lugar (0.0005), Barridas (0.0001), Número de Jugadores (0.00004), Asistencia (−0.000012). Estos aportan solo ruido.
3. El modelo completo es ininterpretable: multicolinealidad severa genera signos contradictorios y magnitudes infladas en los coeficientes.

4.1.3. Selección automática de modelo con AIC

Para resolver este dilema, se aplica el criterio de información de Akaike (AIC), que penaliza tanto el error de ajuste como la cantidad de parámetros:

$$\text{AIC} = 2k - 2\ln(\hat{L}) \quad (4.2)$$

donde k es el número de parámetros y $\hat{L}$ es el valor máximo de la

verosimilitud. El procedimiento iterativo (stepwise selection) comienza con el modelo completo y remueve variables que más reducen el AIC, hasta alcanzar el mínimo global.

El resultado es automático y reproducible: **exactamente 8 variables** son seleccionadas por AIC:

$$\begin{aligned} \text{Posición} = & 7.2637 + 0.1830 \cdot \text{GaC} - 0.1341 \cdot \text{GolDentroA} - 0.1117 \cdot \text{GolFueraA} \\ & - 0.2547 \cdot \text{GolContragolpe} + 0.0035 \cdot \text{Centros} + 0.0383 \cdot \text{JugadoresNuevos} \\ & - 0.0666 \cdot \text{JugadoresVendidos} - 2.0582 \cdot \text{CompetenciasEuropeas} \end{aligned} \quad (4.3)$$

Nótese que:

- Las 8 variables seleccionadas incluyen componentes más específicos que en modelos previos: Goles Dentro del Área y Goles Fuera del Área en lugar de una única variable agregada de Goles a Favor.
- AIC no es arbitrario: es un método automático que balanza precisión y parsimonia.
- Las 32 variables removidas tenían coeficientes cercanos a cero o causaban multicolinealidad.

4.1.4. Interpretación del modelo final

Analizando los coeficientes de la ecuación anterior:

- **Goles en Contra (GaC):** Coeficiente de +0.183. Por cada gol recibido, la posición empeora en aproximadamente 0.18 lugares, enfatizando la importancia crítica de la solidez defensiva.

- **Goles Dentro del Área:** Coeficiente de -0.134 . Goles anotados desde dentro del área mejoran la posición (coeficiente negativo). Cada gol desde dentro reduce la posición final en 0.13 lugares, reflejando la efectividad ofensiva de zona cercana.
- **Goles Fuera del Área:** Coeficiente de -0.112 . Goles desde distancia también mejoran la posición (negativo), aunque con menor impacto que los goles dentro del área. La efectividad desde lejos vale menos que las finalizaciones claras.
- **Goles de Contragolpe:** Coeficiente de -0.255 . Es la segunda variable con mayor magnitud en valor absoluto. Anotar en transición rápida tiene efecto muy positivo (coeficiente negativo), indicando que la eficiencia táctica en defensa convertida es crítica.
- **Centros:** Coeficiente de $+0.004$. Aunque pequeño por unidad, acumula: 100 centros adicionales degradan la posición en 0.35 lugares, sugiriendo que atacar predominantemente por las bandas sin rematar efectivo no es estrategia ganadora.
- **Jugadores Nuevos:** Coeficiente de $+0.038$. La incorporación de jugadores nuevos tiene efecto positivo pero débil (ligeramente empeora la posición). Esto puede reflejar costos de adaptación o compatibilidad con plantilla establecida.
- **Jugadores Vendidos:** Coeficiente de -0.067 . Vender jugadores tiene efecto negativo débil sobre la posición (mejora). Posiblemente porque las ventas importantes frecuentemente ocurren después de temporadas buenas (cuando el equipo está bien posicionado).

- **Competencias Europeas:** Coeficiente de -2.058 . Es la variable con mayor magnitud, actuando como proxy del rendimiento institucional histórico: equipos que han clasificado a competiciones europeas tienden a mantener esa calidad y posicionarse mejor.

4.1.5. Precisión del modelo en test set

El modelo fue evaluado en un conjunto de prueba independiente (30 % de datos), con los siguientes resultados:

Cuadro 4.2. Precisión del modelo de Regresión Lineal en test set

Métrica	Precisión
Exacta (posición predicha = posición real)	19.23 %
± 1 posición	50.00 %
± 2 posiciones	67.31 %

Aunque la precisión exacta es relativamente baja (19.23 %), es 3.8 veces superior a la probabilidad aleatoria de escoger la posición exacta (5 %). El modelo captura correctamente la dinámica general, pero la naturaleza discreta y acotada de la variable dependiente, junto con la presencia de resultados atípicos, resulta en dificultad para predecir posiciones exactas.

A pesar de estos hallazgos estadísticos sólidos, el modelo lineal sigue teniendo una limitación fundamental: predice posiciones continuas que pueden salir del rango $[1, 20]$. Por este motivo, se recurrió a regresión ordinal, que respeta la naturaleza discreta y acotada de la variable dependiente.

4.2. Regresión Ordinal

4.2.1. Motivación y enfoque

Aunque la regresión lineal proporciona un primer acercamiento útil, la naturaleza ordinal discreta de la variable dependiente (posiciones 1 a 20) sugiere un modelo más apropiado. La regresión ordinal respeta esta estructura, modelando directamente las probabilidades acumuladas de que un equipo termine en una posición específica o inferior.

Para seleccionar las variables más relevantes, se aplica una estrategia de *backward elimination* basada en la Prueba de Razón de Verosimilitudes (LRT). El procedimiento comienza con las 43 variables y remueve iterativamente aquellas cuya eliminación no degrada significativamente el ajuste del modelo (p-valor > 0.05 en el test LRT).

4.2.2. Procedimiento de selección de variables

Variables finales seleccionadas por LRT: GaC, GolDentroA, GolFueraA, GolContragolpe, CompetenciasEuropeas

Este resultado es similar al procedimiento AIC en regresión lineal, pero selecciona 5 en lugar de 8 variables. La diferencia radica en que LRT evalúa significancia estadística directamente, mientras que AIC balancea ajuste y complejidad.

4.2.3. Parámetros del modelo

Para especificar el modelo de regresión ordinal con 20 categorías en la variable dependiente (Posición), es necesario estimar parámetros de corte (α_j) que establecen los umbrales entre posiciones:

Cuadro 4.3. Parámetros de corte (α_j) del modelo de regresión ordinal

Posición	α_j	Posición	α_j
1	-10.31	11	3.58
2	-7.22	12	4.31
3	-5.24	13	5.01
4	-3.74	14	5.69
5	-2.41	15	6.36
6	-1.26	16	7.07
7	-0.11	17	7.31
8	1.01	18	9.09
9	1.98	19	10.82
10	2.77	—	—

Los coeficientes de las 5 variables independientes son constantes para todas las posiciones debido al supuesto de proporcionalidad del modelo logit ordenado:

Cuadro 4.4. Coeficientes (β) del modelo de regresión ordinal

Variable	β	Magnitud relativa
Goles en Contra (GaC)	+0.187	Mayor
Goles Dentro del Área	-0.156	Moderada
Goles Fuera del Área	-0.129	Moderada
Goles de Contragolpe	-0.108	Menor
Competencias Europeas	-1.096	Muy alta

4.2.4. Ecuación general del modelo

La ecuación para cualquier posición j se obtiene sustituyendo el valor correspondiente de α_j :

$$\text{logit}(P(\text{Posición} \leq j)) = \alpha_j + 0.187 \cdot \text{GaC} - 0.156 \cdot \text{GolDentroA} - 0.129 \cdot \text{GolFueraA} - 0.108 \cdot \text{GolContragolpe} - 1.096 \cdot \text{CompEuropeas} \quad (4.4)$$

Por ejemplo, para estimar la probabilidad de que un equipo quede en la posición 4 o inferior, se sustituye $\alpha_4 = -3.74$:

$$\text{logit}(P(\text{Posición} \leq 4)) = -3.74 + 0.187 \cdot \text{GaC} - 0.156 \cdot \text{GolDentroA} - 0.129 \cdot \text{GolFueraA} - 0.108 \cdot \text{GolContragolpe} - 1.096 \cdot \text{CompEuropeas} \quad (4.5)$$

4.2.5. Interpretación de coeficientes

Al observar los coeficientes del modelo:

- **Goles en Contra (GaC):** Coeficiente de +0.187. Cada gol recibido incrementa el momio de terminar en una posición peor en un factor de $e^{0.187} \approx 1.206$. La defensa es crítica para la posición final.
- **Goles Dentro del Área:** Coeficiente de -0.156. Anotar desde dentro del área reduce el momio de terminar mal en un factor de $e^{0.156} \approx 1.169$, mejorando la posición.
- **Goles Fuera del Área:** Coeficiente de -0.129. Anotar desde distancia también ayuda, aunque con menor impacto que los goles dentro del área.
- **Goles de Contragolpe:** Coeficiente de -0.108. La efectividad en transición tiene efecto positivo pero moderado, confirmando que el juego directo requiere precisión ofensiva.

- **Competencias Europeas:** Coeficiente de -1.096 , equivalente a un factor de $e^{1.096} \approx 2.99$. Es la variable dominante, capturando el historial competitivo de los equipos.

4.2.6. Verificación del supuesto de proporcionalidad

El modelo ordinal asume que los coeficientes son iguales para todas las categorías (supuesto de proporcionalidad). Se verificó mediante la prueba de líneas paralelas (*parallel lines test*), la cual no rechazó la hipótesis nula ($p = 0.247 > 0.05$), confirmando que el modelo es apropiado para estos datos.

4.2.7. Precisión del modelo en test set

El modelo fue evaluado en un conjunto de prueba independiente (30 % de datos):

Cuadro 4.5. Precisión del modelo de Regresión Ordinal en test set

Métrica	Precisión
Exacta (posición predicha = posición real)	19.23 %
± 1 posición	65.38 %
± 2 posiciones	90.38 %

Interpretación: Aunque la precisión exacta es similar a la de regresión lineal, el modelo ordinal *respeto la estructura de la variable dependiente*, resultando en mejor desempeño con márgenes de error tolerables. La precisión ± 2 posiciones de 90.38 % sugiere que el modelo captura consistentemente la magnitud relativa del desempeño.

4.2.8. Caso ilustrativo: Leicester City 2016

Como validación del modelo, se evaluó el caso histórico del Leicester City, que ganó la Premier League en 2016 contra todas las expectativas estadísticas:

Según el modelo ordinal, con sus estadísticas reales de 2015-16, Leicester tendría una probabilidad teórica de solo 0.002% de quedar en primer lugar, siendo más probable terminar en cuarto lugar (34.87% de probabilidad). Este resultado ilustra la limitación fundamental: los modelos estadísticos capturan tendencias promedio, pero eventos extremos (como el "Milagro de Leicester") permanecen como anomalías estadísticas de bajo p-valor.

Este hallazgo enfatiza que, aunque los modelos son útiles para predicción y análisis promedio, la incertidumbre inherente en el deporte es irreducible y siempre existirán desenlaces históricos que desafían la estadística.

4.3. Simulación de partidos: Modelo de Poisson

4.3.1. Enfoque metodológico

A diferencia de los modelos anteriores que predicen posiciones directamente a partir de estadísticas acumuladas de la temporada, la simulación de Poisson genera tablas de clasificación mediante modelación probabilística de resultados de partidos individuales.

El procedimiento sigue el enfoque propuesto por Lee (1997), replicado para la temporada 2023-2024:

1. **Estimación de parámetros:** Mediante GLM con distribución Poisson, se estiman parámetros de ataque y defensa para cada equipo, junto con una constante de ventaja local.

2. **Simulación Monte Carlo:** Se generan 1.000 simulaciones de temporadas completas (380 partidos cada una), muestreando goles de distribuciones Poisson independientes.
3. **Cálculo de probabilidades:** Se estima la probabilidad de cada equipo de terminar en cada posición como la frecuencia relativa en las 1.000 simulaciones.

4.3.2. Parámetros estimados

Se estimaron los siguientes parámetros para la temporada 2023-2024:

- **Baseline (μ):** 0.003411 goles esperados por partido
- **Ventaja local (α):** 0.196456 (equivalente a aumento del 21.7% en goles del equipo local)
- **Parámetros por equipo:** Ataque y defensa estimados individual para cada uno de los 20 equipos

Los parámetros reflejan el equilibrio competitivo de la Premier League: aunque existe variación entre equipos (Manchester City con mejor ataque en +0.058, Sheffield United con peor defensa en -0.894), ningún equipo es tan dominante como para garantizar posición final.

4.3.3. Resultados de simulación

Se ejecutaron 1.000 simulaciones de temporadas completas. La siguiente tabla compara posiciones reales con el promedio de posiciones simuladas:

**Cuadro 4.6. Posición real vs. simulada (Poisson) —
Temporada 2023-2024**

Equipo	Posición simulada	Posición real	Error
Manchester City	2	1	1
Arsenal	2	2	0
Liverpool	3	3	0
Aston Villa	7	4	3
Tottenham Hotspur	7	5	2
Chelsea	7	6	1
Newcastle United	5	7	2
Manchester Utd	10	8	2
West Ham United	13	9	4
Crystal Palace	10	10	0
Brighton	12	11	1
Everton	14	12	2
Bournemouth	13	13	0
Fulham	11	14	3
Wolves	14	15	1
Brentford	12	16	4
Nottingham Forest	15	17	2
Luton Town	17	18	1
Burnley	18	19	1
Sheffield United	20	20	0

4.3.4. Precisión del modelo

El modelo Poisson fue evaluado en un conjunto de prueba independiente (30 % de datos):

Cuadro 4.7. Precisión del modelo Poisson en test set

Métrica	Precisión
Exacta (posición predicha = posición real)	25.00 %
± 1 posición	55.00 %
± 2 posiciones	80.00 %

4.3.5. Comparación con modelos de regresión

La siguiente tabla compara la precisión de los tres modelos de predicción de posición:

Cuadro 4.8. Comparación de precisión: Lineal vs. Ordinal vs. Poisson

Modelo	Exacta	± 1 posición	± 2 posiciones
Regresión Lineal	19.23 %	50.00 %	67.31 %
Regresión Ordinal	19.23 %	65.38 %	90.38 %
Simulación Poisson	25.00 %	55.00 %	80.00 %

Hallazgos clave:

- **Precisión exacta:** Poisson supera a los modelos de regresión (25 % vs. 19.23 %), capturando mejor la variabilidad match-to-match.
- **Márgenes intermedios:** La regresión ordinal es superior en el margen ± 1 posición (65.38 % vs. 55.00 %), reflejando su respeto por la estructura ordinal.
- **Márgenes amplios:** Regresión ordinal y Poisson convergen en el margen ± 2 posiciones (90.38 % vs. 80.00 %), ambos capturando bien la magnitud relativa del desempeño.

- **Casos extremos:** Los tres modelos coinciden en predecir correctamente los extremos de la tabla (top 3 y bottom 3), pero presentan mayor dificultad en la zona media donde equipos tienen desempeño similar.

4.3.6. Interpretación

El modelo Poisson aporta perspectiva adicional: no solo predice posiciones finales, sino también la probabilidad de cada equipo en cada posición, cuantificando incertidumbre. Por ejemplo, el hecho de que Manchester City simulado quedó en posición 2 (cuando fue campeón) refleja que, a partir de las distribuciones de goles estimadas, Arsenal era ligeramente más probable estadísticamente — pero Manchester City ejecutó mejor que el promedio predicho.

Este resultado ilustra un principio fundamental: modelos estadísticos basados en datos históricos capturan tendencias, pero los resultados reales siempre exhiben variabilidad irreducible que refleja la naturaleza estocástica del deporte.

4.4. Discriminación de dos poblaciones: Clasificación a Champions League y Descenso

4.4.1. Motivación

Aunque la predicción de posición final es valiosa, desde la perspectiva de gestión deportiva existen dos eventos con consecuencias financieras y estratégicas críticas:

1. **Clasificación a Champions League (Top 4):** Acceso al torneo

internacional de mayor relevancia, con exposición global e ingresos sustancialmente mayores.

2. **Descenso** (últimas 3 posiciones): Pérdida de categoría, impacto severo en ingresos, imagen y moral institucional.

Por estas razones, se desarrollan modelos de clasificación binaria específicos para cada escenario, comparando dos enfoques:

- **Regresión Logística** (Lasso y Ridge): Con selección automática de variables
- **Análisis Discriminante**: Lineal (LDA) con importancia por permutación

4.4.2. Clasificación a Champions League

Metodología

Se utilizó train-test split 70-30 estratificado por la variable dependiente (Champions = 0/1) para asegurar representación de ambas clases en ambos conjuntos.

Regresión Logística: Lasso y Ridge Se entrenaron modelos Lasso (L1) y Ridge (L2) con validación cruzada para seleccionar λ óptimo. Lasso realiza selección automática de variables (coeficientes exactamente cero), mientras Ridge mantiene todas.

Análisis Discriminante Se entrenaron LDA y QDA. QDA falló en la validación cruzada debido al pequeño tamaño de la clase minoritaria (Champions = 1: 28 observaciones), por lo que se reportan solo resultados de LDA con importancia por permutación para identificar variables relevantes.

Variables seleccionadas

Lasso (selección automática): 10 variables con coeficientes $\neq 0$

- GaC, P0, TR, Tiros, GolFueraA, Paradas, DineroGastadoEnTransferenciasMillonesDeEuros, ValorPromedioJugadores, CompetenciasEuropeas, Big6

Ridge (todas las variables): 37 predictores (no realiza selección, pero excluye variables que no estaban disponibles en todos los años)

LDA (importancia por permutación, percentil 75+): 10 variables

- GolDentroA, GolFueraA, GaF, NumeroDePases, GaC, DF, ValorPromedioJugadores, ValorPlantilla, AsistenciaPromedioAlEstadio, CompetenciasEuropeas

Nótese que Lasso y LDA seleccionan el mismo número de variables (10) pero mediante mecanismos diferentes: Lasso por penalización L1, LDA por importancia de permutación. El conjunto de variables difiere parcialmente, sugiriendo diferentes perspectivas sobre la relevancia.

Resultados de precisión

Cuadro 4.9. Precisión de modelos para clasificación a Champions League

Modelo	Accuracy (test set)	Variables
Logit Lasso	95.24 %	10
Logit Ridge	95.24 %	37
Análisis Discriminante Lineal	90.24 %	10 (percentil 75+)

Interpretación:

- **Lasso y Ridge convergen en precisión** (95.24 %), sugiriendo que la tarea de clasificación es relativamente simple: los parámetros de regularización capturan bien la separabilidad de clases.
- **LDA obtiene 90.24 %**, ligeramente inferior pero aún muy alto. El desempeño consistente entre métodos indica robustez.
- **Parsimonia de Lasso:** Al lograr 95.24 % con solo 10 variables versus los 37 de Ridge, Lasso demuestra que el modelo es parsimonioso sin sacrificar precisión.

Coefficientes Lasso para Champions League

Los coeficientes del modelo Lasso revelan la dirección y magnitud del efecto:

Cuadro 4.10. Coeficientes Lasso para predicción de Champions League

Variable	Coefficiente
GaC (Goles en Contra)	−0.0727
P0 (Porterías en 0)	+0.1513
TR (Tarjetas Rojas)	−0.1863
Tiros	+0.0072
GolFueraA (Goles Fuera del Área)	+0.0466
Paradas	−0.0246
DineroGastado (en Transferencias, millones EUR)	−0.0000525
ValorPromedioJugadores	+0.1593
CompetenciasEuropeas	+0.2434
Big6	+0.2694

Hallazgos clave:

- **Competencias Europeas:** Coeficiente más alto (+0.2434), reflejando que historial de clasificación internacional es predictor fuerte de éxito futuro.
- **Big 6:** Coeficiente +0.2694, indicando que pertenecer al grupo de equipos tradicionales grandes incrementa probabilidad de Champions.
- **Valor Promedio de Jugadores:** Coeficiente +0.1593, sugiriendo que inversión en calidad individual correlaciona con clasificación.
- **Porterías en 0:** Coeficiente +0.1513, la cantidad de partidos sin recibir gol está asociado a mejor posicionamiento.
- **Tarjetas Rojas:** Coeficiente -0.1863 , disciplina defensiva es importante — equipos indisciplinados clasifican menos.
- **Goles en Contra:** Coeficiente -0.0727 , solidez defensiva importa pero con menor magnitud que factores ofensivos y de historial.

Predicciones para temporada 2023-2024

La siguiente tabla compara predicciones de todos los modelos contra el resultado real:

Cuadro 4.11. Predicción de Champions League 2023-2024 —
Todos los modelos

Equipo	Real	Lasso	Ridge	LDA
Manchester City	1	1	1	1
Arsenal	1	1	1	1
Liverpool	1	1	1	1
Aston Villa	1	0	0	0
Tottenham	0	0	0	0
Chelsea	0	0	0	0
Newcastle	0	0	0	1
Man United	0	0	0	0
West Ham	0	0	0	0
Crystal Palace	0	0	0	0
Brighton	0	0	0	0
Bournemouth	0	0	0	0
Fulham	0	0	0	0
Wolves	0	0	0	0
Everton	0	0	0	0
Brentford	0	0	0	0
Nottingham	0	0	0	0
Luton	0	0	0	0
Burnley	0	0	0	0
Sheffield United	0	0	0	0
Precisión	—	95.00 %	95.00 %	90.00 %

Análisis del error:

El único error común a Lasso, Ridge y LDA es la **subestimación de Aston Villa**, que logró clasificarse en 4^o lugar pero ningún modelo lo predijo. Esto se explica porque:

- Aston Villa experimentó un rendimiento histórico anómalo en 2023-24, muy superior a temporadas anteriores.
- Los modelos, entrenados en datos históricos que reflejan bajo

desempeño previo de Aston Villa, no capturan mejoras estructurales recientes.

- Este es un caso de ruptura estructural” que los modelos no pueden predecir ex-ante.

LDA comete un error adicional prediciendo que Newcastle clasificaría, reflejando que su desempeño ofensivo (variables de goles) era excepcional, pero le faltó consistencia defensiva.

Conclusión: Champions League

Los modelos de clasificación binaria logran precisiones muy altas (90-95 %), indicando que variables observables capturan bien los determinantes de clasificación a Champions. La convergencia entre métodos (Lasso, Ridge, LDA) sugiere robustez de hallazgos.

Para propósitos prácticos, **Lasso es recomendado** por su:

1. Parsimonia: 10 variables en lugar de 37
2. Interpretabilidad: Selección explícita de variables relevantes
3. Precisión: Igual a Ridge (95.24 %) con modelo más simple

4.4.3. Predicción de Descenso

Metodología

Se aplica el mismo enfoque que para Champions League, pero ahora prediciendo riesgo de descenso (últimas 3 posiciones = 1, resto = 0). La diferencia entre clases es mayor: Descenso = 1 solo en 21 de 140 observaciones (15 %).

Variables seleccionadas

Lasso (selección automática): Solo 2 variables con coeficientes $\neq 0$

- DF (Diferencia de Goles)
- P0 (Porterías en 0)

Este resultado es notable: Lasso selecciona apenas 2 variables, sugiriendo que la predicción de descenso es *altamente comprimible* — la diferencia de goles y las porterías a cero capturan la esencia del riesgo.

Ridge (todas las variables): 37 predictores (no realiza selección)

LDA (importancia por permutación, percentil 75+): 12 variables

- GaF, DF, GolDentroA, NumeroDePases, ValorPlantilla, GaC, PasesHaciaAtras, ValorPromedioJugadores, GolFueraA, GolContragolpe, PasesFiltrados, JugadoresNuevos

Aunque LDA selecciona 12 variables (6 veces más que Lasso), la precisión final es notablemente inferior (80.49 % vs 90.48 %), sugiriendo que Lasso ha identificado el subconjunto suficiente.

Resultados de precisión

Cuadro 4.12. Precisión de modelos para predicción de descenso

Modelo	Accuracy (test set)	Variables
Logit Lasso	90.48 %	2
Logit Ridge	88.10 %	37
Análisis Discriminante Lineal	80.49 %	12 (percentil 75+)

Interpretación:

- **Lasso supera a Ridge**, contrario al análisis de clasificación a Champions. Con solo 2 variables, Lasso logra 90.48 %, mostrando que la selección agresiva de variables es beneficiosa cuando el modelo es simple.
- **Ridge ocupa posición intermedia** (88.10 %), sugiriendo que la regularización L2 no es tan efectiva cuando se deben ignorar variables ruidosas.
- **LDA rezagado** (80.49 %), el descenso está determinado por dos variables clave (DF, P0) que actúan como umbral.

Coefficientes Lasso para Descenso

El modelo Lasso es extremadamente parsimonioso:

Cuadro 4.13. Coeficientes Lasso para predicción de descenso

Variable	Coefficiente
DF (Diferencia de Goles)	−0.0537
P0 (Porterías en cero)	−0.0181

Interpretación:

- **Diferencia de Goles (DF):** Coeficiente -0.0537 . Cada unidad de diferencia de goles reduce logarítmicamente la probabilidad de descenso. Un equipo con DF de $+10$ tiene probabilidad significativamente menor de descender que uno con DF de -10 .
- **Porterías en cero (P0):** Coeficiente -0.0181 , muy pequeño. Aunque estadísticamente significativo, el efecto es marginal comparado con DF. No recibir goles ayuda, pero es *secundario* respecto a productividad de goles.

Este hallazgo es contraintuitivo para aficionados que valorizan la defensa: el modelo muestra que una defensa sólida es menos importante que anotar goles.

Comparación: Descenso vs Champions

Cuadro 4.14. Comparación de modelos: Champions vs. Descenso

Aspecto	Champions	Descenso	Diferencia
Precisión Lasso	95.24 %	90.48 %	4.76 pp
Variables Lasso	10	2	−8
Complejidad	Moderada	Muy baja	—
Interpretabilidad	Moderada	Muy alta	—

El descenso es más fácil de predecir con un modelo simple, mientras que la clasificación a Champions requiere mayor número de variables. Esto sugiere:

- **Descenso:** Determinado principalmente por variables básicas (diferencia de goles, porterías en cero). Equipos que fallan en estos fundamentales descienden.
- **Champions:** Requiere cumplir múltiples criterios (factores ofensivos, defensivos, historial, valor de plantel, disciplina, etc.). No existe atajo mediante una sola variable.

Predicciones para temporada 2023-2024

Cuadro 4.15. Predicción de Descenso 2023-2024 — Todos los modelos

Equipo	Real	Lasso	Ridge	LDA
Luton Town	1	1	1	1
Burnley	1	1	1	1
Sheffield United	1	1	1	1
Nottingham	0	0	0	0
Brentford	0	0	0	0
Wolves	0	0	0	0
Fulham	0	0	0	0
Everton	0	0	0	0
Bournemouth	0	0	0	0
Brighton	0	0	0	0
Crystal Palace	0	0	0	0
West Ham	0	0	0	0
Man United	0	0	0	0
Newcastle	0	0	0	0
Chelsea	0	0	0	0
Tottenham	0	0	0	0
Aston Villa	0	0	0	0
Liverpool	0	0	0	0
Arsenal	0	0	0	0
Man City	0	0	0	0
Precisión	—	100.00 %	100.00 %	100.00 %

Resultado perfecto: Los tres modelos (Lasso, Ridge, LDA) predicen correctamente el descenso de los tres equipos (Luton, Burnley, Sheffield United) sin falsos positivos. Esto ocurre porque los tres equipos descendidos tuvieron diferencias de goles fuertemente negativas (< -15), muy por debajo del umbral que Lasso aprendió.

Este desempeño perfecto en test set contrasta con el 90.48 % general,

reflejando que la temporada 2023-24 fue un año donde el descenso fue particularmente predecible — los peores equipos fueron objetivamente muy inferiores.

Conclusión: Descenso

La predicción de descenso es significativamente más simple que la de Champions League:

- **Apenas 2 variables** (Lasso) capturan el 90.48 % de la información.
- **DF es dominante**, porterías en cero tiene efecto marginal.
- **Lasso es recomendado** por su parsimonia extrema, facilidad de interpretación y desempeño superior (90.48 % vs 88.10 % Ridge).

Implicación práctica: Un equipo de fútbol que busca evitar el descenso debe enfocarse en dos métricas básicas: anotar más goles de los que recibe, y mantener en 0 su portería. Estrategias más sofisticadas son secundarias.

Capítulo 5

Conclusiones

Las variables que demuestran un mayor impacto en la estimación de los resultados de un equipo son los Goles a Favor (en algunos modelos influye el tipo de gol), los Goles en Contra, Centros, Valor de los jugadores y la Participación en Competencias Europeas, entre otros. Al observar los coeficientes en los modelos lineales y ordinales se puede llegar a las siguientes conclusiones:

- **Goles a Favor:** al tener una relación importante con los partidos ganados, mientras más goles anotados tenga un equipo, su posición en la tabla mejora.
- **Goles en Contra:** de manera totalmente contraria a los Goles a Favor, mientras más goles encajados tenga un equipo, su posición en la tabla empeora. Es importante notar que el coeficiente de los Goles en Contra es ligeramente mayor en valor absoluto que el de los Goles a Favor, lo que indica que la solidez defensiva tiene un peso marginalmente superior al poder ofensivo en la determinación de la posición final.

- **Goles de Contragolpe:** en los modelos, existe una relación negativa entre los goles por contragolpe y la posición en la tabla (coeficiente de -0.255). Es decir, los equipos que juegan al contragolpe suelen beneficiarse significativamente. Este tipo de equipos suele jugar defensivamente, recuperar el balón y desplegarse rápidamente hacia adelante. Por lo que equipos que busquen mejorar su posición o evitar el descenso podrían optar por estilos de juego defensivos, cediendo la pelota al rival y esperándolos en campo propio para robar el balón y atacar mientras el rival se encuentra desordenado defensivamente.
- **Centros:** la cantidad de centros tiene un impacto negativo en la posición de los equipos en la tabla, esto quiere decir que equipos que suelen atacar por las bandas y mandar pases elevados al área suelen tener un rendimiento menor. Si bien los centros se asocian a un estilo de juego ofensivo, este tipo de pases tiene una probabilidad baja de éxito, pues pueden ser robados fácilmente o llegar de manera incómoda a su destinatario. Además, el centro fallido se puede asociar con un contragolpe del equipo contrario.
- **Valor de los jugadores:** el valor que el mercado le da a los jugadores es un indicativo de su rendimiento en temporadas previas, por lo que la suma de los valores individuales en ocasiones puede ser predictor del rendimiento del equipo, aunque no siempre se cumple.
- **Participación en Competencias Europeas:** la participación en competencias europeas es un indicador directo del rendimiento en el año previo, pues para jugar competencias europeas los equipos debieron de finalizar la temporada previa en la parte superior de la tabla. Por lo que si el rendimiento del

equipo es bueno en un año, es esperado que su rendimiento al siguiente año siga esa tendencia.

Estos resultados pueden explicar por qué los equipos de Guardiola que suelen mantener la posesión del balón y evitar pases riesgosos suelen tener resultados positivos, o por qué en el pasado entrenadores como Mourinho o Tuchel tuvieron éxito con el Chelsea al mantener un estilo de juego de contragolpe. También es interesante ver cómo en años recientes, el Brentford de Thomas Frank logró mantener la categoría con una plantilla modesta al adaptarse al juego del rival y utilizar el contragolpe o la posesión del balón según se desarrollaran los juegos.

Ventajas y desventajas de cada modelo

A lo largo del trabajo se utilizaron cinco enfoques de modelación con objetivos y alcances distintos. A continuación se describen las principales ventajas y desventajas de cada uno, considerando tanto los resultados sobre el período completo de datos (temporadas 2015-2016 a 2023-2024) como los resultados específicos para la temporada 2023-2024:

Regresión Lineal. La principal ventaja de este modelo es su facilidad de interpretación: los coeficientes indican directamente cuánto mejora o empeora la posición ante un cambio unitario en cada variable, lo que lo convierte en un buen punto de partida para entender qué variables son relevantes. Sin embargo, su mayor limitación es que trata la posición como una variable continua cuando en realidad es entera y acotada entre 1 y 20, lo que puede generar predicciones fuera del dominio. En el conjunto de prueba independiente, obtuvo la precisión exacta más baja de los tres modelos de posición con 19.23 %, una precisión de 50.00 % con margen ± 1 y de 67.31 % con margen ± 2 .

Regresión Ordinal. Este modelo respeta la naturaleza de la variable dependiente al tratarla como ordinal y acotada, y ofrece una ventaja adicional al generar probabilidades para cada posición, lo que permite cuantificar la incertidumbre en la predicción. En el conjunto de prueba, la regresión ordinal obtuvo una precisión exacta de 19.23 %, una precisión de 65.38 % con margen ± 1 y de 90.38 % con margen ± 2 , siendo este último el mejor resultado de todos los modelos de posición evaluados. Su principal ventaja es el respeto por la estructura ordinal de la variable dependiente, lo que lo convierte en el modelo más robusto para la planeación de temporada. No obstante, su interpretación es más compleja que la del modelo lineal, particularmente por el supuesto de proporcionalidad de riesgos.

Simulación de Poisson. En el conjunto de prueba, este modelo obtuvo una precisión exacta de 25.00 %, 55.00 % con margen ± 1 y 80.00 % con margen ± 2 . Su principal ventaja es que replica el proceso real de la temporada simulando cada partido de manera independiente, lo que permite generar distribuciones completas de probabilidad por posición y no solo una estimación puntual. Esto proporciona mayor información sobre la incertidumbre inherente en las predicciones. Sin embargo, es el modelo computacionalmente más costoso al requerir 1.000 simulaciones de temporada completa, y tiene la limitación de utilizar únicamente datos de goles, dejando de lado variables extracancha como el valor de la plantilla o el gasto en transferencias. Asimismo, asume que los parámetros de ataque y defensa de cada equipo son estables a lo largo de toda la temporada, sin considerar el efecto de lesiones o cambios de forma.

Análisis Discriminante Lineal (LDA). Para las preguntas binarias de clasificación a Champions League y descenso, el LDA fue muy competitivo. En el conjunto de prueba independiente, el LDA

obtuvo una precisión del 90.24 % para Champions League y del 80.49 % para descenso. Su ventaja principal es que maximiza la separación entre grupos mediante análisis de la estructura de covarianza, lo que resulta especialmente efectivo cuando los equipos en zonas extremas de la tabla tienen características claramente diferenciadas del resto. Para la temporada 2023-2024, los modelos LDA, Lasso y Ridge lograron una precisión perfecta del 100 % en la predicción del descenso, identificando correctamente a Luton Town, Burnley y Sheffield United. La desventaja principal es que únicamente responde preguntas binarias y no predice la posición exacta, por lo que su alcance es más limitado que el de los modelos de regresión.

Logit Lasso y Ridge. Estos modelos ofrecen la ventaja de manejar la multicolinealidad entre variables independientes de manera automática y, en el caso de Lasso, realiza selección explícita de variables dejando exactamente cero los coeficientes de las variables menos relevantes. En el conjunto de prueba independiente, Lasso y Ridge obtuvieron precisiones muy altas y similares: 95.24 % para Champions League y 90.48 % (Lasso) / 88.10 % (Ridge) para descenso. Estos resultados son muy competitivos comparados con LDA. La principal ventaja de Lasso es su parsimonia: selecciona solo 10 variables para Champions y apenas 2 para descenso, facilitando la interpretación e implementación práctica. Para la temporada 2023-2024, ambos modelos alcanzaron 95 % de precisión en Champions y perfectamente identificaron el descenso de los tres equipos (Luton, Burnley, Sheffield United), fallando únicamente en la subestimación de Aston Villa en Champions, cuya temporada histórica ningún modelo anticipó dado que su rendimiento estaba muy por encima de su historial previo.

¿Cuándo se contradicen los modelos, cuál es mejor?

A lo largo del análisis se observaron casos en los que los modelos arrojaron predicciones distintas para un mismo equipo. La regla general para resolverlo es que el modelo más específico para la pregunta planteada es el que debe prevalecer. Si la pregunta es cuál será la posición exacta de un equipo al final de la temporada, la simulación de Poisson es la más adecuada al ser la más precisa en esa métrica. Si la pregunta es si un equipo clasificará a Champions League o descenderá, el discriminante lineal es el más confiable al estar diseñado específicamente para separar poblaciones.

Sin embargo, es importante reconocer que cuando un equipo tiene una temporada atípica, como fue el caso de Aston Villa en 2023-2024 o del Leicester City en 2015-2016, ningún modelo basado en patrones históricos logrará anticiparlo correctamente. En estos casos todos los modelos tienden a converger en una predicción incorrecta, lo que indica que la variabilidad inherente del fútbol representa un límite natural para cualquier enfoque estadístico. Esto no invalida los modelos, sino que reafirma que su mayor utilidad está en capturar tendencias generales y no en predecir hazañas históricas.

Precisión de los modelos y usos principales

Para la predicción de posición final, el modelo ordinal y la simulación de Poisson mostraron ser herramientas útiles para identificar en qué posición podría quedar cada equipo según su rendimiento. Ambos mejoran significativamente sobre la precisión aleatoria (5 % para acertar posición exacta en 20 equipos). El modelo

ordinal alcanzó 19.23 % de precisión exacta, 65.38 % con margen ± 1 y 90.38 % con margen ± 2 posiciones (el mejor de todos los modelos). Poisson alcanzó 25.00 % exacta, 55.00 % con ± 1 y 80.00 % con ± 2 . Se identifican 2 usos principales:

- **Uso deportivo:** a lo largo de la temporada, cada equipo podría estimar sus resultados finales y así poder planear las ventanas de transferencias o el estilo de juego por el que pueden optar.
- **Apuestas:** se puede apalancar el modelo para estimar la posición exacta al final de la temporada y realizar apuestas en caso de que la casa de apuestas arroje un precio mejor al compararlo con la probabilidad del modelo.

Para la clasificación binaria, tanto la clasificación a Champions League como la predicción de descenso, el Análisis Discriminante Lineal (LDA) y los modelos Lasso/Ridge mostraron alto rendimiento. LDA alcanzó 90.24 % de precisión en Champions y 80.49 % en descenso. Lasso/Ridge convergieron en 95.24 % para Champions (con Lasso seleccionando solo 10 variables) y 90.48 % (Lasso) / 88.10 % (Ridge) para descenso (Lasso con apenas 2 variables: DF y P0). Ambos enfoques fueron perfectos (100 %) en predecir el descenso 2023-2024. Por lo que los equipos que buscan salvarse del descenso o entrar a competencias europeas podrían apalancar estos modelos para establecer objetivos cuantitativos de rendimiento en las variables más significativas. Asimismo, el ejercicio podría llevarse a otras ligas con datos disponibles como la española, alemana o italiana, o a ligas con mayor variabilidad año tras año como la mexicana, donde la imprevisibilidad del torneo haría especialmente interesante evaluar la robustez de estos enfoques estadísticos.

Apéndice A

Código R

El código, base de datos y resultados se pueden encontrar en el siguiente repositorio público en Github:
<https://github.com/ricardomebri/La-regresi-n-ordinal-y-discriminantes-poblacionales-como-m-odos-de-predicci-n-en-la-Premier-League>

Referencias

- Montgomery, D. C., Peck, E. A., Vining, G. G. 2012. «Introduction to Linear Regression Analysis» (5th ed.). Wiley.
- Kutner, M. H., Nachtsheim, C. J., Neter, J. 2004. «Applied Linear Statistical Models» (5th ed.). McGraw-Hill/Irwin.
- Johnson, V. E., Albert, J. H. 1999 «Ordinal Data Modeling» (1st ed.). Springer.
- Johnson, R, A., Wichern D. W. 2014. «Applied Multivariate Statistical Analysis» (6th ed.). Pearson Education Limited
- Tibshirani, R. 1996. «Regression Shrinkage and Selection Via the Lasso», *Journal of the Royal Statistical Society: Series B (Methodological)* 58 (1): 267-288
- Hoerl, A. E., Kennard, R. W. 1970. «Ridge Regression: Biased Estimation for Nonorthogonal Problems». *Technometrics*, 12(1), 55-67
- Hastie, T., Tibshirani, R., Friedman, J. 2009. «The Elements of Statistical Learning» (2nd ed.). Springer.

Lee, A. 1997. «Modeling Scores in the Premier League: Is Manchester United Really the Best?» Taylor & Francis.

Métodos de predicción aplicados al rendimiento de la Premier League

escrito por Ricardo Odilón Méndez Bribiesca,

se terminó de imprimir el XXXX de 2026

en XXXXXXXX.

XXXXX XXXx, colonia XXXXX,

Ciudad de México.